

Python によるデータ解析と高速化

Ichiro KOMAE

2026 年 4 月 15 日

目次

はじめに	13
第 1 章 このテキストの使い方	15
1.1 誰のためのテキストか	15
1.2 何を順に学ぶのか	15
1.3 本書で大切にしたい姿勢	16
1.4 章の読み進め方	16
1.5 参考資料	16
1.6 この本の後半で扱う実践的な内容	17
第 2 章 シェルとファイル操作	19
2.1 シェルの基本と環境	19
2.1.1 Windows では WSL を使う	19
2.2 コマンドの基本と使い方	20
2.2.1 コマンド、オプション、引数	20
2.2.2 困ったときは説明を読む	20
2.3 ファイルとディレクトリの操作	21
2.3.1 今どこにいるかを確認する: <code>ls</code>	21
2.3.2 移動する: <code>cd</code>	24
2.3.3 絶対パスと相対パス	25
2.3.4 ディレクトリを作る: <code>mkdir</code>	26
2.4 コピー、移動、削除	27
2.4.1 コピーする: <code>cp</code>	27
2.4.2 移動する、名前を変える: <code>mv</code>	28
2.4.3 削除する: <code>rm</code>	29
2.4.4 ワイルドカード	29
2.5 ファイルの内容確認とデータ抽出	30
2.5.1 <code>cat</code>	31
2.5.2 <code>less</code>	31
2.5.3 <code>head</code>	31
2.5.4 <code>tail</code>	32
2.5.5 <code>wc</code>	32
2.5.6 <code>grep</code>	32
2.5.7 <code>awk</code>	33

2.5.8	パイプ	34
2.6	URL からファイルを取得する	34
2.6.1	curl	34
2.6.2	wget	35
2.7	環境変数と PATH	35
2.7.1	環境変数を使う	35
2.7.2	展開と引用	36
2.7.3	PATH と実行ファイル	37
2.8	リダイレクトとログ保存	38
2.8.1	echo、標準出力、標準エラー	38
2.8.2	> と >>	38
2.8.3	1> と 2>	39
2.8.4	tee で見ながら保存する	39
2.9	権限とスクリプトの実行	40
2.9.1	権限を読む	40
2.9.2	スクリプトを直接実行する	41
第 3 章	Python 環境を整える	43
3.1	Python の確認と管理方針	43
3.1.1	何を分けて考えるべきか	43
3.1.2	今の Python を確認する	43
3.2	pyenv による複数バージョンの管理	44
3.2.1	macOS での準備	44
3.2.2	WSL / Ubuntu での準備	44
3.2.3	pyenv を入れてシェルへ組み込む	45
3.2.4	バージョンを入れて切り替える	46
3.3	venv でプロジェクトごとの仮想環境を作る	47
3.3.1	pip と python -m pip	48
3.4	解析用ライブラリと JupyterLab	48
3.4.1	JupyterLab を併用する	48
3.5	プロジェクト管理ツール uv の利用	49
3.5.1	プロジェクトの初期化	49
3.5.2	依存関係の追加と環境の同期	50
3.5.3	コマンドの実行とバージョン固定	51
3.5.4	標準ライブラリと外部ライブラリ	52
3.5.5	解析用のライブラリを入れる	52
3.6	引数・設定ファイルとコードの分離	53
3.6.1	コマンドライン引数と設定ファイルを使い分ける	53

3.6.2	設定ファイルとマジックナンバーの排除	54
第 4 章	Python の基本	55
4.1	データ型と基本操作	55
4.1.1	変数と基本型	55
4.1.2	数値と演算子	55
4.1.3	文字列	56
4.2	データ構造	56
4.2.1	リスト、タプル、辞書	56
4.2.2	リストのメソッド	57
4.2.3	インデックスとスライス	57
4.3	制御構文	57
4.3.1	条件分岐	57
4.3.2	反復処理	58
4.4	関数とモジュール	59
4.4.1	関数を分ける理由	59
4.5	保守と実践的な書き方	62
4.5.1	エラーは失敗ではなく情報である	62
第 5 章	入出力とファイル	65
5.1	テキストファイルの入出力と探索	65
5.1.1	ファイルを開き、読み書きの基本を押さえる	65
5.2	文字列データの解析と整形	66
5.2.1	文字列を値へ変換し、結果を書き出す	66
5.3	オブジェクトと構造化データの保存	68
5.3.1	JSON と Pickle / PKL	68
5.4	発展的なトピック	69
5.4.1	日付と時刻を数値として扱う	69
5.4.2	保存形式について: ベストプラクティスへのステップ	69
第 6 章	NumPy による数値計算	71
6.1	NumPy の考え方	71
6.1.1	配列計算の基本概念	71
6.1.2	ndarray と属性	71
6.1.3	Python, C, NumPy でのデータ型の違い	72
6.1.4	NumPy が速くなりやすい理由	73
6.2	最小限のコード例	73
6.2.1	配列を作る	73
6.2.2	よく使う操作	74
6.2.3	要素ごとの演算とユニバーサル関数	75

6.2.4	集計と <code>axis</code>	76
6.2.5	添字、スライス、条件抽出	76
6.2.6	形を変える	77
6.2.7	配列をつなぐ、分ける	78
6.2.8	形とブロードキャスト	78
6.2.9	統計量とヒストグラム	79
6.3	よくある落とし穴	80
6.3.1	演算子の意味を取り違える	80
6.3.2	<code>axis</code> と条件式	80
6.3.3	<code>dtype</code> と <code>np.empty</code>	81
6.3.4	コピーとビュー	81
6.3.5	浮動小数点数の比較	82
6.4	解析へのつながり	82
6.4.1	解析で NumPy を使うときの視点	82
6.4.2	差分、ソート、ヒストグラム	82
6.4.3	線形代数の入口	83
6.4.4	公式資料の使い方	84
第 7 章	pandas による表形式データ解析	85
7.1	pandas の考え方	85
7.1.1	Series と DataFrame	85
7.1.2	最初に見るべき情報	86
7.1.3	index と列名の役割	86
7.1.4	pandas が速くなりやすい理由	87
7.2	最小限のコード例	87
7.2.1	列選択と行抽出	87
7.2.2	列を追加する	88
7.2.3	欠損値と型	88
7.2.4	要約統計と <code>groupby</code>	89
7.2.5	表の形を変える	90
7.2.6	時刻、文字列、カテゴリ	91
7.2.7	入出力	91
7.2.8	表を LaTeX へ出力する	93
7.2.9	<code>plot()</code> は確認用として使う	93
7.3	よくある落とし穴	93
7.3.1	<code>SettingWithCopy</code> と <code>loc</code>	93
7.3.2	object 型のまま計算しない	94
7.3.3	行ループは最後の手段である	94

7.3.4	欠損値と比較演算を混同しない	96
7.4	解析へのつながり	96
第 8 章	Polars による高速な表処理	97
8.1	Polars の考え方	97
8.1.1	index を持たない DataFrame	97
8.1.2	式で列変換を書く	98
8.1.3	eager と lazy	98
8.2	最小限のコード例	98
8.2.1	select() と filter()	98
8.2.2	with_columns() で列を増やす	99
8.2.3	group_by() と集計	99
8.2.4	join と表の変形	100
8.2.5	欠損値、null、NaN	101
8.2.6	文字列と条件分岐	101
8.2.7	lazy API と scan_parquet()	101
8.2.8	CSV と Parquet の入出力	102
8.3	よくある落とし穴	102
8.3.1	pandas の書き方をそのまま持ち込まない	102
8.3.2	map_elements() や Python の lambda を多用しない	102
8.3.3	lazy API では collect() を忘れない	102
8.3.4	欠損値は null と NaN を区別する	103
8.4	解析へのつながり	103
第 9 章	Matplotlib による可視化	105
9.1	基本的な作図と可視化	105
9.1.1	最小限のヒストグラム	105
9.1.2	軸ラベル、凡例、目盛り	105
9.1.3	plot 関数へ渡すデータ	106
9.2	実践的な作図（データに応じた図の選択）	107
9.2.1	相関の可視化：論理的改善ステップ	107
9.2.2	複数の図を並べる (subplots)	109
9.2.3	凡例とレイアウト	110
9.2.4	エラーバーと対数軸 (log-log プロット)	111
9.2.5	結果例の読み方	112
9.2.6	画像フォーマットの選択：ラスタとベクタ	112
9.3	オブジェクト指向 API による複雑な図の管理	113
9.3.1	Figure, Axes, Axis, Artist の役割	113
9.3.2	オブジェクト指向 API で描く	117

9.3.3	補助関数で作図をまとめる	117
9.4	見た目とスタイルの管理	118
9.4.1	rcParams で見た目をそろえる	118
9.4.2	設定ファイル (.mplstyle) で見た目を共通化する	119
9.4.3	共通スタイルの一部だけを上書きする	120
9.5	比較しやすい図を作る	120
9.5.1	Matplotlib の数式表記を使う	120
9.6	よくある落とし穴	121
9.6.1	plt と ax を混ぜて迷子になる	121
9.6.2	文字列がカテゴリ軸になる	121
9.6.3	savefig と余白調整の順序	121
9.6.4	公式資料から似た図を探す	122
第 10 章	SciPy による数値計算とフィット	123
10.1	SciPy の考え方	123
10.1.1	NumPy の上にある専門工具箱	123
10.1.2	関数形を仮定して数値を取り出す	123
10.1.3	この本でよく使う分布	124
10.2	最小限のコード例	124
10.2.1	scipy.stats による要約統計と分布	124
10.2.2	curve_fit によるパラメータ推定	125
10.3	フィットを進める手順	126
10.3.1	初期値、制約、残差	127
10.3.2	sigma を使った重み付きフィット	128
10.3.3	scipy.interpolate による補間	129
10.3.4	scipy.signal による平滑化とピーク検出	130
10.3.5	scipy.integrate と scipy.constants	130
10.4	よくある落とし穴	131
10.4.1	モデル選択の理由がないままフィットしない	131
10.4.2	初期値と制約を無視しない	131
10.4.3	補間と外挿を混同しない	131
10.4.4	信号処理ではサンプリング間隔を意識する	131
10.5	解析へのつながり	131
第 11 章	Astropy による時刻・単位・天体データ処理	133
11.1	Astropy の考え方	133
11.1.1	数値だけでなく意味も持たせる	133
11.1.2	時刻系と座標系を自前で持たない	134
11.2	最小限のコード例	134

11.2.1	units と Quantity	134
11.2.2	物理定数	134
11.2.3	Time による時刻表現	135
11.2.4	時刻差と TimeDelta	135
11.2.5	SkyCoord による座標変換	136
11.2.6	Table と QTable	136
11.2.7	Astropy Table と pandas の行き来	137
11.2.8	astropy.io.fits による FITS の読み書き	137
11.2.9	ASCII や ECSV も読める	138
11.3	よくある落とし穴	138
11.3.1	.value を早く使い過ぎない	138
11.3.2	時刻系を省略しない	138
11.3.3	座標変換には観測条件が必要なことがある	138
11.3.4	DataFrame への変換で情報が落ちる	139
11.4	解析へのつながり	139
第 12 章	自作モジュールを作って再利用する	141
12.1	なぜ自作モジュールにするのか	141
12.2	uv でパッケージ開発を始める	141
12.2.1	最初の初期化	141
12.2.2	pyproject.toml の役割	142
12.3	具体例: ヒストグラムとフィットをまとめたパッケージ	143
12.3.1	モデル関数を分ける	143
12.3.2	pytest で最小のテストを書く	145
12.3.3	ヒストグラムを作って保存する関数	146
12.3.4	公開インタフェースを __init__.py で整える	148
12.3.5	使い方の例	149
12.4	docstring、型ヒント、README	150
12.4.1	docstring と型ヒント	150
12.4.2	README に書くべきこと	150
12.5	pip install . と pip install -e .	151
12.5.1	通常インストール	151
12.5.2	editable install	151
12.5.3	インストール確認	152
12.6	Git リポジトリへ置いて共有する	152
12.7	依存関係をどう書くか	153
第 13 章	Python 解析の高速化	155
13.1	まず測る	155

13.1.1	Jupyter では %timeit も使える	155
13.2	計算量の見積もり	155
13.2.1	オーダーとは何か	156
13.2.2	オーダーが改善する例: 重複判定	157
13.2.3	オーダーは同じで定数倍だけ改善する例	158
13.3	実装を軽くする	159
13.3.1	NumPy と pandas による高速化	159
13.3.2	メモリとコピーの管理	159
13.3.3	分割読み込み、並列化、ストリーミング	159
13.4	プロファイリングと低レベル実装	160
13.4.1	プロファイラを使う	160
13.4.2	C や C++ へ書き換えるという選択肢	160
13.4.3	Python から C/C++ を呼び出す	161
13.4.4	外部実装を参考にするときの見方	162
13.5	結果例と報告の仕方	162
第 14 章	課題: 同時観測イベントの探索	165
14.1	課題の準備	165
14.1.1	まず配布コードを動かす	165
14.1.2	gzip ファイルの中身を見る	165
14.1.3	小さいデータで確認する	166
14.2	課題で求めること	166
14.2.1	出力としてほしいもの	167
14.2.2	正しさ確認の目安	167
14.3	提出物と発展課題	168
14.3.1	発展課題	168
付録 A	SSH, 鍵認証, ファイル転送	169
A.1	SSH の基本	169
A.1.1	サーバーへ接続する	169
A.1.2	SSH 鍵を作る	169
A.1.3	公開鍵をサーバーへ登録する	170
A.1.4	ssh-agent を使う	170
A.2	接続設定と GitHub 連携	170
A.2.1	~/.ssh/config を書く	170
A.2.2	GitHub に SSH 鍵を登録する	171
A.3	ファイル転送	171
A.3.1	scp の最小例	171
A.3.2	rsync を推奨する理由	171

付録 B	Git と GitHub の基本	173
B.1	Git の基本概念	173
B.1.1	リポジトリと公開範囲	173
B.1.2	Git で何をしているのか	173
B.2	ローカルで履歴を作る	174
B.2.1	最初の設定	174
B.2.2	新しいリポジトリを作る	174
B.2.3	編集、確認、記録の流れ	174
B.2.4	.gitignore を使って除外する	175
B.3	GitHub と接続する	176
B.3.1	既存のリポジトリを持ってくる	176
B.3.2	手元のリポジトリを GitHub へ初めて載せる	176
B.3.3	GitHub と同期する	178
B.3.4	GitHub で使う URL には HTTPS と SSH がある	178
B.4	認証と最小ワークフロー	178
B.4.1	GitHub の認証: SSH 鍵を基本にし、必要なら PAT	178
B.4.2	初心者が押さえるべき最小ワークフロー	179
付録 C	pybind11 による C++ 拡張モジュール	181
C.1	どのようなときに使うか	181
C.2	最小構成	181
C.2.1	pyproject.toml	181
C.2.2	CMakeLists.txt	182
C.2.3	C++ の実装	182
C.2.4	Python 側の入口	183
C.3	ビルドとインストール	183
C.4	Python 側からの使い方	184
C.5	どこまで C++ へ出すべきか	184
付録 D	正規表現の基本	185
D.1	正規表現とは何か	185
D.1.1	文字どおりの一致とメタ文字	185
D.1.2	ワイルドカードとの違い	185
D.2	よく使う部品	186
D.2.1	アンカー (行頭と行末)	186
D.2.2	文字クラス [...] と代表的な省略記法	186
D.2.3	量指定子 *, +, ?	187
D.3	物理・データ解析での具体例	187
D.3.1	ログから必要な行だけを探す	187

D.3.2	検出器 ID やセンサー名を選別する	187
D.3.3	Python で抽出と変換を同時に行う	188
D.4	Python の re と grep/awk の使い分け	188
D.4.1	Python では raw string を使う	188
D.4.2	search, match, fullmatch を使い分ける	188
D.4.3	コマンドラインで十分な場面と、Python に移すべき場面	189
付録 E	シェルスクリプトによる自動化と一括処理	191
E.1	シェルスクリプトの基礎構造	191
E.1.1	シバンと実行権限	191
E.1.2	コマンドライン引数	191
E.2	変数、演算、条件式	192
E.2.1	変数の定義とリスト (配列)	192
E.2.2	数値計算 (算術式展開)	192
E.2.3	条件式 (test コマンド)	193
E.3	条件分岐 (if, case)	193
E.3.1	if 文を用いた分岐	193
E.3.2	case 文による分岐	194
E.4	反復処理と一括自動化 (for)	195
E.4.1	配列やリストの要素に対する for ループ	195
E.4.2	実践: 複数ファイルのパス置換とバッチ処理	195
E.5	sed を用いたテンプレート書き換えと動的実行	196
E.5.1	テンプレートファイルの準備	196
E.5.2	sed による置換の実行	197
参考文献		199

はじめに

このテキストは、Python を使ってデータを読み、整形し、図を描き、分布を調べるための入門書である。単に文法を覚えるのではなく、結果の正しさを自分で確かめ、処理時間を測り、改善点を説明できるようになることを目標にする。

本書の構成は Python 公式チュートリアル [1] の流れを意識している。前半では、変数、リスト、関数、ファイル読み書きといった基礎を確認する。中盤では NumPy、pandas、Polars、Matplotlib、SciPy、Astropy を用いた実践的な解析へ進む。後半では、大規模データの高速化や低レベル言語との連携に触れ、最後に総合演習へ進む。

特に、Python 公式チュートリアル [1] の「An Informal Introduction to Python」「More Control Flow Tools」「Data Structures」「Modules」「Input and Output」「Errors and Exceptions」「Brief Tour of the Standard Library」で扱われている基礎事項を、データ解析の文脈でつなぎ直すことを意識している。公式チュートリアルを置き換えるというより、その内容を土台にして、解析実装で本当に困る点まで掘り下げることを目指す。

コマンド例は、macOS 上のターミナルで作業する状況を自然な基準として書いている。Terminal.app でも iTerm2 でも構わない。Windows ユーザーは PowerShell を用いてもよいが、Windows Subsystem for Linux (WSL) の使用を強く推奨する。

第 1 章 このテキストの使い方

1.1 誰のためのテキストか

このテキストは、次のような読者を想定している。

- Python をこれから学びたい人
- 多少は書けるが、解析コードをどう整理すればよいか分からない人
- 小さなデータでは動くが、大きなデータになると急に遅くなる理由を知りたい人
- 結果の図をそれらしく描くことはできても、正しさの確認やフィットの説明に自信がない人

逆に、すでに Python で大規模解析を日常的に行っており、NumPy や pandas の内部挙動にも慣れている読者にとっては、前半の内容は基礎的に見えるだろう。その場合は、後半の高速化や総合演習から読んでも構わない。

本書は、単に「使い方を覚える」ためだけの資料ではない。研究や課題で自力の解析を組み立てるとき、何を順に確かめればよいか、どの段階で道具を変えるべきかまで含めて学ぶことを目指している。したがって、短いサンプルコードであっても、なぜその書き方になっているのかを説明する。

1.2 何を順に学ぶのか

本書では、大きく分けて三段階で学ぶ。

第一段階では、Python の基本的な書き方と、ファイルを読むための最低限の技術を扱う。ここでは、短いスクリプトを自分で動かし、何が入力で何が出力なのかをはっきり意識する。

第二段階では、NumPy、pandas、Polars、Matplotlib、SciPy、Astropy を使い、実際の解析に必要な表現力を身につける。配列、表形式データ、ヒストグラム、フィット、時刻と単位の違いが、この段階の中心になる。

第三段階では、高速化と設計を学ぶ。遅い実装と速い実装を比べ、どこで時間を使っているのかを測り、アルゴリズムの違いが速度にどう響くのかを考える。この延長として、Python だけでなく C や C++ へ処理を移す発想も扱う。

この順序には理由がある。NumPy や pandas を早く使いたくなるのは自然だが、入力と出力、型、反復、条件分岐が曖昧なままでは、便利なライブラリを使っても何が起きているか分からなくなる。基礎を先に固めるのは遠回りではなく、後半を理解する最短経路である。

1.3 本書で大切にしたい姿勢

本書で繰り返し強調するのは、次の三点である。

- 結果をそのまま信じず、自分で確かめること
- 遅いと感じたら、どこが遅いかを測ること
- コードが動く理由と、速くなる理由を言葉で説明すること

特にデータ解析では、コードが実行できたことと、結果が正しいことは同じではない。さらに、正しいコードであっても、データ量が増えた途端に実用にならなくなることがある。本書では、その両方を区別して考える。

もう一つ大切なのは、結果を言葉に直すことである。たとえば「NumPy を使ったら速くなった」と書くだけでは不十分で、どの操作を Python ループから配列演算へ移したのか、どの程度速くなったのか、メモリ使用量はどう変わったのか、といった説明が必要になる。レポートや口頭説明では、この差がそのまま理解の差として現れる。

1.4 章の読み進め方

各章には、できるだけ次の順序で内容を置く。

1. その章で扱う考え方の意味
2. 最小限のコード例
3. よくある落とし穴
4. 解析へのつながり

最初は、コードを丸ごと理解しようとしなくてよい。まずは「何を入力し、何を出しているか」を追う。その後で「なぜこの書き方を選んだか」を読むと、理解しやすい。

特に初学者は、1 行ずつ読んで意味を取ろうとして全体像を見失いがちである。まずは関数名、引数、返り値、ファイル名、出力先だけを追い、流れをつかんでから細部へ戻る方が理解しやすい。本書のコード例も、その読み方を意識して配置している。

1.5 参考資料

本書は独立して読めるように書いているが、コマンドの細かいオプションやライブラリの仕様はバージョンによって変わることがある。そのため、必要に応じて公式資料も併用した方がよい。本文で公式資料に触れた箇所には参考文献番号を付けてあり、巻末の参考文献にはその番号ごとに題名と URL をまとめている。

特に参照頻度が高い資料は、次の通りである。

- Python の基礎: [1, 2]
- JupyterLab と環境構築: [3–5]
- NumPy, pandas, Polars: [7, 9, 10, 16, 18, 20]
- Matplotlib: [22–25]
- SciPy, Astropy: [27, 34, 35]
- Git, GitHub: [41, 42]

上の一覧は主に Web 上の公式資料だが、シェルコマンドについては手元の環境に入っているマニュアルも重要である。特に `ssh`、`rsync`、`ls`、`chmod` などは環境ごとに細かな違いが出ることがあるので、細部を確かめたいときは `man ssh`、`man rsync`、`man ls`、`man chmod` のように、その場で使える説明を直接確認した方がよい。

1.6 この本の後半で扱う実践的な内容

本書の後半では、単なる文法紹介ではなく、実際のデータを扱うときに何が問題になるかを扱う。そこでは、正しさの確認、バグの切り分け、図の作成、フィット、速度改善といった要素が一つの流れとして現れる。

最後の章には具体的な総合演習を置くが、それは本書で扱った一般的な考え方をまとめて使うための実践例という位置付けである。したがって、前半の章では特定の演習に閉じず、より広いデータ解析へそのまま応用できる書き方と考え方を重視する。

言い換えると、後半へ行くほど「何を書くか」よりも「どう考えるか」が主題になる。ライブラリの関数名は将来変わることがあるが、入力を確認する、分布を見る、速度を測る、遅い理由を切り分ける、といった考え方は長く残る。

第 2 章 シェルとファイル操作

2.1 シェルの基本と環境

本書では、ファイル操作やスクリプト実行をターミナルから行う。まず言葉を分けておく。

- ターミナル: 文字で命令を入力するためのアプリケーション
- シェル: ターミナルの中で動き、入力されたコマンドを解釈して実行するプログラム

macOS では `zsh`、Linux や WSL では `bash` を使うことが多い。`zsh` と `bash` はどちらもシェルであり、本書の基本コマンドはほぼ同じように使える。自分がどのシェルを使っているかを調べるには、次のように実行する。

```
$ echo $SHELL
```

実行結果の例は次のようになる。

```
/bin/zsh
```

この 1 行は、「いまログイン中のシェルとして `zsh` が使われている」ことを表す。末尾の `zsh` や `bash` が、実際にコマンドを解釈しているプログラム名である。以後、設定ファイルを編集するときは、この結果を見て `~/.zshrc` と `~/.bashrc` のどちらを触るかを決める。

本書では、シェルで入力するコマンド例の先頭に `$` を付ける。`$` 自体は「ここから先が入力するコマンドである」という印であり、読者が実際に打ち込むのはその後ろの部分である。これに対して、出力結果やファイル内容の例には `$` を付けない。

2.1.1 Windows では WSL を使う

本書のコマンド例は macOS や Linux のシェルを前提にしている。そのため、Windows で読み進める場合は、コマンドプロンプトや PowerShell をそのまま使うより、WSL (Windows Subsystem for Linux) を入れて Ubuntu などの Linux 環境を使う方が混乱しにくい。導入の際は次のように実行する。

```
$ wsl --install
```

WSL を使う利点は、単にコマンド名がそろふことだけではない。後半で扱う並列処理や周辺ツールの中には、Linux 系環境での利用を前提としているものがある。OS ごとの差でつまずくより、最初から UNIX 系の作法へ寄せた方が、解析そのものに集中しやすい。

2.2 コマンドの基本と使い方

2.2.1 コマンド、オプション、引数

シェルで打つ 1 行は、多くの場合「コマンド本体」「オプション」「引数」から成る。たとえば次のような形である。

```
$ ls -l results
$ cp data/raw.txt backup/raw.txt
```

1 行目では、`ls` がコマンド本体、`-l` がオプション、`results` が引数である。2 行目では、`cp` がコマンド本体で、`data/raw.txt` と `backup/raw.txt` が引数である。一般に、オプションは動作を変え、引数は対象のファイル名やディレクトリ名を与える。

オプションには短い書き方（`-` の後に 1 文字）と、長い書き方（`--` の後に英単語）が用意されていることが多い。たとえば、使い方を表示するオプションとしては `-h` と `--help` の両方がサポートされていることが多い。

2.2.2 困ったときは説明を読む

コマンドの使い方を丸暗記する必要はない。忘れたときは、その場で説明を読む方が正確である。短い使い方を知りたいときは `-h` や `--help`、より詳しい説明を読みたいときは `man` を使う。実際の調べ方は次のようになる。

```
$ python3 -h
$ python3 --help
$ man rsync
```

`python3 -h` の出力は長いですが、先頭はたとえば次のようになる。

```
usage: python3 [option] ... [-c cmd | -m mod | file | -] [arg] ...
Options and arguments (and corresponding environment variables):
-b      : issue warnings about str(bytes_instance), str(bytearray_instance)
         and comparing bytes/bytearray with str. (-bb: issue errors)
-B      : don't write .pyc files on import; also PYTHONDONTWRITEBYTECODE=x
-c cmd  : program passed in as string (terminates option list)
```

ここで最初の `usage: ...` は「このコマンドをどういう形で呼び出せるか」を要約した行である。`[-c cmd | -m mod | file | -]` のように角括弧で囲まれた部分は省略可能、`|` で区切られた部分はどれか 1 つを選ぶ、という意味で読む。その次の `Options and arguments ...` 以下では、各オプションの意味が 1 行ずつ並ぶ。`-b` のように短いオプション名、コロンの後ろにその効果、必要なら対応する環境変数が示される。`-c cmd` のように引数を伴うものは、オプションの直後に必要な値の名前も書かれる。

`man rsync` を開くと、画面の先頭付近はたとえば次のようになる。

OPENRSYNC(1)

NAME

opensync - synchronise local and remote files

SYNOPSIS

```
opensync [-0468BCDEFHILOPRSTWVabcdefghijklmnopqrstuvwxyz] [-e program] [-f filter] ...
... source ... directory
```

NAME はそのコマンドが何をするものかを 1 行で示す欄である。SYNOPSIS は、「このコマンドをどういう形で呼び出せるか」を要約した欄である。ここで角括弧 [...] に入っているものは省略可能であり、すべてを書かなければならないわけではない。この例では、末尾の source ... directory を見れば、コピー元を並べて最後にコピー先を書くことが分かる。全オプションを暗記する必要はない。--exclude や -a のように、必要なものだけを後ろの節や man から確認して使えば十分である。

--help や -h は、そのコマンドが受け付けるオプションや引数の書式を短く表示することが多い。ただし、すべてのコマンドが両方を実装しているわけではない。macOS の ls のように --help を受け付けないコマンドもあるので、その場合は man ls、man ssh、man rsync のように man を引く方が確実である。man を開いたあとは、上下キーや Space で移動し、/pattern で検索できる。q を押せば終了する。

検索エンジンや AI を用いてコマンドの使い方を調べることもできるが、同じ名前のコマンドでもバージョンや OS によって使い方が異なることもあるため注意が必要である。検索しても問題が解決しない場合は --help や man を確認し、手元の環境にあった正しい情報を確認しよう。

2.3 ファイルとディレクトリの操作

2.3.1 今どこにいるかを確認する: ls

シェルでは、いま作業しているディレクトリが基準になる。この基準となるディレクトリをカレントディレクトリという。まずは、現在どこで作業しているのか、そしてその場所に何があるのかを確認できるようになろう。そのためによく使うのが、次の pwd と ls である。

```
$ pwd
$ ls
$ ls -l
$ ls -lh
$ ls -a
$ ls -lah
```

pwd は、現在のカレントディレクトリの絶対パスを表示する。ls は、そのディレクトリにあるファイルやディレクトリの一覧を表示する。たとえば pwd の結果が次のようであれば、

```
/Users/ikomae/analysis
```

現在の作業場所は `/Users/ikomae/analysis` である。この状態で `ls` を実行すると、その中にある項目が表示される。

```
$ ls
data  scripts
```

この結果から、`/Users/ikomae/analysis` の中には `data` と `scripts` という2つのディレクトリがあることが分かる。

`ls` にはさまざまなオプションがあり、表示内容を切り替えられる。まず、`-l` オプションを付けると、一覧を詳細表示にできる。

```
$ ls -l
total 0
drwxr-xr-x  3 ikomae  staff  96  4月 12 23:19 data
drwxr-xr-x  3 ikomae  staff  96  4月 12 23:19 scripts
```

`ls -l` の最初の行に表示される `total 0` は、この一覧に表示されている項目が使用しているブロック数の合計を表している。`total` の単位は環境によって見え方が分かりにくいので、ここでは「一覧に表示されている項目全体についての使用量をまとめて示したもの」と理解しておけばよい。

`ls -l` の出力では、その下の各行が1つのファイルまたはディレクトリに対応しており、左から順に次の情報が表示される。

- `drwxr-xr-x`：ファイル種別とアクセス権
- `3`：リンク数
- `ikomae`：所有者
- `staff`：グループ
- `96`：サイズ
- `4月 12 23:19`：最終更新日時
- `data`：名前

先頭の1文字は種別を表し、`d` ならディレクトリ、`-` なら通常のファイルである。続く `rwxr-xr-x` はアクセス権を表している。アクセス権の詳しい意味は [2.9.1 節](#) で説明する。

リンク数は、ファイルやディレクトリに対して、ファイルシステムの中でいくつ参照があるかを表す値である。通常のファイルでは、ふつうに作成したものであれば多くの場合は1であり、入門の段階ではあまり深く気にしなくてよい。ディレクトリでは意味が少し異なる。ディレクトリ構造により値が変化するが、その定義は環境によって異なるため、通常のファイルのように単純には読めない。したがって、リンク数については、通常のファイルでは多くの場合1であり、ディレクトリでは構造に関係する値が表示される、と理解しておけば十分である。

`ls -l` で表示されるサイズの欄は、通常はバイト単位で表示される。したがって、ファイルが大きくなると数値も大きくなり、ぱっと見ただけでは大きさをつかみにくいことがある。そこで、サイズを見やすく表示したいときには `-h` オプションを併用する。`h` は `human-readable` の略で、サイズを `K`、`M`、`G` などの読みやすい単位で表示する。

```
$ ls -lh
total 0
drwxr-xr-x 3 ikomae staff 96B 4月 12 23:19 data
drwxr-xr-x 3 ikomae staff 96B 4月 12 23:19 scripts
```

この例ではサイズが `96B` と表示されているが、これはディレクトリ項目そのものの大きさであって、その中に入っているファイル全体の容量を表しているわけではない。ディレクトリのサイズ欄は、通常のファイルのサイズ欄とは同じ感覚では読めない点に注意が必要である。

通常のファイルに対して `ls -lh` を使うと、サイズは `12K` や `3.4M` のように読みやすい単位で表示される。そのため、特にファイルの大きさを確認したいときには `ls -lh` を使うことが多い。

一方、`-a` オプションを付けると、隠しファイルも含めて表示できる。

```
$ ls -a
.      ..      .config data  scripts
```

ファイル名やディレクトリ名が `.`（ドット）で始まるものは隠しファイルとして扱われ、通常の `ls` では表示されない。たとえば `.config`、`.gitignore`、`.bashrc` などがこれにあたる。設定ファイルのように、ふだんは一覧に見えなくてよいものを隠しファイルにしておくことが多い。

上の `ls -a` に現れる `.` と `..` にも意味がある。`.` は現在のディレクトリ自身を表し、`..` は 1 つ上の親ディレクトリを表す。これらは後でディレクトリ移動をするときにも重要になる。

詳細表示、隠しファイル表示、読みやすいサイズ表示をまとめて使うこともできる。たとえば `-lah` を指定すると、詳細情報を隠しファイル込みで、人が読みやすい単位で表示できる。

```
$ ls -lah
total 96
drwxr-xr-x 5 ikomae staff 160B 4月 12 23:20 .
drwxr-xr-x 5 ikomae staff 160B 4月 12 23:18 ..
-rw-r--r-- 1 ikomae staff 47K 4月 12 23:22 .config
drwxr-xr-x 3 ikomae staff 96B 4月 12 23:19 data
drwxr-xr-x 3 ikomae staff 96B 4月 12 23:19 scripts
```

この例では `.config` という通常のファイルも表示されており、`ls -l` のときとは `total` の値が異なっている。`total` は各行の「サイズ」欄を単純に足したものではなく、表示対象が使用しているブロック数に基づいて表示される点に注意したい。

このように、`ls` はオプションを組み合わせて、必要な情報を見やすく確認できる。まずは、現在位置を確認する `pwd`、項目を一覧する `ls`、詳細を見る `ls -l`、隠しファイルも含

めて確認する `ls -a`、サイズを読みやすく表示する `ls -lh` や `ls -lah` を使い分けられるようになるとうい。

2.3.2 移動する: `cd`

`cd` はカレントディレクトリを変更するためのコマンドである。`ls` や `cat`、`cp` など多くのコマンドは「いまいる場所」を基準に動くため、`cd` を正しく読めるようになると、その後のファイル操作も理解しやすくなる。次のようなディレクトリ構成を例に考える。

```
analysis/  
|-- data/  
|   |-- events.txt  
|-- scripts/  
    |-- plot.py
```

いま `/Users/ikomae/analysis` にいるとする。まず `pwd` と `ls` を実行すると、現在位置とその場にある項目は次のように分かる。

```
$ pwd  
/Users/ikomae/analysis  
$ ls  
data  scripts
```

この状態で `cd data` を実行すると、`analysis` の下にある `data` ディレクトリへ移動する。

```
$ cd data  
$ pwd  
/Users/ikomae/analysis/data  
$ ls  
events.txt
```

`data` は相対パスなので、「いまいる `analysis` から見て `data` に入る」という意味になる。次に `cd ..` を実行すると、1 つ上の親ディレクトリへ戻る。

```
$ cd ..  
$ pwd  
/Users/ikomae/analysis
```

ここで使っている `..` は、`ls -a` でも見た「親ディレクトリ」を表す特別な名前である。絶対パスを使って直接移動することもできる。たとえば `~` はホームディレクトリを表すので、次のように書けば現在位置に関係なく `scripts` へ移動できる。

```
$ cd ~/analysis/scripts  
$ pwd  
/Users/ikomae/analysis/scripts  
$ ls  
plot.py
```

また、`cd -` は 1 つ前にいた場所へ戻る。たとえば上の状態で実行すると、直前にいた `/Users/ikomae/analysis` へ戻る。

```
$ cd -  
/Users/ikomae/analysis
```

さらに、引数なしの `cd` はホームディレクトリへ戻る。深い階層まで移動したあとで基準位置に戻りたいときに便利である。

```
$ cd  
$ pwd  
/Users/ikomae
```

このように、`cd` では「相対パスでたどる」「絶対パスで直接飛ぶ」「`..` や `-` で戻る」という使い分けが重要になる。慣れないうちは、移動した直後に `pwd` や `ls` を実行して、本当に意図した場所へ来ているかを確認めるとよい。

2.3.3 絶対パスと相対パス

ファイルやディレクトリの場所は、パスで表す。パスは階層を `/` でつないだ表記であり、最初の書き方によって意味が変わる。大きく分けると絶対パスと相対パスがある。

表 2.1 よく出てくるパス表記

表記	意味
<code>/abs/data.txt</code>	絶対パス。 <code>/</code> から始まり、どこにいても同じ場所を指す
<code>~/analysis</code>	絶対パス。 <code>~</code> はホームディレクトリ
<code>data.txt</code>	相対パス。今いるディレクトリを基準に解釈される
<code>./x.txt</code>	相対パス。 <code>.</code> は現在のディレクトリ
<code>../x.txt</code>	相対パス。 <code>..</code> は 1 つ上のディレクトリ

表 2.1 は、シェルを読み始めた直後に最低限区別したい表記をまとめたものである。特に重要なのは、絶対パスは `/` や `~` から始まり、相対パスは現在のカレントディレクトリを基準に読む、という違いである。

先ほどと同じく、次のディレクトリ構成を考える。

```
analysis/  
|-- data/  
|   |-- events.txt  
|-- scripts/  
    |-- plot.py
```

現在位置が `/Users/ikomae/analysis` なら、次の 2 つのコマンドは同じファイルを指している。

```
$ pwd  
/Users/ikomae/analysis  
$ cat data/events.txt  
$ cat /Users/ikomae/analysis/data/events.txt
```

1 つ目の data/events.txt は相対パスであり、「いまいる analysis の中にある data の中にある events.txt」という意味である。2 つ目の /Users/ikomae/analysis/data/events.txt は絶対パスなので、どこにいても同じ events.txt を指す。

一方で、現在位置が /Users/ikomae/analysis/scripts に変わると、同じ相対パスでも意味が変わる。

```
$ pwd
/Users/ikomae/analysis/scripts
$ cat data/events.txt
cat: data/events.txt: No such file or directory
$ cat ../data/events.txt
```

この場所で data/events.txt と書くと scripts/data/events.txt を探しに行くことになるが、そのようなファイルは存在しないので data/events.txt: No such file or directory というエラー文が表示される。相対パスで events.txt を指定するには、1 つ上へ戻る .. を使って ../data/events.txt と書く必要がある。

同様に、./plot.py は「現在のディレクトリにある plot.py」、../data は「1 つ上にある data ディレクトリ」を表す。相対パスは短く書ける反面、現在位置を読み違えると別の場所を指してしまう。したがって、コマンドを読むときは「今どこにいるか」と「そのパスが絶対か相対か」を必ずセットで考える必要がある。

2.3.4 ディレクトリを作る: mkdir

mkdir は新しいディレクトリを作るコマンドである。解析では、生データ、途中結果、図、ログなどを別々の場所へ整理したいので、作業の最初に出力先のディレクトリを作ることが多い。

たとえば、最初に次のような構成になっているとする。

```
analysis/
|-- data/
    |-- events.txt
```

output というディレクトリを 1 つ作るだけなら、次のように実行すればよい。

```
$ mkdir output
$ ls
data  output
```

1 行目では、現在のカレントディレクトリの直下に output が新しくできる。2 行目の ls で、それが確認できる。

一方、output/2026/04 のように深い階層をまとめて作りたい場面もある。途中の output/2026 がまだ無い場合、単純に mkdir output/2026/04 のように書くとエラーが表示される。-p オプションを付けると、足りない親ディレクトリも含めてまとめて作ることができる。

```
$ mkdir output/2026/04
```

```
mkdir: output/2026: No such file or directory
$ mkdir -p output/2026/04
```

実行後は、次のようなディレクトリ構成になる。

```
analysis/
|-- data/
|   |-- events.txt
|-- output/
|   |-- 2026/
|       |-- 04/
```

解析では、観測日ごとの出力先や、figures/summary/ のような途中ディレクトリを一度に作ることが多い。このような場面では `mkdir -p` を用いるのが便利である。

2.4 コピー、移動、削除

2.4.1 コピーする: `cp`

`cp` は元のファイルやディレクトリを残したまま複製を作るコマンドである。最後の引数が既存のディレクトリならその中へ同じ名前でコピーされ、ファイル名ならその名前で複製が作られる。まずは次のようなディレクトリ構造を考える。

```
work/
|-- backup/
|-- raw/
|   |-- events.txt
```

ここで `raw/events.txt` を `backup` へコピーするには、たとえば次のように実行できる。

```
$ cp raw/events.txt backup/
$ cp raw/events.txt backup/events_20260412.txt
```

1 行目では、`backup/` が既存のディレクトリなので、その中に同じ名前の `events.txt` が作られる。2 行目では、コピー先の名前まで明示しているので、同じ内容を `events_20260412.txt` という別名で保存できる。

```
work/
|-- backup/
|   |-- events.txt
|   |-- events_20260412.txt
|-- raw/
|   |-- events.txt
```

このように、`cp` は元ファイルを消さない。`raw/events.txt` はそのまま残り、コピー先だけが増える。バックアップを取るときや、元データを残したまま加工用のファイルを作るときによく使う。

ディレクトリごと複製したい場合は `-r` を付ける。

```
$ cp -r raw raw_backup
```

```
work/
|-- backup/
|   |-- events.txt
|   |-- events_20260412.txt
|-- raw/
|   |-- events.txt
|-- raw_backup/
|   |-- events.txt
```

-r は再帰的にコピーする、という意味である。ディレクトリの中にさらにファイルやサブディレクトリがあっても、その構造ごと複製される。なお、既存ファイルへの上書きが心配なときは -i を付けて確認しながらコピーすると安全である。

2.4.2 移動する、名前を変える: mv

mv は「別の場所へ移す」と「名前を変える」の両方に使う。考え方は cp と似ており、最後の引数が既存ディレクトリならその中へ移動し、そうでなければその名前へ変更する。ただし、cp と違って元の場所には残らない。

まず、同じディレクトリの中で名前だけを変える例を見る。

```
work/
|-- result.txt
```

```
$ mv result.txt result_old.txt
```

```
work/
|-- result_old.txt
```

この場合は、同じ場所にあるファイルの名前だけが result_old.txt へ変わる。

次に、別のディレクトリへ移動しながら名前も変える例を考える。

```
work/
|-- output/
|-- result_old.txt
```

```
$ mv result_old.txt output/final.txt
```

```
work/
|-- output/
|   |-- final.txt
```

mv result_old.txt output/final.txt では、result_old.txt が output の中へ移り、名前も final.txt に変わる。もし mv result_old.txt output/ と書けば、名前はそのまま場所だけが変わる。

このように、mv は「移動」と「改名」を 1 つのコマンドで行えるのが特徴である。整理のためにファイルを別ディレクトリへ移したり、解析段階に応じて tmp.txt を final.txt に改名したりするときに使う。mv -i を使うと、すでにファイルが存在した場合に上書きするかどうかを確認しながら進められる。

2.4.3 削除する: rm

rm はファイルやディレクトリを削除するコマンドである。重要なのは、通常の rm はゴミ箱へ移すのではなく、その場で削除するという点である。Finder での削除と違って、あとから気軽に戻すことはできない。したがって、慣れないうちは削除前に pwd や ls で場所と対象を確認する方がよい。

たとえば、次のような状態を考える。

```
work/
|-- old_output/
|   |-- plot.png
|-- result_old.txt
```

ここで使う基本形は次の通りである。

```
$ rm result_old.txt
$ rm -i result_old.txt
$ rm -r old_output
$ rm -ri old_output
```

rm result_old.txt は通常のファイルを削除する。rm -i result_old.txt は削除前に確認を出すので、うっかり消したくないときに有用である。rm -r old_output はディレクトリを中身ごと再帰的に削除する。rm -ri old_output のように -r と -i を組み合わせれば、ディレクトリ削除でも確認しながら進められる。

特に rm -r は強力である。対象のパスを誤ると大きな被害になるので、削除前に ls old_output や ls result_old.txt のように対象を一度表示してから実行すると安全である。

2.4.4 ワイルドカード

複数のファイルを一度に指定したいときは、ワイルドカードが役に立つ。よく使うのは * であり、これは「0 文字以上の任意の文字列」を表す。重要なのは、cat や rm が * を理解しているのではなく、シェルが先に実際のファイル名へ展開してから各コマンドへ渡しているという点である。

たとえば、次のような構成を考える。

```
data/
|-- run01.csv
|-- run02.csv
|-- run03.txt
|-- test_20260411.csv
|-- test_20260412.csv
```

```
|-- test_20260413.csv
|-- subdir/
   |-- run04.csv
```

このとき、次のような書き方ができる。

```
$ ls data/*.csv
$ cp data/*.csv backup/
$ rm test_*.csv
```

`data/*.csv` は、`data` ディレクトリ直下にある `.csv` ファイルすべてを意味する。したがって、この例では `run01.csv` と `run02.csv` は対象になるが、`subdir/run04.csv` は含まれない。`*` は `/` をまたいで階層全体を探すわけではないからである。

`cp data/*.csv backup/` とすると、条件に合う複数の CSV をまとめてコピーできる。`rm test_*.csv` なら、`test_001.csv` や `test_old.csv` のように同じ接頭辞を持つファイルを一括削除できる。

ただし、ワイルドカードは便利な反面、想定より多くのファイルへ一致することもある。特に削除系のコマンドでは、先に `ls test_*.csv` のように実際の対象を表示してから `rm test_*.csv` を実行する方が安全である。また、一致しないときの振る舞いはシェル設定によって異なることがあるので、その意味でもまず `ls` で確認する習慣が有用である。

2.5 ファイルの内容確認とデータ抽出

解析では、データを読む前にまず中身を確認する。そのための基本コマンドと、最低限覚えておきたいオプションを最初に表へまとめる。

表 2.2 中身確認と抽出でよく使うコマンドと主要オプション

コマンド	主なオプションや書式	主な用途
<code>cat</code>	<code>-n</code>	短いファイルをそのまま読む、複数ファイルを連結する
<code>less</code>	<code>-N</code> , <code>/pattern</code> , <code>q</code>	長いファイルをスクロールしながら読む
<code>head</code>	<code>-n N</code>	先頭の数行だけを見る
<code>tail</code>	<code>-n N</code> , <code>-f</code>	末尾の数行を見る、ログの追記を監視する
<code>wc</code>	<code>-l</code> , <code>-w</code> , <code>-c</code>	行数、単語数、バイト数を数える
<code>grep</code>	<code>-i</code> , <code>-v</code> , <code>-n</code> , <code>-A N</code> , <code>-B N</code>	条件に合う行だけを抽出する
<code>awk</code>	<code>-F</code> , <code>if (...)</code> , <code>sum += ...</code>	列単位で取り出す、簡単な整形や集計を行う

表 2.2 は、ファイルの確認と抽出で頻繁に使うコマンドを一覧するためのものである。最初は全てを暗記する必要はないが、「中身を見る」「条件で抜く」「列ごとに整形する」という

役割の違いは押さえない。ここからは、各コマンドの役割と主要なオプションを順に説明する。

2.5.1 cat

cat はファイルの中身をそのまま標準出力へ流す。短い設定ファイルや、数行だけの確認用テキストを一気に見たいときに向く。複数のファイルを並べて渡すと、内容を順に連結して表示できる。

```
$ cat data/events.txt
$ cat header.txt body.txt
$ cat log/*.log
$ cat -n config.txt
```

3 行目のように、前節のワイルドカードを使えば複数のログファイルをまとめて連結して表示できる。ただし、巨大なログや観測データへそのまま使うと画面が一気に流れて読めない。つまり、cat は「短い内容を一気に見る」道具だと考えるとよい。長いファイルは、次に述べる less や head、tail に切り替える。

-n 行番号を付けて表示する。設定ファイルやログの何行目に何があるかを確認したいときに便利である。

2.5.2 less

less は長いファイルをスクロールしながら読むためのコマンドである。大きなデータを「まず中身だけ見たい」とときには、最初に less を使うことが多い。

```
$ less data/events.txt
$ less -N data/events.txt
```

less は単なる表示コマンドではなく、表示中に検索や移動ができる。ログや観測データの形式を確認するときは、次の操作を覚えておくとよい。

-N 行番号を表示する。後で「どの行に何があったか」を参照しやすくなる。

Space 1 画面ぶん先へ進む。

b 1 画面ぶん戻る。

/pattern 指定した文字列を前方検索する。たとえば /ERROR と打てば、ERROR を含む次の行へ飛べる。

n 直前の検索条件の次の一致へ進む。

q 表示を終了してターミナルへ戻る。

2.5.3 head

head はファイルの先頭だけを見るためのコマンドである。どのような形式のデータが入っているか、ヘッダやコメント行はどのようになっているかを確認したいときに向く。

```
$ head data/events.txt
$ head -n 20 data/events.txt
```

-n N 先頭から N 行だけ表示する。既定では 10 行なので、少し長めに見たいときに使う。

2.5.4 tail

tail はファイルの末尾だけを見るためのコマンドである。ログファイルの最新部分を確認したいときや、計算結果が末尾へ追記される形式のファイルを見るときに使う。

```
$ tail log.txt
$ tail -n 30 log.txt
$ tail -f log.txt
```

-n N 末尾から N 行だけ表示する。直近 20 行や 30 行だけ見たいときに使う。

-f ファイルの末尾を監視し、追記された内容を続けて表示する。実行中のジョブのログを見るときに有用である。

2.5.5 wc

wc はファイルの行数、単語数、バイト数などを数えるコマンドである。特に **-l** は「何行あるか」を知るためによく使う。データ件数やログの大きさをざっと見積もるときの第一歩になる。

```
$ wc data/events.txt
$ wc -l data/events.txt
$ wc -w memo.txt
$ wc -c output.bin
```

-l 行数を数える。最もよく使う。

-w 単語数を数える。自然言語テキストの確認で使うことが多い。

-c バイト数を数える。ファイルサイズを概算したいときに役立つ。

2.5.6 grep

grep は、条件に合う行だけを抽出するためのコマンドである。ログからエラー行を探す、コメント行を除く、特定の測定条件を含む行だけ取り出す、といった用途で頻繁に使う。

```
$ grep "ERROR" log.txt
$ grep -n "ERROR" log.txt
$ grep -A 2 -B 1 "ERROR" log.txt
$ grep -i "warning" log.txt
$ grep -v "^#" data.txt
$ grep -rn "TODO" src/
```

- i 大文字と小文字を区別せずに検索する。error と ERROR を同じものとして扱いたいときに使う。
- v 一致した行ではなく、一致しなかった行を出す。コメント行やノイズ行を除外したいときに便利である。
- n 一致した行の行番号も表示する。後で元ファイルを見直すときに役立つ。
- A N 一致した行の後ろを N 行ぶん追加で表示する。エラー行の直後にある補足メッセージも一緒に見たいときに便利である。
- B N 一致した行の前を N 行ぶん追加で表示する。エラーの直前に何が起きていたかを見たいときに使う。
- r ディレクトリの中を再帰的に検索する。複数ファイルにまたがって同じ文字列を探したいときに使う。たとえば `grep -rn "TODO" src/` と書けば、src/ 以下のすべてのファイルをたどり、TODO を含む行を行番号付きで表示できる。日常的なログ確認では -A や -B の方を先に使うことが多いが、複数ファイル検索ではこちらも重要である。

grep では正規表現も使える。たとえば ^ は行頭、\$ は行末を表すので、`grep "^#" data.txt` と書けば「# で始まる行」だけを拾える。また、複数のログファイルをまとめて調べたいなら、`grep -r "ERROR" log/` のようにディレクトリごと渡せばよい。ここでは最低限の例だけを示したが、[] や . や * まで含めた正規表現の整理は付録 D にまとめているので、記号の意味が曖昧になったときはそちらを見返すとよい。

2.5.7 awk

awk は、テキストを列データとして扱って抽出や整形を行うコマンドである。空白区切りのログや表形式テキストを扱うときには非常に強力である。

```
$ awk '{print $1}' data.txt
$ awk '{print $1, $3}' data.txt
$ awk -F, '{print $2}' data.csv
$ awk '{ if ($3 > 10) print $1, $3 }' data.txt
$ awk '{ sum += $3 } END { print sum }' data.txt
```

既定では空白やタブが区切り文字として使われる。そのため、空白区切りの観測データなら \$1 が 1 列目、\$2 が 2 列目という意味になる。条件分岐は if を明示的に書くこともできるので、「3 列目が 10 より大きい行だけ表示する」といった処理の流れが読みやすい。また、各行で値を足し合わせて最後に合計や平均を出す、といった簡単な計算もそのまま書ける。

-F 区切り文字を指定する。CSV のようにカンマ区切りなら -F, のように書く。

{print \$1} 1 列目を表示する最も基本的な形である。{print \$1, \$3} のようにすれば複数列を並べて出せる。

{ if (\$3 > 10) print \$1, \$3 } 条件分岐を明示的に書く形である。最初のうちは、このように if を書いた方が処理の意味を追いやすい。

{ sum += \$3 } END { print sum } 各行で 3 列目を足し上げ、最後に合計を表示する。簡単

な集計や平均計算の出発点として便利である。

2.5.8 パイプ |

さらに、強力な手段としてパイプ (|) がある。パイプは、あるコマンドの標準出力を次のコマンドの入力へそのまま流し込む機能である。単機能のコマンドを組み合わせで欲しい結果を得るのが UNIX 環境の流儀である。

```
$ cat log.txt | grep "ERROR"
$ grep "ERROR" log.txt | wc -l
$ cat events.txt | grep -v "noise" | awk '{print $2}'
```

1 行目は log.txt の内容を読み出し、その中から ERROR を含む行だけを表示する。2 行目では、抽出結果をさらに wc -l へ渡し、エラー件数を数えている。3 行目では、ノイズ行を除外したうえで 2 列目だけを取り出している。

このように、まず全体を見る、次に条件で絞る、最後に列を抜く、という手順を 1 行の中でつなげられる。

2.6 URL からファイルを取得する

解析では、公開データや設定例、インストーラスクリプトを URL から取得することがある。そのときによく使うのが curl と wget である。大きな違いは、curl は何も付けずに内容を標準出力へ出し、wget は既定でファイルとして保存する点にある。macOS には curl が標準で入っているが、wget は標準では入っていない。必要なら brew install wget などで追加する。

2.6.1 curl

curl は、URL の内容を表示したり、保存したり、別のコマンドへ渡したりするときに使う。まずは次の形を覚えておけばよい。

```
$ curl https://example.com/config.txt | head -n 2
$ curl -O https://example.com/data/run001.csv
$ curl -o events.csv https://example.com/data/run001.csv
$ curl -L -O https://example.com/latest.csv
$ curl -fsSL https://pyenv.run | bash
```

1 行目では、取得した内容をファイルへ保存せず、そのまま画面へ流している。たとえば結果は次のようになる。

```
threshold=5.0
window_ns=250
```

2 行目と 3 行目はファイル保存である。2 行目の -O は URL の末尾にあるファイル名をそのまま使う。3 行目の -o events.csv は、保存名を自分で決めたいときに使う。4 行目の

-L はリダイレクト先までたどるオプションであり、短縮 URL や配布用リンクを扱うときによく必要になる。5 行目の -fsSL はインストール手順でよく見る組合せで、-f は HTTP エラー時に失敗として扱う、-s は通常の進捗表示を消す、-S は -s と併用したときでもエラー文は表示する、-L はリダイレクトをたどる、という意味である。

- O URL の末尾にある名前でも保存する。配布元のファイル名をそのまま使いたいときに向く。
- o 保存名を自分で指定する。長い URL や分かりにくい名前を短く直したいときに使う。
- L リダイレクトをたどる。共有 URL や最新版リンクでは付けた方が安全なことが多い。
- f HTTP エラーを成功扱いにしない。存在しない URL を取ってしまったときの見落としを減らせる。
- ss 通常表示を減らしつつ、エラーだけは見えるようにする。スクリプトから呼ぶときに便利である。

2.6.2 wget

wget は、URL を指定すると既定でファイルへ保存する。大量のファイルを順に取得したいときや、大きなファイルの取得を再開したいときに使いやすい。

```
$ wget https://example.com/data/run001.csv
$ wget -O events.csv https://example.com/data/run001.csv
$ wget -c https://example.com/archive.tar.gz
```

1 行目では、URL の末尾にある run001.csv という名前で保存される。2 行目の -O は保存名を自分で決める形であり、curl -o と同じ発想である。3 行目の -c は途中で止まったダウンロードを再開するときに使う。回線が不安定な環境やサイズの大きい配布物では便利である。

- O 保存名を自分で指定する。既定の名前を使いたくないときに使う。
- c 中断したダウンロードを再開する。大きなファイルで有効である。
- q 表示を減らす。ログを静かにしたいときに使う。
- show-progress 進捗だけは見たいときに使う。静かな実行と相性がよい。

wget が手元にない環境では、curl -O や curl -o で代用できる。また、画面へ流した内容をそのままパイプで次のコマンドへ渡したいときは、wget より curl の方が自然である。

2.7 環境変数と PATH

2.7.1 環境変数を使う

シェルやプログラムには、「名前」と「値」の組として渡される設定がある。これが環境変数である。環境変数は、シェルの中だけで完結するものではなく、そこから起動した Python

や各種コマンドにも引き継がれる。現在設定されているよく使う環境変数の値を見るには、次のように打つ。

```
$ echo $HOME
$ echo $SHELL
$ echo $PATH
```

実行結果は、たとえば次のようになる。

```
/Users/ikomae
/bin/zsh
/opt/homebrew/bin:/usr/local/bin:/usr/bin:/bin:/usr/sbin:/sbin
```

1 行目はホームディレクトリ、2 行目は現在のシェル、3 行目は実行ファイルを探すディレクトリの一覧である。PATH はコロン : 区切りで並んでおり、シェルは左から順に探して最初に見つかった実行ファイルを使う。後で出てくる PYENV_ROOT や DATA_ROOT も同じ仲間であり、「プログラムへ外から値を渡す仕組み」と考えると分かりやすい。新たに環境変数を設定するには次のようにする。

```
$ export DATA_ROOT="$HOME/data/events"
$ echo $DATA_ROOT
```

結果の例は次の通りである。

```
/Users/ikomae/data/events
```

export 自体は成功しても通常は何も表示しない。続けて echo \$DATA_ROOT を実行し、意図した値が入ったことを確認する。ここでは \$HOME が先に展開され、その結果として絶対パスが保存されている。

ただし、この設定は通常そのターミナルを閉じると消える。毎回使う値ならシェルの設定ファイルに export ... を書いておく。どのファイルを編集するかは今使っているシェルで決まる。第 2.1 章で述べたように、echo \$SHELL を実行することで使用しているシェルの種類を確認することができる。/bin/zsh と出た場合は ~/.zshrc、/bin/bash と出た場合は ~/.bashrc に export ... を追記すればよい。

2.7.2 展開と引用

シェルでは、コマンドを実行する前に \$HOME のような変数展開や、\$(pwd) のようなコマンド置換が行われる。ここで重要なのは、引用符の種類によって展開の有無が変わることである。

```
$ echo $HOME
$ echo "$HOME"
$ echo '$HOME'
$ name="analysis result"
$ echo $name
$ echo "$name"
$ echo "$(pwd)"
```

```
$ echo "`pwd`"
```

1 行目と 2 行目は、どちらも `$HOME` を展開する。多くの場合、`HOME` には空白が入らないので、見た目の結果は同じになる。しかし、クォートなしの `$HOME` は展開後に空白で分割されたり、ワイルドカードとして再解釈されたりする可能性がある。これに対して `"$HOME"` は 1 つの引数として扱われるので、安全である。したがって、「変数は基本的にダブルクォートで囲む」と覚えた方がよい。

3 行目のシングルクォート `'...'` は、中の文字列をほぼそのまま扱う。そのため `$HOME` は展開されず、文字どおり `$HOME` と表示される。4 行目と 5 行目の違いは、空白を含む値で見ると分かりやすい。 `name="analysis result"` のあとで `echo $name` と書くと、シェルは `analysis` と `result` を別々の単語として扱う。これに対して `echo "$name"` なら、空白を含んだまま 1 つの値として渡る。6 行目の `$(pwd)` は `pwd` の出力で置き換える書き方であり、7 行目のバッククォート記法も同じ目的で使われる。ただし、新しく書くなら `$(...)` の方が読みやすく、入れ子にもできるので自然である。

この違いは、設定ファイルへ 1 行追記するとき特に重要である。たとえば `echo 'export PATH="$HOME/bin:$PATH"' >> ~/.zshrc` のようにシングルクォートで囲むと、`$HOME` や `$PATH` を展開せず、その文字列をそのまま `~/.zshrc` へ追記できる。もしダブルクォートで囲むと、その場で現在の値へ展開されて書き込まれるので、意図とずれることがある。

また、空白と改行の扱いにも注意が必要である。クォートの外では、空白やタブや改行が単語の区切りになる。そのため、空白を含むファイル名はクォートしないと壊れる。

```
$ mkdir "analysis result"
$ cp "analysis result/data.txt" backup/
```

1 つの長いコマンドを複数行へ分けたいときは、行末に `\` を置いて改行を継続する。

```
$ python analyze.py \
  --input data/events.txt \
  --output result.txt
```

改行は通常その場でコマンドの終わりになるので、`\` を付けずに改行すると別のコマンドとして解釈される。コマンド例を写すときは、空白、クォート、改行のどれが意味を持っているかを意識した方が安全である。

2.7.3 PATH と実行ファイル

シェルが `python3` や `ls` を実行できるのは、それらが実行ファイルとして保存されており、しかもシェルがその場所を知っているからである。その探索に使う環境変数が `$PATH` である。実際に実行ファイルがどこから使われているかを探すには、次のコマンドを用いる。

```
$ which python3
$ which ls
$ echo $PATH
```

出力の例は次のようになる。

```
/opt/homebrew/bin/python3
/bin/ls
/opt/homebrew/bin:/usr/local/bin:/usr/bin:/bin:/usr/sbin:/sbin
```

`which python3` は「いま `python3` という名前で実際に呼ばれる実行ファイルの場所」を返す。ここでは Homebrew で入れた Python が使われている。`which ls` が `/bin/ls` なら、`ls` は OS 標準のコマンドを使っているという意味である。3 行目の `PATH` と見比べると、`/opt/homebrew/bin` が `/usr/bin` より左にあるため、`python3` ではそちらが優先されていることが分かる。

`bin` という名前は、実行ファイルを置くディレクトリによく使われる。後で出てくる `.venv/bin` の `bin` も、この慣習に従っている。

自分が作ったシェルスクリプトや実行ファイルを別のディレクトリ（例えば `~/my_scripts`）に置き、どこからでもコマンド名だけで呼び出したい場合は、次のように現在の `$PATH` の先頭に自分のディレクトリを追加して上書きすればよい。これもシェル起動時に毎回行う必要があるなら、`~/.zshrc` などに記載しておく。

```
$ export PATH="$HOME/my_scripts:$PATH"
```

2.8 リダイレクトとログ保存

2.8.1 echo、標準出力、標準エラー

シェルのコマンドは、単に画面へ文字を出すだけではなく、出力先を切り替えられる。ここで区別したいのは、通常の結果を流す標準出力（standard output, `stdout`）と、エラーメッセージを流す標準エラー（standard error, `stderr`）である。

`echo` は標準出力へ文字列を出す最も基本的なコマンドであり、動作確認や設定ファイルへの追記でよく使う。

```
$ echo "hello"
$ echo "$HOME"
```

1 行目は単に `hello` を出力する。2 行目は前節で述べた変数展開により、`$HOME` の値を出力する。ここで重要なのは、`echo` 自体は画面へ出しているだけであり、その出力先は次の節のリダイレクトで変えられるという点である。

2.8.2 > と >>

`>` は標準出力をファイルへ書き出す。既存のファイルがあれば中身を上書きする。

```
$ echo "alpha" > notes.txt
$ cat notes.txt
alpha
```

この例では、echo の結果が画面ではなく notes.txt に保存される。すでに notes.txt が存在していた場合も、その内容は新しい内容で置き換わる。したがって、> は便利だが、うっかり使うと既存ファイルを消してしまう。

>> は追記であり、既存の内容を残したまま末尾に足す。

```
$ echo "alpha" > notes.txt
$ echo "beta" >> notes.txt
$ cat notes.txt
alpha
beta
```

設定ファイルの末尾へ 1 行追加したいときは、この >> を使う。たとえば ~/.zshrc に環境変数の設定を足すときに自然である。逆に、> を使うと既存の設定を消してしまうので注意が必要である。

2.8.3 1> と 2>

> は実際には 1> と同じ意味であり、標準出力だけをファイルへ送る。標準エラーを別ファイルへ分けたいときは 2> を使う。

```
$ python analyze.py > output.log
$ python analyze.py 1> output.log 2> error.log
```

1 行目では通常の出力だけが output.log に入り、エラーメッセージは画面に残る。2 行目では、通常の出力を output.log に、エラーメッセージを error.log に分けて保存している。長い処理を回すときは、「結果は保存したいが、失敗したときの原因も別に残したい」ということが多いので、この書き方は有用である。

標準出力と標準エラーを同じファイルへまとめたときは、2>&1 を使う。

```
$ python analyze.py > run.log 2>&1
```

これは、標準エラーの行き先を標準出力と同じ先へ合わせる、という意味である。ログを 1 本にまとめたいときに使う。

2.8.4 tee で見ながら保存する

> や >> を使うと出力はファイルへ送られ、画面には出なくなる。実行中の様子も見たいが、同時に保存もしたいときは tee が便利である。tee は標準入力を受け取り、その内容を画面へ出しつつファイルへも書く。

```
$ python analyze.py | tee run.log
$ python analyze.py 2>&1 | tee run.log
```

1 行目は標準出力だけを画面と run.log の両方へ流す。2 行目は標準エラーもまとめてから tee へ渡しているので、実質的に「全部を見ながら全部を保存する」形になる。処理が数分から数十分かかる場合、進捗を画面で見つつ、あとで見返すためのログも残せるので実用的である。

tee に -a を付けると追記になる。

```
$ python analyze.py 2>&1 | tee -a run.log
```

この場合は、既存の run.log を消さずに末尾へ足していく。毎日の実行結果を 1 つのログへ蓄積したい場合に向く。

2.9 権限とスクリプトの実行

2.9.1 権限を読む

ファイルには権限がある。読み取れるか、書き込めるか、実行できるかを `rwX` で表す。`ls -l` を使うと確認しやすい。

```
-rwxr-xr-x  1 user  staff  1234 Apr  8 10:00 run_analysis.sh
-rw-r--r--  1 user  staff   411 Apr  8 10:05 notes.txt
-rw-----  1 user  staff   411 Apr  8 10:05 id_ed25519
```

最初の 10 文字のうち、先頭 1 文字はファイル種別であり、残り 9 文字が権限である。3 文字ずつに区切って、所有者、グループ、その他の利用者に対する権限を表す。文字と権限の対応は表 2.3 のとおりである。

権限を変更するには `chmod` コマンドを用いる。所有者 (user) に実行権限 (x) を付与したければ `u+x`、その他の利用者 (other) の読み込み権限 (r) と書き込み権限 (w) を剥奪したければ `o-rw`、グループ (group) とその他 (other) の権限を読み取り (r) のみにしたければ `go=r` のように指定すればよい。`a+x` のようにして、すべてのユーザー (all) の権限を変更することもできる。

```
$ chmod u+x my_script.sh
$ chmod o-rw notes.txt
$ chmod go=r read_only.txt
$ chmod a+x run_analysis.sh
```

表 2.3 権限の記号と数字

記号	数字	意味
r	4	読み取り
w	2	書き込み
x	1	実行

表 2.3 に示すように、権限は数字で指定することもできる。数字指定では権限を足し算で表す。たとえば 7 は `rwX`、6 は `rw-`、5 は `r-x` である。したがって 755 は所有者が `rwX`、それ以外が `r-x` を意味し、644 は所有者が `rw-`、それ以外が `r--` を意味する。秘密鍵のように本人だけが読めればよいものには 600 がよく使われる。設定を変更する例を下に示す。

```
$ chmod 755 run_analysis.sh
$ chmod 644 notes.txt
$ chmod 600 ~/.ssh/id_ed25519
```

2.9.2 スクリプトを直接実行する

Python スクリプトは `python3 hello.py` の形で実行するなら、実行権限がなくてもよい。これに対して `./hello.py` のように直接実行する場合には、どのプログラムで解釈するかをファイル先頭を書いておく必要がある。その先頭行の `#!` で始まる記法を、シバン (shebang) という。

```
1 #!/usr/bin/env python3
2
3 print("hello")
```

このように記述した上で、ファイルそのものに対して直接実行できるようにするため、実行権限を付与する。所有者に対して権限を付与する場合は、付与の対象 (u) を省略することができる。

```
$ chmod +x hello.py
$ ./hello.py
```

`#!/usr/bin/env python3` は、「python3 を見つけてこのファイルを実行せよ」という意味である。いきなり言葉だけで覚える必要はないが、「直接実行にはシバンと実行権限の両方が必要だ」という構造だけは理解しておいた方がよい。この考え方をシェルスクリプト全体へ広げると、自動化や一括処理を書けるようになる。付録 E では、for ループや条件分岐を用いた実践的なバッチ処理の書き方をまとめている。

第 3 章 Python 環境を整える

3.1 Python の確認と管理方針

3.1.1 何を分けて考えるべきか

Python を使い始めるときは、次の 3 つを分けて考える必要がある。

1. Python 本体を入れること
2. 複数バージョンの Python を切り替えること
3. プロジェクトごとの仮想環境を作ること

まず Python 本体が必要であり、そのうえで Python 3.11 と 3.12 を切り替えたいならバージョン管理ツールが必要になる。さらに、同じ Python 3.12 でもプロジェクト A と B で依存ライブラリが違えば、仮想環境で分ける必要がある。この 3 段階を分けて理解した方が、あとで混乱しにくい。

3.1.2 今の Python を確認する

macOS でも WSL でも、最初にいま見えている Python を調べておく方がよい。現在利用可能な Python を確認するには、次のように実行する。

```
$ python3 --version
$ which python3
$ python3 -c "import sys; print(sys.executable)"
```

結果の例は次のようになる。

```
Python 3.12.10
/opt/homebrew/bin/python3
/opt/homebrew/Cellar/python@3.12/3.12.10/bin/python3.12
```

1 行目は、いま python3 で呼ばれるバージョンを表す。2 行目は、シェルが実際に見つけた python3 という名前の実行ファイルである。3 行目は、その Python の内部から見た実行ファイルの実体であり、シンボリックリンクの先まで含めて表示されることがある。2 行目と 3 行目が完全に同じ文字列でなくても問題はないが、「どちらも同じ系列の Python を指しているか」は確認した方がよい。複数バージョンを切り替えるようになると、この確認は非常に重要になる。

3.2 pyenv による複数バージョンの管理

Python 本体の導入と切り替えには pyenv が分かりやすい。pyenv は、シェルから見える python をディレクトリ単位で切り替えるための道具であり、複数バージョンの Python を使い分けるときの基準として扱いやすい。

3.2.1 macOS での準備

pyenv は Python 本体をビルドして入れるので、macOS では Xcode Command Line Tools が必要になる。すでに Homebrew が正常に動いているなら、Command Line Tools は入っていることが多い。すでにインストールされているかを確認するには次のように実行する。

```
$ xcode-select -p
```

すでにインストールされていれば、結果の例は次のようになる。

```
/Library/Developer/CommandLineTools
```

このようにパスが表示されれば、Command Line Tools はインストール済みである。逆に、エラー文が出て何も表示されなければ未導入の可能性が高い。未導入の場合は、次のコマンドを実行してインストールする。

```
$ xcode-select --install
```

3.2.2 WSL / Ubuntu での準備

WSL の Ubuntu では、ビルドに必要なライブラリを先に入れておく。一括で導入するには次のコマンドを実行する。

```
$ sudo apt update
$ sudo apt install -y build-essential curl git libssl-dev zlib1g-dev \
  libbz2-dev libreadline-dev libsqlite3-dev libffi-dev liblzma-dev tk-dev
```

apt update の出力は長いが、末尾でたとえば次のように Done が見えれば、パッケージ一覧の更新は完了している。

```
Reading package lists... Done
Building dependency tree... Done
Reading state information... Done
```

apt install でも多くの行が流れる。今回の例では -y を付けているので、通常は確認なしで続行する。-y を外して実行した場合は、途中で次のような確認が出ることがある。

```
Need to get 48.2 MB of archives.
After this operation, 201 MB of additional disk space will be used.
Do you want to continue? [Y/n]
```

この表示が出たら、示されているパッケージや使用量に問題がないことを確認し、続けるなら `y` を入力して `Enter` を押す。`n` を入力すると処理は中止され、インストールは行われない。

インストールの終盤では、次のように `Setting up ...` が並ぶことがある。

```
Setting up libffi-dev:amd64 (3.4.4-1) ...
Setting up libsqlite3-dev:amd64 (3.40.1-2ubuntu0.2) ...
Setting up build-essential (12.9ubuntu3) ...
```

これは各パッケージの設定を進めている段階であり、この表示自体は正常である。最後まで流れたあとでエラーが出ずにシェルのプロンプトへ戻れば、インストールは完了している。

3.2.3 pyenv を入れてシェルへ組み込む

macOS では、まず次のように実行する。

```
$ brew install pyenv
```

結果の末尾では、たとえば次のような行が見える。

```
==> Pouring pyenv--2.6.2.arm64_sequoia.bottle.tar.gz
Installed to /opt/homebrew/Cellar/pyenv/2.6.2
```

最後の行は、Homebrew が `pyenv` をどこへ入れたかを示している。エラーなくこの行まで進めば、インストール自体は完了している。

一方、WSL / Ubuntu では通常 Homebrew を前提にしないので、前節の依存パッケージを入れたあとにインストーラスクリプトを使う。

```
$ curl -fsSL https://pyenv.run | bash
```

`curl ... | bash` の出力は長くなりやすいが、エラーなくシェルへ戻ればインストール自体は完了している。

どちらの方法でも、インストール直後はまだ `pyenv` を通常のコマンドとして使える状態にはなっていない。次に、自分のシェルに対応する設定ファイルへ初期化コードを書き込む。設定先は、`/bin/zsh` なら `~/.zshrc`、`/bin/bash` なら `~/.bashrc` である。以下では `>>` を使って設定ファイルの末尾へ 1 行ずつ追記している。`>` ではなく `>>` を使うのは、既存の設定を消さないためである。

```
$ echo 'export PYENV_ROOT="$HOME/.pyenv"' >> ~/.zshrc
$ echo '[[ -d $PYENV_ROOT/bin ]] && export PATH="$PYENV_ROOT/bin:$PATH"' >> ~/.zshrc
$ echo 'eval "$(pyenv init - zsh)"' >> ~/.zshrc
$ exec "$SHELL"
```

`exec "$SHELL"` は、いま動いているシェルを `$SHELL` で示されるシェル本体で置き換えて、設定をその場で読み直すためのコマンドである。`SHELL` は現在使っているシェルのパスを入れた環境変数であり、`zsh` なら通常 `/bin/zsh`、`bash` なら通常 `/bin/bash` が入っている。ここでは `~/.zshrc` に追記した内容をすぐ反映させるために実行している。ターミナルをいったん閉じて開き直しても同じ目的は果たせる。

echo ... >> /.zshrc 自体は成功しても何も表示しない。確認は、シェルを読み直した後に pyenv が見えるかで行う。たとえば次のように打つ。

```
$ pyenv --version
pyenv 2.6.2
$ which pyenv
/Users/ikomae/.pyenv/bin/pyenv
```

1 行目でバージョン番号が出れば、シェルから pyenv を実行できる状態になっている。
2 行目では、pyenv が ~/.pyenv/bin から見つかっていることが分かる。ここで command not found になる場合は、設定ファイルへの追記先を間違えたか、exec "\$SHELL" で読み直せていない可能性が高い。

使っているシェルが bash の場合は、次のように ~/.bashrc に対して設定を追記する。

```
$ echo 'export PYENV_ROOT="$HOME/.pyenv"' >> ~/.bashrc
$ echo '[[ -d $PYENV_ROOT/bin ]] && export PATH="$PYENV_ROOT/bin:$PATH"' >> ~/.bashrc
$ echo 'eval "$(pyenv init - bash)"' >> ~/.bashrc
$ exec "$SHELL"
```

3.2.4 バージョンを入れて切り替える

pyenv を使う場合は、pyenv install でバージョンを追加し、pyenv global、pyenv local、pyenv shell で切り替える。たとえば新しいバージョンを追加して確認するには次のように行う。

```
$ pyenv install 3.11.11
$ pyenv install 3.12.10
$ pyenv versions
```

pyenv install は数分かかることがあり、途中でビルドログが多数流れる。完了後に pyenv versions を実行すると、たとえば次のように表示される。

```
* system (set by /Users/ikomae/.pyenv/version)
 3.11.11
 3.12.10
```

system は、pyenv で切り替えない場合に OS 側が標準で見せる Python である。3.11.11 と 3.12.10 が一覧に出ていれば、そのバージョンはインストール済みである。先頭の * は、いま有効になっているシステムを示す印であり、この段階ではまだ system のままでも問題はない。

その後、システム全体で普段使う標準のバージョンを決めるなら、次のように pyenv global を実行する。

```
$ pyenv global 3.12.10
$ python --version
$ which python
```

結果の例は次のようになる。

```
Python 3.12.10
/Users/ikomae/.pyenv/shims/python
```

pyenv global は普段使うバージョンを決める。ここで python の実体が ~/.pyenv/shims/python になっている点が重要である。pyenv はこの shim を経由して、裏でどのバージョンを起動するかを切り替えている。これに対して pyenv local は、そのディレクトリだけ別のバージョンを使いたいときに使う。特定のプロジェクト用ディレクトリ内でバージョンを固定するには、次のような手順を踏む。

```
$ mkdir analysis311
$ cd analysis311
$ pyenv local 3.11.11
$ python --version
$ cat .python-version
```

結果の例は次のようになる。

```
Python 3.11.11
3.11.11
```

pyenv local を実行すると .python-version が作られ、そのファイルの中身として 3.11.11 が書き込まれる。そのディレクトリでは指定したバージョンが優先される。つまり、analysis311 に入っている間だけ python の結果が 3.11 へ切り替わる。これによって、同じマシンの中でプロジェクト A は 3.11、プロジェクト B は 3.12 という使い分けができる。

pyenv shell 3.11.11 は、そのターミナルを閉じるまでの一時的な切り替えである。検証用に 1 回だけ古いバージョンで動かしたいときに便利である。

3.3 venv でプロジェクトごとの仮想環境を作る

Python 本体のバージョンを決めたら、そのバージョンの上にプロジェクト専用の仮想環境を作る。依存ライブラリの衝突を避けるためである。仮想環境を作り、そこに入るための基本コマンドは次の通りである。

```
$ python -m venv .venv
$ source .venv/bin/activate
$ which python
$ which pip
$ python --version
$ pip --version
```

仮想環境へ入ると、プロンプトの先頭に (.venv) が付くことが多い。ターミナルの表示は次のように変わる。

```
(.venv) ikomae@macbook analysis $
```

which python 以降の結果は、たとえば次のようになる。

```
/Users/ikomae/analysis/.venv/bin/python
/Users/ikomae/analysis/.venv/bin/pip
Python 3.11.11
pip 25.0 from /Users/ikomae/analysis/.venv/lib/python3.11/site-packages/pip
```

which python と which pip を見ると、.venv/bin/python と .venv/bin/pip が使われていることが分かる。これは、source .venv/bin/activate が \$PATH の先頭に .venv/bin を追加しているからである。最後の pip ... from .../.venv/... という表示も、「この仮想環境の中の pip を使っている」ことの確認になる。

3.3.1 pip と python -m pip

仮想環境へ入っているなら、通常は pip と python -m pip は同じ環境の pip を指す。したがって、作業中は pip install numpy と書いてよい。

一方で、いまどの Python が有効か不安なときや、スクリプトや文書の中で「この Python に対応する pip を使う」と明示したいときは、python -m pip の方が誤解が少ない。実務では両方見るが、意味の違いを分かって使うことが重要である。実際にライブラリを入れる例を挙げる。

```
$ pip install --upgrade pip
$ pip install numpy pandas polars matplotlib scipy astropy tqdm
```

pip install の出力は長いが、末尾ではたとえば次のような行が見える。

```
Successfully installed numpy-2.3.0 pandas-2.3.0 scipy-1.15.0
```

ここで Successfully installed ... が出れば、少なくともインストール処理自体は成功している。直後に python -c "import numpy, pandas" のように試して import エラーが出ないことまで確認すると確実である。

作業を終えたら deactivate で仮想環境から抜けられる。

3.4 解析用ライブラリと JupyterLab

3.4.1 JupyterLab を併用する

対話的に試しながら解析したいときは、JupyterLab も便利である。小さなコード片をその場で動かし、数値や図をすぐ確認できるため、探索的な作業では特に役立つ。これを導入・起動するには次のように実行する。

```
$ pip install jupyterlab
$ jupyter lab
```

jupyter lab を実行すると、ターミナルにはたとえば次のような行が出る。

```
[I] Jupyter Server 2.15.0 is running at:
```

```
[I] http://localhost:8888/lab?token=abc123...
```

この URL は、ブラウザから接続するためのアドレスである。localhost:8888 は「いま使っているマシン上で待ち受けている」ことを意味し、token=... は最初の接続確認に使う一時的な鍵である。ブラウザが自動で開かなかった場合も、この URL を開けば JupyterLab へ入れる。

JupyterLab の利点は、コードを実行できるだけでなく、その前後に説明文、数式、図の読み方を書き添えられる点にある。解析の途中経過を他人へ見せるときも、自分で後から読み返すときも、コードと説明が同じノートブックに並んでいる方が理解しやすい。たとえば次のような書式で Markdown セルを書くことができる。

```
# 解析メモ
```

```
- 入力ファイル: `events_2024_01_01.txt.gz`  
- 閾値: `signal > 5.0`
```

```
$\Delta t$ の分布を確認する
```

ただし、JupyterLab は最終成果物の置き場所というより、試行錯誤の場として使う方がよい。解析手順を再現したい段階では、ノートブック中で固めた処理を Python スクリプトへ戻し、入力や出力を明示した方が後で困りにくい。ここまでが「試しながら考える」ための環境であり、次に扱う uv は、その試行錯誤をプロジェクトとして固定するための道具である。

3.5 プロジェクト管理ツール uv の利用

uv は Python 本体の導入もできるが、本書ではそれよりも「プロジェクト単位の管理」に使う道具として位置付ける方が自然である。特に、依存関係、ロックファイル、.python-version、Git 管理、パッケージ化、ワークスペース管理といった、プロジェクト全体の整理で力を発揮する。

3.5.1 プロジェクトの初期化

多くの人は、まずシンプルに uv init を使えばよい。オプションは後から必要になったときに足せばよい。新しいプロジェクトを始めるには、次のようにディレクトリを作ってから初期化する。

```
$ mkdir analysis_uv  
$ cd analysis_uv  
$ uv init
```

uv init 自体は短い完了メッセージだけで終わることもあるので、結果はファイル構成で確認の方が確実である。たとえば ls -a を実行すると、既定では少なくとも次のようなファイルやディレクトリが見える。(tree で確認してもよい。)

analysis_uv/ の初期構成

```
.git/  
.gitignore  
.python-version  
README.md  
main.py  
pyproject.toml
```

つまり、uv init は単に Python ファイルを 1 つ置くだけでなく、Git 管理の土台までまとめて用意する。この点が venv 単体との大きな違いである。まずはこの既定構成を理解すれば十分であり、以下のオプションは「最初から構成を変えたい事情がある場合」にだけ見ればよい。

- uv init --bare: pyproject.toml だけを作る
- uv init --vcs none: Git 初期化をしない
- uv init --no-pin-python: .python-version を作らない
- uv init --package や uv init --lib: スクリプトではなくパッケージやライブラリとして始める

特に、コードを再利用可能なモジュールやライブラリとして育てたいなら、--package や --lib を意識した方がよい。単発スクリプトで終わるのか、将来 import される部品になるのかで、適切な初期構成は変わる。

3.5.2 依存関係の追加と環境の同期

uv add は依存ライブラリを追加し、pyproject.toml とロック情報を更新する。複数同時に指定する場合は次のようにする。

```
$ uv add numpy pandas polars matplotlib scipy astropy tqdm
```

uv add を実行すると、依存関係の解決結果が要約表示される。たとえば次のようになる。

```
Resolved 18 packages in 0.42s  
Installed 7 packages in 0.31s  
+ numpy==2.3.0  
+ pandas==2.3.0  
+ scipy==1.15.0
```

Resolved ... packages は、直接指定したライブラリだけでなく、その依存先も含めて必要な集合を決めたことを表す。Installed ... packages は実際に環境へ追加した数であり、その下の + 付き行は今回入った主なパッケージ名とバージョンである。

uv sync は、pyproject.toml とロックファイルに基づいて環境をそろえる。ここで初めて .venv が作られることもある。実行コマンドは次の通りである。

```
$ uv sync
```

uv sync の後は、たとえば次のような行が見える。

```
Creating virtual environment at: .venv
Installed 18 packages in 0.54s
```

ここで `Creating virtual environment at: .venv` と出れば、そのプロジェクト専用の仮想環境が作られている。過去の自分の解析や、他人から受け取ったプロジェクトを再現するときは、この `uv sync` が重要になる。リポジトリを取得して `uv sync` すれば、必要な依存関係をまとめてそろえやすい。ここで `Git` の基本が必要になるので、付録 B もあわせて読むとよい。

3.5.3 コマンドの実行とバージョン固定

`uv run` は、そのプロジェクトの環境でコマンドを実行する。スクリプトを直接走らせるときは、`Python` 本体を起動したいときとで書き分ける。いくつか例を挙げる。

```
$ uv run main.py
$ uv run python --version
$ uv run python -m pytest
```

たとえば `uv run python --version` の結果は次のようになる。

```
Python 3.12.10
```

この 1 行は、「いまのプロジェクト設定に従って起動された `Python` が 3.12.10 である」ことを示している。実行対象が `Python` スクリプトそのものであるなら、`uv run main.py` と書けばよい。わざわざ `python` を挟む必要はない。一方で、`-m` を使いたいときや、`Python` 本体へオプションを渡したいときは `uv run python ...` と書く。

ここまでは「その環境でどう実行するか」を見た。次は「そのプロジェクトがどの `Python` を使うか」を固定する。

`uv` もプロジェクト単位で `Python` バージョンを固定できる。`pyenv` がシェル全体の切り替えを担当し、`uv` がプロジェクト側の固定を担当する、と分けて考えると分かりやすい。固定や一発実行のコマンド例は次の通りである。

```
$ uv python pin 3.12
$ uv run python --version
$ uv run --python 3.11 python --version
```

結果の例は次の通りである。

```
Python 3.12.10
Python 3.11.11
```

1 行目は、`uv python pin 3.12` によってプロジェクト既定が 3.12 系になっていることを示す。2 行目は、`--python 3.11` を付けたその 1 回だけ 3.11 系で起動した結果である。`pin` は既定値の設定、`--python` は一時的な上書きとして読むとよい。

3.5.4 標準ライブラリと外部ライブラリ

Python には、最初から使える標準ライブラリと、自分で追加する外部ライブラリがある。

- 標準ライブラリの例: `math`, `pathlib`, `glob`, `argparse`
- 外部ライブラリの例: `numpy`, `pandas`, `polars`, `matplotlib`, `scipy`, `astropy`

ここまでで Python 本体、仮想環境、プロジェクト管理の役割を見たので、次はその環境へ何を入れるのかを整理する。標準ライブラリは Python 本体に含まれている。外部ライブラリは、目的に応じて自分で追加する。解析では外部ライブラリが非常に重要だが、まずは「何が標準で、何が追加なのか」を区別しておくことが大切である。

3.5.5 解析用のライブラリを入れる

本書の後半で使う主なライブラリを表 3.1 に示す。

表 3.1 本書で使う主なライブラリと役割

ライブラリ	主な役割
NumPy	数値配列の高速処理
pandas	表形式データの読み込みと加工
Matplotlib	図の作成
SciPy	フィットと数値計算
Astropy	時刻・単位・座標の扱い
Polars	大規模な表データの高速処理
tqdm	進捗表示

`venv` を使うなら `pip install`、`uv` を使うなら `uv add` と書けばよい。まず `venv` を使う場合は、次のように書く。

```
$ pip install numpy pandas polars matplotlib scipy astropy tqdm
```

インストールが成功すると、末尾ではたとえば次のように表示される。

```
Successfully installed astropy-7.0.0 matplotlib-3.10.0 numpy-2.3.0 pandas-2.3.0
```

ここでは、指定した主要ライブラリがその仮想環境へ入ったことが分かる。バージョン番号まで表示されるので、レポートや再現用メモではこの情報も残しておく役に立つ。

同じライブラリを `uv` 管理のプロジェクトへ追加するなら、次のように書く。

```
$ uv add numpy pandas polars matplotlib scipy astropy tqdm
```

`uv` 管理のプロジェクトでは、たとえば次のような要約が表示される。

```
Resolved 18 packages in 0.42s
Installed 7 packages in 0.31s
```

`pip install` と違って、`uv add` は環境へ入れるだけでなく、`pyproject.toml` に依存関係を記録する点が重要である。つまり、「いまだけ入った」のではなく、「このプロジェクトはこれらのライブラリに依存している」と宣言したことになる。

3.6 引数・設定ファイルとコードの分離

3.6.1 コマンドライン引数と設定ファイルを使い分ける

同じ解析スクリプトを何度も使うなら、入力ディレクトリや出力先をコードに埋め込むより、コマンドライン引数で渡す方がよい。Python では `argparse` が標準で使える。もっともシンプルな構成例を下に示す。

```
1 import argparse
2
3 parser = argparse.ArgumentParser()
4 parser.add_argument("input_dir")
5 parser.add_argument("--outdir", default="output")
6 args = parser.parse_args()
7
8 print(args.input_dir, args.outdir)
```

このスクリプトを `analyze.py` として保存し、次のように実行するとする。

```
$ python analyze.py data/run001
data/run001 output
$ python analyze.py data/run001 --outdir results/figures
data/run001 results/figures
```

1 行目では、位置引数 `input_dir` に `data/run001` が入り、`--outdir` は省略したので既定値 `output` が使われている。2 行目では、`--outdir` を明示したため、既定値が `results/figures` に上書きされている。引数の説明では、「どの値が必須で、どの値が省略時の既定値を持つか」を結果と対応させて読むことが重要である。

ただし、何でも引数にすればよいわけではない。毎回ほぼ同じ値まで毎回書かせると、使いにくいスクリプトになる。

値の置き場所は、表で機械的に覚えるより、用途ごとに言葉で整理した方が分かりやすい。

コマンドライン引数 実行ごとに変わる値を置く。入力ディレクトリ、出力先、日付範囲、並列数などが典型である。

設定ファイル プロジェクト単位では固定だが、将来変更し得る値を置く。校正ファイルのパス、検出器 ID、閾値、図の保存形式などが当てはまる。

環境変数 マシン依存の値や秘密情報を置く。`DATA_ROOT`、API トークン、認証情報などが典型である。

コード内の定数 定義として固定したい値や単位変換を書く。`NS_PER_SECOND` や物理定数の

ように、意味が仕様として決まっているものを置く。

入力ファイルのパス、出力先、しきい値、作業ディレクトリのように「実行条件」であるものは、原則としてハードコーディングしない方がよい。コードを書き換えずに切り替えられるようにしておく、と、再利用と再現が楽になる。

3.6.2 設定ファイルとマジックナンバーの排除

めったに変わらない値は、設定ファイルへまとめる方が使いやすい。形式は JSON でも TOML でもよい。ここでは標準ライブラリだけで扱える JSON の例 (config.json) を示す。

config.json

```
{
  "calibration_path": "calib/detector_a.csv",
  "coincidence_window_ns": 250,
  "figure_format": "pdf"
}
```

この JSON ファイルを Python のスクリプトから読み込む場合のコード例は次のようになる。

```
1 import json
2 from pathlib import Path
3
4 config = json.loads(Path("config.json").read_text())
5 window_ns = config["coincidence_window_ns"]
6 print(window_ns)
```

実行結果は次のようになる。

```
250
```

この 250 は、JSON の中の coincidence_window_ns を読み取った結果である。ここで重要なのは、250 という値がコードへ直接書かれていなくても、設定ファイルから読み込んで使える点である。このようにしておけば、同じコードを保ったまま設定だけを差し替えられる。Python 3.11 以降なら tomlib を使って TOML を読むこともできる。どの形式を選ぶにしても、「たまに変わるがコード本体ではない値」を分離することが大切である。

250 や 3600 のような数値が説明なしにコードへ裸で出てくると、後から読んだ人は意味を判断しにくい。このような数値はマジックナンバーと呼ばれる。詳しくは第 4.5.1.3 節で述べるが、意味のある数値には名前を付け、実行条件なら引数や設定ファイルへ出す、という整理を早い段階で身に付けた方がよい。

第 4 章 Python の基本

4.1 データ型と基本操作

4.1.1 変数と基本型

Python では、値に名前を付けて使う。たとえばデータを表すいくつかの変数を定義すると次のようになる。

```
1 n_rows = 12
2 threshold = 3600.0
3 label = "A"
4 use_log = True
```

`n_rows` は整数、`threshold` は浮動小数点数、`label` は文字列、`use_log` は真偽値である。解析では、整数と浮動小数点数を区別して扱う感覚が重要になる。たとえば、件数は整数だが、フィットで得られるパラメータは浮動小数点数であることが多い。

Python では変数に対して明示的な型の宣言（「これは整数です」という指定）を記述しなくても自動的に推論されるため、型を意識せずにコードを書くことができる。これは非常に便利である反面、背後では「どの型のデータとして扱うべきか」を都度 Python 側が判定・管理・包含しているため、計算処理が重くなる原因にもなる。

後述する NumPy などを用いて大量のデータを高速に処理する際には、あえて C 言語などのように厳密な型（メモリ上のデータサイズ）を書き手が意識し、指定して扱う必要が出てくる。この「Python の型と C 言語・NumPy の厳密な型の違い」の詳細については第 6.1.3 節で解説するが、基本的な文法を学ぶ段階でも、記述した値が 1 であれば整数、1.0 であれば浮動小数点数となるという「見た目による型の指示の違い」は強く意識して読み書きする癖を付けておきたい。とくに、文字列としての "12" と整数としての 12 の混同は、ファイルの読み込みや数値計算で頻繁にエラーの原因となる。

4.1.2 数値と演算子

Python は、対話的な計算機として使い始めるのが理解しやすい。四則演算、べき乗、剰余、整数除算など、基本的な計算の書き方は次の通りである。

```
1 2 + 3
2 7 / 3
3 7 // 3
4 7 % 3
5 2 ** 10
```

/ は浮動小数点数として割り算を行い、// は整数部分を返す。観測時間を秒へ直す、ビン番号を求める、インデックスを分ける、といった処理では、この違いが重要になる。特に // と % は、周期的な区切りやグループ分けでよく現れる。

浮動小数点数の計算では、表示された値が見た目通りに内部で表現されているとは限らない。これは Python 特有の問題ではなく、一般的な計算機の表現上の性質である。後半でフィットや統計量を扱うときにも、この前提を意識しておきたい。

4.1.3 文字列

ファイル名、日付時刻、ヘッダ、ラベルなど、解析コードでは文字列を扱う場面が多い。文字列は単なる表示用のデータではなく、分割、検索、整形の対象でもある。基本的な操作例を挙げる。

```
1 name = "detector_A"
2 date = "2026-04-04"
3
4 print(name.upper())
5 print(date.replace("-", "/"))
6 print(name.split("_"))
```

split、replace、strip のような操作は、ファイル読み込みの前処理で頻繁に使う。特に split は、空白区切りやカンマ区切りの 1 行を各列へ分ける最初の道具である。NumPy や pandas を使う前に、この感覚を持っておくとデータ形式の理解が速い。

4.2 データ構造

4.2.1 リスト、タプル、辞書

複数の値をまとめたいときには、いくつかの基本的な入れ物がある。よく使う 3 種類の定義例を下に示す。

```
1 labels = ["A", "B", "C", "D"]
2 point = (12, 18)
3 row = {"id": 42, "value": 3.5, "flag": True}
```

リストは順序付きで変更可能、タプルは順序付きで変更不可、辞書は名前付きの値を持つ。最初のうちは辞書が読みやすいが、大きなデータを大量に処理するときはオーバーヘッドが大きくなることもある。この違いは後の高速化章で再び出てくる。

どの入れ物を選ぶかは、見た目の好みではなく、何をしたいかで決まる。位置でアクセスするならリストやタプル、名前でアクセスするなら辞書が自然である。小さなコードでは差が見えにくいですが、処理量が増えると選択の重みが増してくる。

4.2.2 リストのメソッド

Python 公式チュートリアル [1] でも詳しく扱われているように、リストにはいくつかの基本メソッドがある。これらを知っていると、簡単な前処理や集約を自然に書ける。主な操作は次のようになる。

```
1 values = [3, 1, 4]
2 values.append(1)
3 values.sort()
4 last = values.pop()
```

`append` は末尾へ追加し、`sort` はその場で並べ替え、`pop` は末尾要素を取り出して削除する。リストメソッドの多くは「その場で変更する」点に注意が必要である。新しいリストを返すのではなく、元のリスト自体を書き換える操作が多いので、どこで状態が変わるかを意識して読む必要がある。

解析コードでは、ファイル一覧の作成、簡単なバッファ、途中結果の蓄積などにリストを使うことが多い。ただし、大量の数値そのものを主役として扱う段階では、後で NumPy 配列へ移った方が自然になることが多い。

4.2.3 インデックスとスライス

解析では、配列や文字列の一部だけを取り出したい場面が非常に多い。Python では、`[]` の中に位置を書くことで要素を取り出し、`:` を使うことで範囲を切り出せる。次のように記述する。

```
1 values = [10, 20, 30, 40, 50]
2
3 first = values[0]
4 last = values[-1]
5 middle = values[1:4]
```

最初の要素が 0 番目であること、終点の添字は含まれないこと、負の添字で末尾から数えられることは、最初にしっかり覚えておきたい。時刻列や列名の一部を取り出すとき、この基本がそのまま使われる。

文字列に対しても同じ考え方が使える。例えば `hhmmss[0:2]` で時、`hhmmss[2:4]` で分を取り出せる。この一貫性が Python の扱いやすさの一つである。

4.3 制御構文

4.3.1 条件分岐

条件によって処理を変えるには `if` を使う。

```
1 if value <= threshold:
```

```

2     print("small")
3 else:
4     print("large")

```

解析コードでは、閾値判定、ファイル名の選別、欠損値の除外など、条件分岐が頻繁に現れる。重要なのは、「なぜその条件で分けているのか」を自分で説明できることだ。

条件分岐が増えて読みにくくなったときは、条件式そのものを変数へ切り出すと分かりやすくなる。たとえば `is_valid_row = value <= threshold` のように一度名前を付けるだけでも、後で読むときの負担がかなり減る。

条件は左から右へ読んで意味が分かる形に書く方がよい。否定が重なる条件や、複数の `and` と `or` が混ざる条件は、括弧や一時変数で整理した方が安全である。解析コードでは、条件の誤読がそのままバグになる。

4.3.2 反復処理

複数の値を順に調べるには `for` を使い、次のように取り出す。

```

1 for label in labels:
2     print(label)

```

要素の番号（添字）も必要なら `enumerate` を組み合わせると便利である。

```

1 for i, value in enumerate(labels):
2     print(i, value)

```

一方で、データ点が非常に多いとき、Python レベルの `for` ループが速度のボトルになることがある。本書では後半で、その回避方法を詳しく扱う。

初学者の段階では、まず正しく読める `for` 文を書くことが先である。速く書くことを意識するのは、その後でよい。読みやすい基本形を知っているからこそ、後で NumPy や pandas へ置き換えたときに、何を省略しているかが分かる。

4.3.2.1 range と while

`for` 文と並んで、反復処理でよく使うのが `range` と `while` である。`range` は連続した整数を順に生成し、`while` は条件が成り立つ間くり返す。次のように記述する。

```

1 for i in range(5):
2     print(i)
3
4 count = 0
5 while count < 3:
6     print(count)
7     count += 1

```

`range(5)` は 0 から 4 までを返す。ファイル番号やビン番号のような添字処理では便利である。一方、`while` は終了条件を自分で管理する必要があるので、無限ループにしないよう注

意が必要である。時刻順に読み進めて、条件を満たす間だけ比較するような処理では `while` が自然な場合もある。

4.3.2.2 `break`, `continue`, `else`

反復処理では、途中で打ち切ったり、ある条件だけ飛ばしたりしたくなる。Python では `break` と `continue` がそのために使える。

```
1 for value in values:
2     if value < 0:
3         continue
4     if value > threshold:
5         break
6     print(value)
```

`continue` はその回だけを飛ばし、`break` はループ全体を終了する。探索範囲を打ち切る処理では特に重要である。さらに Python には `for ... else` という構文もあり、`break` せずに最後まで回り切ったときだけ `else` 節が実行される。頻出ではないが、見かけても驚かないようにしておくといよい。

4.3.2.3 内包表記

短い変換や簡単なフィルタであれば、内包表記を使うとすっきりと構築できる。

```
1 values = [1, 2, 3, 4, 5]
2 squares = [x * x for x in values]
3 large_values = [x for x in values if x >= 3]
```

内包表記は便利だが、何段階もの条件や複雑な変換を 1 行に押し込むと読みにくくなる。初学者のうちは、読みやすさを失わない範囲で使う方がよい。長くなりそうなら、普通の `for` 文や補助関数へ戻した方が親切である。

4.4 関数とモジュール

4.4.1 関数を分ける理由

同じ処理を何度も書かないためだけでなく、処理の意味を分けるためにも関数は重要である。一例として、時刻を表す文字列から秒数を計算する関数を考える。

```
1 def hhmss_to_seconds(hhmss):
2     hour = int(hhmss[0:2])
3     minute = int(hhmss[2:4])
4     second = int(hhmss[4:6])
5     return hour * 3600 + minute * 60 + second
```

この関数は短い、「文字列で与えられた時刻を秒へ変換する」という役割が明確である。解析コードでは、このような小さな関数が積み重なって全体の読みやすさを作る。

関数を切り出す利点は再利用だけではない。入力は何で、出力が何かをはっきりさせることで、テストしやすくなる。短い補助関数ほど後回しにされがちだが、解析の正しさはこうした小さな部品の積み重ねで決まることが多い。

4.4.1.1 関数の引数

関数を書くときは、引数の意味をはっきりさせることが重要である。Python では位置引数だけでなく、デフォルト値付き引数やキーワード引数も使える。

```
1 def histogram_path(name, suffix=".pdf"):
2     return f"{name}{suffix}"
3
4 print(histogram_path("value_hist"))
5 print(histogram_path("value_hist", suffix=".png"))
```

デフォルト引数を使うと、よく使う設定を省略できる一方で、必要なら上書きできる。コマンドライン引数と同じで、解析コードの柔軟性は「固定値をどこに置くか」で決まることが多い。関数でも同じ発想が使える。

ただし、可変オブジェクトをデフォルト引数に置くと予想外の共有が起きる。この罫は Python 公式チュートリアル [1] でも強調されている典型例である。初学者の段階では、リストや辞書をデフォルトにしたくなったら一度立ち止まった方がよい。以下の書き方は避けるべきである。

```
1 def bad_append(value, buffer=[]):
2     buffer.append(value)
3     return buffer
```

この例では、`buffer` が呼び出しのたびに新しく作られるわけではない。そのため、前回の状態が次回にも残る。安全に書くなら `None` を使って関数内部で初期化の方がよい。初学者がつまづきやすいので、早めに知っておく価値が高い。

4.4.1.2 モジュールと `import`

別ファイルに書かれた関数を使うには次のように `import` する。

```
1 import math
2 import glob
3 import argparse
```

Python の解析では、標準ライブラリと外部ライブラリを組み合わせる。どの名前がどこから来たものかを意識して読む習慣を付けておくと、大きなコードも追いやすくなる。

特に、同じ名前に見えても標準ライブラリと外部ライブラリで役割が大きく異なることがある。インポート文は単なるおまじないではなく、そのファイルが何に依存しているかを示す地図でもある。ここまでは既存のライブラリを読み込む話だったが、同じ仕組みで自分が書いたファイルも読み込める。

4.4.1.3 自作モジュールへ分ける

解析が少し大きくなると、1 つのファイルへ全部を書くのはすぐに苦しくなる。よく使う関数や定数は別ファイルへ分け、モジュールとして読み込む方が見通しが良い。たとえば次のようなファイル構造で分けるとする。

```
analysis_project/  
|-- constants.py  
|-- physics.py  
`-- main.py
```

この構成にすると、physics.py に書いた関数を main.py から読み込める。次の例は、その最小形である。

```
1 # physics.py  
2 import numpy as np  
3  
4 def deg_to_rad(degrees):  
5     return degrees * np.pi / 180.0  
6  
7  
8 # main.py  
9 import physics  
10  
11 theta = physics.deg_to_rad(45.0)
```

この形にしておくと、座標変換、時刻変換、定数定義のような再利用しやすい処理を 1 か所へまとめられる。ファイルを分けると、「他のファイルから読み込んで使う」場面が自然に増える。逆に、そのファイル自身を直接実行して動作確認したいこともある。次に示す `if __name__ == "__main__":` は、その 2 つを切り分けるための書き方である。

4.4.1.4 スクリプトとして実行する

Python ファイルは、他のファイルから読み込まれることもあれば、直接実行されることもある。その違いを区別する基本形が次である。

```
1 def main():  
2     print("run")  
3  
4 if __name__ == "__main__":  
5     main()
```

この形にしておくと、モジュールとして読み込んだときには関数だけを使え、直接実行したときだけ本体が動く。後半の解析スクリプトでも、この形を基本として採用すると整理しやすい。

4.5 保守と実践的な書き方

4.5.1 エラーは失敗ではなく情報である

初心者のうちは、エラーメッセージが出るとそこで止まってしまいがちである。しかし、トレースバックは「どこで何が起きたか」を教えてくれる重要な情報である。

たとえば `FileNotFoundError` ならファイルパスが違うかもしれないし、`ValueError` なら想定した形式でデータを読めていないかもしれない。大切なのは、英語の文章全体を恐れるのではなく、例外名と最後の数行を見ることである。

解析では、最初から一度もエラーを出さずに進む方が珍しい。問題はエラーが出ることでなく、エラーを無視したり、意味を確かめずに場当たりの直したりすることである。例外名、発生行、直前に読んでいたデータの形を確認する習慣を付けておくと、修正の質が安定する。

4.5.1.1 docstring とヘルプ

関数やモジュールの役割を後から思い出せるようにするには、短い説明を書いておくといい。Python では次のように、関数定義の直後に文字列を書くと docstring（ドキュメント文字列）になる。

```
1 def read_table(path):
2     """空白区切りの表を読み、各行を辞書として返す。"""
3     ...
```

`help(read_table)` を実行すると、この説明を後から確認できる。コメントと同じように見えるが、実行時にも参照できる点が異なる。解析コードが増えてくると、どの関数が何を返すのかを書いておくことの価値が大きくなる。

短い関数なら 1 行の docstring で十分だが、少し長い処理では複数行にして、少なくとも「何をするか」「主要な引数」「返り値」「起こり得る例外」を書いておく読みやすい。たとえば次のような形である。

```
1 def read_table(path):
2     """空白区切りの表を読み込む。
3
4     Args:
5         path: 入力ファイルへのパス。
6
7     Returns:
8         各行を辞書として格納したリスト。
9
10    Raises:
11        FileNotFoundError: ファイルが存在しない場合。
12    """
```

流儀はいくつかあるが、最初の 1 行を「要約」、その後ろを詳細と考えると整理しやすい。特に、他人が `help()` やエディタ上の補完で関数を読むときは、最初の 1 行がそのまま関数の説明になることが多い。

4.5.1.2 名前付けと PEP 8

Python には PEP 8 という代表的なスタイルガイドがある。すべてを最初から覚える必要はないが、少なくとも変数名、関数名、空白の入れ方を次のようにそろえるだけでコードはかなり読みやすくなる。

```
1 MAX_EVENTS = 1000
2
3 def read_event_table(path):
4     total_count = 0
5     ...
```

一般には、変数名や関数名は `snake_case`、定数は大文字の `UPPER_CASE` にすることが多い。さらに、演算子の前後に空白を入れる、1 行を詰め込みすぎない、といった基本だけでも効果は大きい。スタイルの統一は飾りではなく、バグを見つけやすくするための道具だと考える方が実践的である。

PEP 8 を最初から全部暗記する必要はないが、少なくとも次の規則は守る価値が高い。

- インデントはタブではなく 4 スペースにする
- 関数名や変数名は `snake_case`、クラス名は `CamelCase`、定数は `UPPER_CASE` にする
- 演算子 (`=`, `+`, `-` など) やカンマの後ろには空白を入れる
- トップレベルの関数定義やクラス定義の間には空行を入れて、かたまりを分ける
- 1 行を長くしすぎない。PEP 8 では 79 文字が目安だが、少なくとも横に流れすぎて読みにくい行は分割する
- `import` は標準ライブラリ、外部ライブラリ、自作モジュールの順にまとめる

この程度でも、見た目のばらつきはかなり減る。重要なのは「絶対に厳密であること」より、「同じプロジェクトの中で揃っていること」である。

4.5.1.3 マジックナンバーを避ける

コード中に 250 や 3600 のような数値が突然現れると、その値が何を表すのかを読む側が推測しなければならない。このような、説明なしに裸で現れる数値をマジックナンバーと呼ぶ。これを避けるには、次のように意味のある名前を持たせる。

```
1 NS_PER_SECOND = 1_000_000_000
2 COINCIDENCE_WINDOW_NS = 250
3
4 dt_ns = second_diff * NS_PER_SECOND + ns_diff
```

```
5 is_coincident = abs(dt_ns) <= COINCIDENCE_WINDOW_NS
```

250 をそのまま書くより、COINCIDENCE_WINDOW_NS と書いた方が意味が明確である。3600 なら SECONDS_PER_HOUR、86400 なら SECONDS_PER_DAY といった具合に、意味を名前へ出した方が読みやすい。

ただし、どんな値でもコード内定数にすればよいわけではない。物理定数や単位換算のように定義として固定したい値はコード内の定数に向いている。一方で、入力パス、出力先、閾値、利用する検出器番号のように実行条件として変わり得る値は、コマンドライン引数や設定ファイルへ出した方がよい。値の置き場所そのものが設計である、という意識を持つことが重要である。

4.5.1.4 例外処理

エラーは読むべき情報だが、予想される失敗を自分で受け止めたい場面もある。例えば、1 行だけ形式が壊れているデータを見つけて記録し、解析全体は続けたいことがある。そのときに使うのが次のような try と except の組み合わせである。

```
1 try:
2     value = float(text)
3 except ValueError:
4     print("数値へ変換できませんでした")
```

ただし、何でも except: で受けてしまうと、本来止まるべきバグまで隠してしまう。どの例外を受けるのかを明示し、何を記録して、何を諦めて、何を継続するのかを自分で決めることが重要である。

第 5 章 入出力とファイル

この章では、Python でファイルを開き、複数のファイルを集め、1 行ずつ読みながら値へ変換する基本を扱う。ここで重要なのは、特定のデータ形式に慣れることではなく、入力を見て必要な情報を取り出す流れを理解することである。

5.1 テキストファイルの入出力と探索

5.1.1 ファイルを開き、読み書きの基本を押さえる

Python でテキストファイルを読むときの基本は `open` である。さらに `with` を組み合わせると、読み終えた後に自動でファイルが閉じられる。テキストファイルを 1 行ずつ読む基本形は次のようになる。

```
1 with open(path, "r", encoding="utf-8") as f:
2     for line in f:
3         print(line.rstrip())
```

`read` でまとめて読む方法もあるが、大きなファイルでは 1 行ずつ読む方が安全である。まずはこの形に慣れておくとよい。

このとき、`line` には改行文字が含まれている点にも注意したい。表示だけなら `rstrip` で末尾を落とせば十分だが、区切り文字を扱うときには改行の有無が結果に影響することがある。テキスト処理では、見えていない文字を意識することが重要である。

5.1.1.1 `pathlib` でパスを扱う

ファイルパスを単なる文字列として扱うこともできるが、Python では次のように `pathlib.Path` を使うと見通しが良くなる。

```
1 from pathlib import Path
2
3 root = Path("data")
4 path = root / "2026" / "04" / "sample.txt"
5
6 print(path.exists())
7 print(path.name)
```

`/` 演算子でパスをつなげられるため、文字列連結より読みやすい。ファイル名だけ取りたい、親ディレクトリへ戻りたい、拡張子を変えたい、といった操作も自然に書ける。解析コードでは、パス操作を文字列で済ませるより安全なことが多い。`pathlib` を用いて新しく出力先を作る処理は次のようになる。

```

1 outdir = Path("output")
2 outdir.mkdir(parents=True, exist_ok=True)
3 outfile = outdir / "summary.txt"

```

ディレクトリがなければ作る、すでにあってもエラーにしない、という処理は解析コードで非常によく使う。こうした定型操作を安全に書ける点でも `pathlib` は便利である。

5.1.1.2 ファイルオブジェクトのメソッド

ファイルを開いた後には、`read`、`readline`、`write` などのメソッドが使える。Python 公式チュートリアル [1] でも強調されているように、何をどの粒度で読むかでコードの性格が変わる。たとえば次のように記述する。

```

1 with open(path, "r", encoding="utf-8") as f:
2     first_line = f.readline()
3
4 with open("out.txt", "w", encoding="utf-8") as f:
5     f.write("hello\n")

```

`readline` は 1 行だけ確認したいとき、`write` は整形済み文字列をそのまま出したいときに便利である。大きな入力全体を一気に読む前に、最初の数行だけ確認するという使い方もよく行う。

5.1.1.3 複数のファイルを集める

ログや測定結果が複数ファイルに分かれている場合は、まず対象ファイルの一覧を作る必要がある。Python では `glob.glob` がよく使われる。基本的な探索方法は次の通りである。

```

1 import glob
2
3 paths = sorted(glob.glob("data/**/*.txt", recursive=True))

```

`glob.glob` はシェルのワイルドカードに近い感覚で使える。複数ファイルを扱う処理では、最初に見つけた件数や先頭数件のパスを表示して確認する習慣を付けておくとよい。

また、順序が重要な処理では `sorted` を付ける意味も大きい。ファイル探索の結果が環境依存の順序で返ると、処理結果やログの見え方が毎回変わり、デバッグしにくくなる。時系列や連番を扱う場面では、最初に順序を固定する方が安全である。

5.2 文字列データの解析と整形

5.2.1 文字列を値へ変換し、結果を書き出す

多くの表形式データは、1 行の中に複数の列が並ぶ形で保存されている。テキストとして読んだだけでは、まだ単なる文字列である。そこから列に分け、整数や浮動小数点数へ変換して初めて解析に使える。たとえば空白区切りの 1 行を分解する例は次のようになる。

```

1 line = "17_2026-04-04_12:34:56_15.2_OK"
2 columns = line.split()
3
4 record_id = int(columns[0])
5 date_text = columns[1]
6 time_text = columns[2]
7 value = float(columns[3])
8 status = columns[4]

```

ここで重要なのは、どの列をどの型で持つかを自分で決めることである。後で pandas を使う場合でも、この感覚を持っていると列の意味を見失いにくい。

文字列をどの段階で数値へ変換するかも設計の一部である。すぐ数値化してよい列もあれば、元の文字列表現を残しておいた方が確認しやすい列もある。読みやすい解析コードでは、どこでどの変換を行ったかが追えるようになっている。

5.2.1.1 ファイルへ書き出す

解析では、読むだけでなく結果を書き出す場面も多い。最も単純には、テキストとして 1 行ずつ書いていけばよい。

```

1 lines = ["run_id,count,mean", "1_120_3.42", "2_118_3.37"]
2
3 with open("summary.txt", "w", encoding="utf-8") as f:
4     for line in lines:
5         f.write(line + "\n")

```

"w" は新しく書くモード、"a" は追記モードである。既存ファイルを上書きしてよいのか、別名で保存すべきかは、実験ノートやレポート再現性にも関わる。出力ファイル名の設計は、解析の一部として考えるべきである。

5.2.1.2 文字列整形

結果を画面やファイルへ出すときには、数値を読みやすく整えることも大切である。Python では、以下のような f-string（フォーマット済み文字列リテラル）が最もよく使われる。

```

1 mean = 3.14159
2 sigma = 0.27182
3
4 text = f"mean={mean:.3f}, sigma={sigma:.3f}"
5 print(text)

```

`:.3f` は小数点以下 3 桁で表示するという意味である。解析結果をレポートへ貼る前に、このような整形で見やすくしておくと、図や本文との対応が取りやすい。

Python 公式チュートリアル [1] では、f-string のほかに `str.format` や手動整形も紹介されている。現在の実務では f-string が最も使いやすいが、古いコードを読むと別の書き方が出

てくることもある。複数の流儀があることは知っておきたい。

5.3 オブジェクトと構造化データの保存

5.3.1 JSON と Pickle / PKL

結果や設定を構造化して保存したいときは、JSON が便利である。テキストとして読めて、Python では標準ライブラリ `json` ですぐ扱える。基本的な保存と読み込みの記述は次のように行う。

```
1 import json
2
3 config = {"threshold": 3.5, "bins": 40}
4
5 with open("config.json", "w", encoding="utf-8") as f:
6     json.dump(config, f, indent=2)
7
8 with open("config.json", "r", encoding="utf-8") as f:
9     loaded_config = json.load(f)
```

大きな表形式データの本体を JSON で持つのは効率が悪いことも多いが、設定や要約結果を保存するには便利である。人間が読める形式と、Python が簡単に読める形式を両立しやすい。

5.3.1.1 Pickle / PKL

Python オブジェクトをそのまま保存したいときは、`pickle` もよく使われる。拡張子は慣習的に `.pkl` を使うことが多い。辞書、リスト、NumPy 配列、学習済みモデル、中間集計結果などを素早く退避するには便利である。処理の記述例を下に示す。

```
1 import pickle
2
3 result = {"mean": 3.14, "sigma": 0.27, "values": [1.0, 2.0, 3.0]}
4
5 with open("result.pkl", "wb") as f:
6     pickle.dump(result, f)
7
8 with open("result.pkl", "rb") as f:
9     loaded_result = pickle.load(f)
```

"wb" と "rb" の b はバイナリモードを意味する。JSON と違って人間には読めないが、Python では構造を保ったまま簡単に保存できる。ただし、`pickle` は Python 専用であり、他言語との受け渡しには向かない。また、信頼できない `.pkl` ファイルを `load` してはならない。共有用の正式な保存形式というより、自分の解析途中結果を手早く再利用するためのローカル形式と考える方が安全である。

ここでいう「危険」とは、単に壊れたファイルを読んでエラーになるという意味ではない。`pickle.load()` は、ファイルの内容に従って Python オブジェクトを復元する過程で任意のコード実行につながる可能性がある。したがって、メール添付や外部配布物として受け取った不明な `.pkl` を気軽に開いてはならない。自分で保存したもの、あるいは十分に信頼できる相手が生成したものだけを読む、という運用が必要である。

5.4 発展的なトピック

5.4.1 日付と時刻を数値として扱う

日付や時刻を含むデータでは、文字列のまま扱うより、比較や計算がしやすい形へ変換した方がよい。標準ライブラリの `datetime` は、そのための基本的な道具となる。実際のコードは次のようになる。

```
1 from datetime import datetime
2
3 text = "2026-04-04_12:34:56.123456"
4 dt = datetime.strptime(text, "%Y-%m-%d_%H:%M:%S.%f")
5 unix_time = dt.timestamp()
```

秒単位の差を見たいのか、より細かい時間差を見たいのかによって、どの単位で値を持つかは変わる。ただし、どの表現を選んでも、一貫して使うことが大切である。

`datetime` は便利だが、何でも `datetime` オブジェクトのまま持てばよいわけではない。差分計算を大量に繰り返すなら、途中で秒やナノ秒の数値へ変換した方が扱いやすいことも多い。人間に読みやすい表現と計算しやすい表現を分けて考えることが重要である。

さらに、タイムゾーンが関わるデータでは、見かけの時刻だけを比較すると誤解が生じる。研究用のログや観測データでは UTC を使うことが多いが、どの基準時刻を採用しているかを最初に確認する習慣を付けたい。

5.4.2 保存形式について: ベストプラクティスへのステップ

データをファイルに保存・読み出しする際、多くの初学者は何も考えずに `.csv` (CSV 形式) を使い続ける。しかし、データが数百万行に達すると、処理時間の大半が「ファイルの準備」に消えるようになる。

5.4.2.1 Step 1: テキスト形式 (CSV, JSON) の限界

テキスト形式は文字コード (例: UTF-8) を使って人間がそのまま読める形で保存する。CSV/TSV は非常に汎用性が高く、C++ や R、Excel など、どの言語でも読めるのが強みである。

問題点: コンピュータはディスク上の文字列 (例: 「1.2345」という 6 文字の羅列) を、計算に使える実数値にいちいち変換 (パース) しなければならない。データ量が数 GB に及ぶ

と、この「文字列から実数への変換処理」だけで何十分も待たされることになる。

5.4.2.2 Step 2: バイナリ形式への移行と、どれを選ぶかの判断基準

メモリ上の数値を人間には読めない生のバイト列としてそのままファイルに記録する「バイナリ形式」を使えば、読み込み時間は一瞬（ディスクの転送速度の限界）になる。

しかし、バイナリ形式にはいくつかデファクトスタンダードがあり、目的に合わせて選ばなければならない。

- **NPY / NPZ (NumPy 標準)**: NumPy だけで完結する小さな解析なら最も手軽。ただし、Python・NumPy 以外（C++や R など）からは読みづらく使い捨てになりがちである。
- **Pickle / PKL**: Python オブジェクトをそのまま保存できるため、中間結果や学習済みモデルの一時保存に便利である。ただし、Python 以外ではほぼ使えず、信頼できないファイルを読み込んではならない。共同研究の交換形式というより、ローカルな作業用キャッシュとして使うべき形式である。
- **HDF5**: 大規模な数値データをディレクトリの階層構造のように管理する形式。C/C++ (Geant4 など)、Fortran、R 等さまざまな言語の公式ライブラリが存在する。他のグループや別言語のプログラムにデータを渡す場合は、HDF5 を選ぶのが最も安全で汎用性が高い。
- **Parquet**: 列指向のバイナリフォーマット。後述する Pandas や Polars などの DataFrame をそのまま保存でき、特定の列だけを高速に読み込むことが得意。Hadoop や Spark などのビッグデータエコシステムでも標準的である。分析チーム内での巨大データのやり取りにはこれが現在の最強の選択肢である。

解析の初期段階ではデータの中身を目視確認するために CSV を使うことが多いが、大量のイベントデータを何回も読み直す段階になったら、**必ず最初に Parquet や HDF5 への変換スクリプトを書いてバイナリ化することが全体を高速化する第一歩である**。.pkl はその補助として、途中結果や作業用キャッシュを手元で素早く保存する用途に向いている。

Parquet は「保存形式」の名前であり、pyarrow はその形式を pandas から読み書きする代表的な実装の一つである。したがって、「Parquet を使う」と「pyarrow を入れる」は同じ話ではない。多くの環境では `read_parquet()` や `to_parquet()` の背後で pyarrow が使われるため、これが入っていないと Parquet を扱えないことがある。

第 6 章 NumPy による数値計算

NumPy は、Python で数値配列を扱うときの基本となるライブラリである。本章では、まず配列計算の考え方と ndarray の基本を確認し、その後で配列生成、演算、形の変更、集計、ブロードキャストを順に扱う。後半では、初学者がつまづきやすい点を整理し、最後に解析でどのように使うかを具体例で見る。

6.1 NumPy の考え方

6.1.1 配列計算の基本概念

Python のリストは柔軟だが、数値配列として大量の値を処理するには向いていないことがある。NumPy は、同じ型の数値を多次元配列 ndarray として持ち、配列全体へまとめて演算をかけるためのライブラリである。最も基本的な NumPy 配列の定義と差分計算の例を示す。

```
1 import numpy as np
2
3 times = np.array([10, 15, 23, 41], dtype=np.int64)
4 deltas = times[1:] - times[:-1]
```

このような差分計算は、Python の for ループでも書けるが、NumPy では配列全体に対してまとめて書ける。後の図 13.1 に示すように、この差は速度にも大きく効く。

数式で書けば、これは隣り合う時刻の差

$$\Delta t_i = t_{i+1} - t_i$$

をまとめて計算していることに対応する。NumPy を使うと、このような「添字付きの式」を配列全体に対してそのまま書きやすい。

ここで重要なのは、NumPy が単に「速いリスト」ではないという点である。NumPy 配列は、同じ型の数値をまとめて持ち、一つの式で大量の要素を処理するための道具である。したがって、設計の発想も「1 要素ずつ何をするか」から「配列全体にどのような変換をかけるか」へ変わる。

6.1.2 ndarray と属性

NumPy の中心は ndarray である。配列を作ったら、まず shape、ndim、dtype を確認する癖を付けると混乱しにくい。

```
1 import numpy as np
2
```

```

3 a = np.array([[1.0, 2.0, 3.0],
4               [4.0, 5.0, 6.0]])
5
6 print(a.shape)      # (2, 3)
7 print(a.ndim)       # 2
8 print(a.dtype)      # float64
9 print(a.size)       # 6
10 print(a.itemsize)  # 8

```

shape は各軸の長さ、ndim は次元数、dtype は要素型、size は総要素数、itemsize は 1 要素あたりのバイト数である。NumPy の初学者は「配列の中身」ばかり見がちだが、実際には shape と dtype を見れば、多くの不具合の原因を早い段階で絞り込める。

```

(2, 3)
2
float64
6
8

```

出力を見れば、この配列が「2 行 3 列の float64 配列」であることがすぐ分かる。NumPy のトラブルの多くは、この 5 行のどれかを見れば原因に近づける。

6.1.3 Python, C, NumPy でのデータ型の違い

Python 標準の変数は型を自動で管理して非常に自由度が高いが、NumPy を用いた数値計算では逆に「データサイズを固定した C 言語レベルの厳密な型」を意識することが重要になる。代表的な型の対応を表 6.1 に示す。

表 6.1 Python, NumPy, C 言語での代表的な数値型の対応

分類	C 言語の型	Python の標準型	NumPy の型 (dtype)
整数型	int, long	int (桁数上限なし)	int32, int64
単精度浮動 小数	float (32 ビット)	(標準では存在せず)	float32
倍精度浮動 小数	double (64 ビット)	float	float64
論理型	bool	bool	bool_

C 言語では、扱う変数が「メモリ空間を何ビットの箱として占有するか」を明示的に宣言しなければならない（例えば単精度の float と倍精度の double）。対して Python の標準型である int は桁数に実質的な上限がなく、float は背後で C 言語の倍精度（double 相当の 64 ビット）として確保される。しかし、Python の標準変数は単なるメモリ上の数値だけでなく、「この変数は現在のどこから参照されているか」「これはいま何の型のオブジェクトか」といった管理情報を余分にひとまとめにして抱え込んでいるため、単純な数値演算の際には非常にオーバーヘッドが大きくなる。

これに対して NumPy では、内部構造として C 言語の「純粋な数値の固定長な配列（ポインタからの連続オフセット）」と同じ状態をメモリ上に展開する。これにより、Python の無駄な管理部分を一切通さず、CPU や C 言語レベルの演算回路にデータを配列ごとそのまま流し込んで一気に処理（ベクタライズ計算）させることが可能になっている。

なお、型の使い分けという観点では、現代のマシンにおける一般的な処理で、あえて単精度の float32（C 言語における float）を使う場面は少なくなっている。現在でも GPU メモリの容量やバンド幅が逼迫する機械学習などの分野では単精度や半精度（16 ビット）が積極的に効果を発揮するが、通常の科学技術計算やデータ解析を行う現代のパーソナルコンピュータでは計算誤差のリスクが少ない倍精度（float64 = double）を標準として用いるのが主流であり安全である。特別なメモリ制約や速度要件がない限り、標準の float64 をそのまま使用することで、無用な丸め誤差や桁落ちなどの問題を回避できる。

6.1.4 NumPy が速くなりやすい理由

NumPy が速くなりやすい理由は、単に「ライブラリだから」ではない。主な理由は三つある。

1. 数値を連続したメモリにまとめて持てること
2. Python レベルのループを減らせること
3. 内部で低レベルに最適化された処理を使えること

特に重要なのは、Python で 1 要素ずつ処理する回数が減ることである。大きなデータでは、この差がそのまま処理時間の差になる。

もう一つの利点は、式がそのまま数学的な記述に近づくことである。たとえば差分、閾値判定、正規化、平均、分散といった操作は、配列演算で書いた方が意図が明確になることが多い。読みやすさと速度が同時に改善する場面は少なくない。

6.2 最小限のコード例

6.2.1 配列を作る

NumPy では、最初に「どの形の配列を、どの型で作るのか」を決める。np.array 以外にも、一定値で埋める、等間隔の値を作る、といった入口が多い。

```
1 a = np.array([1, 2, 3], dtype=np.float64)
2 zeros = np.zeros((2, 3))
3 ones = np.ones((2, 3))
4 tmp = np.empty((2, 3))
5 grid = np.arange(0, 10, 2)
6 x = np.linspace(0.0, 1.0, 5)
7
8 print(a)
```

```

9 print(zeros.shape)
10 print(grid)
11 print(x)

[1. 2. 3.]
(2, 3)
[0 2 4 6 8]
[0.  0.25 0.5  0.75 1. ]

```

`np.array` は既存の Python リストなどから配列を作る。`np.zeros` と `np.ones` は初期値が明確なので安全である。`np.arange` は整数刻みの列、`np.linspace` は区間を等分した実数列を作る。解析では、ビン中心、時間軸、周波数軸を作る場面で `linspace` をよく使う。

`zeros.shape` が (2, 3) なので、`zeros` と `ones` は 2 行 3 列の配列である。`grid` は 0 から 8 まで 2 刻み、`x` は 0 から 1 を 5 点で等分した座標列である。`np.empty` はメモリだけ確保して値を初期化しないため高速だが、初期値は未定である。後で必ず全要素を上書きする場合にだけ使う方が安全である。

6.2.2 よく使う操作

解析でよく使う NumPy の操作として、条件に合う要素だけを取り出すフィルタ、順序をそろえるソート、隣り合う要素の差を取る差分、分布を数えるヒストグラムがある。これらは別々の操作に見えるが、解析ではまとめて使うことが多い。

```

1 times = np.array([41, 10, 23, 15, 42])
2
3 selected = times[times > 20]
4 sorted_times = np.sort(times)
5 deltas = np.diff(sorted_times)
6 hist, edges = np.histogram(times, bins=[0, 20, 40, 60])
7
8 print(selected)
9 print(sorted_times)
10 print(deltas)
11 print(hist)
12 print(edges)

[41 23 42]
[10 15 23 41 42]
[ 5  8 18  1]
[2 1 2]
[ 0 20 40 60]

```

この例で行っていることは次のとおりである。

- フィルタ: `times > 20` は `[True, False, True, False, True]` に相当する条件配列を作り、その位置にある要素だけを `selected` として取り出す。

- ソート: `np.sort(times)` は値を昇順に並べる。観測時刻やエネルギーのように順序が意味を持つ量では、後続の処理の前に並べ替えることが多い。
- 差分: `np.diff(sorted_times)` は隣り合う値の差を返す。返る配列の長さは元の配列より 1 つ短い。イベント時刻が昇順に並んでいれば、これは到着間隔として読める。
- ヒストグラム: `np.histogram(times, bins=[0, 20, 40, 60])` は、区間ごとの個数を `hist`、区間境界を `edges` として返す。この例では `[0, 20)` に 2 個、`[20, 40)` に 1 個、`[40, 60]` に 2 個入っている。

ブール配列によるフィルタは NumPy の基本である。条件式の結果をそのまま添字にできるので、`(times > 20) & (times < 40)` のような複数条件も簡潔に書ける。一方で、差分は順序に依存するので、時刻列のようなデータでは `np.diff(times)` をいきなり使わず、まずソートが必要かどうかを確認した方が安全である。

ヒストグラムは、ビン境界 $b_0, b_1, \dots, b_n$ に対して

$$h_k = \#\{t_i \mid b_k \leq t_i < b_{k+1}\}$$

を数える操作と見なせる。ただし、NumPy では最後のビンだけ右端も含むので、最終区間は $[b_{n-1}, b_n]$ と読めばよい。

6.2.3 要素ごとの演算とユニバーサル関数

NumPy の演算子や多くの関数は、原則として要素ごとに働く。NumPy の公式ドキュメント [6] では、`exp`、`sqrt`、`sin` のような要素ごと関数をユニバーサル関数 (ufunc) と呼んでいる。

```
1 a = np.array([1.0, 2.0, 3.0])
2 b = np.array([10.0, 20.0, 30.0])
3
4 print(a + b)
5 print(a * 2)
6 print(a ** 2)
7 print(np.exp(a))
8 print(np.sqrt(a))
```

```
[11. 22. 33.]
[2.  4.  6.]
[1.  4.  9.]
[ 2.71828183  7.3890561 20.08553692]
[1.          1.41421356 1.73205081]
```

配列どうしの四則演算は、形がそろっていれば要素ごとに実行される。`np.exp(a)` や `np.sqrt(a)` も同様である。関数が 1 要素に対して何をするかを知っていれば、その関数が配列全体へどう作用するかも追やすい。

たとえば、配列 $a = (a_i)$ 、 $b = (b_i)$ に対しては

$$(a + b)_i = a_i + b_i, \quad (a^2)_i = a_i^2, \quad (\exp(a))_i = e^{a_i}$$

のように、各要素へ同じ規則が適用されると考えればよい。

6.2.4 集計と axis

NumPy の集計関数は、配列全体に対しても、特定の軸ごとにも使える。axis の意味は初学者がつまづきやすいので、コードで確認するのがよい。

```
1 matrix = np.array([[1.0, 2.0, 3.0],
2                     [4.0, 5.0, 6.0]])
3
4 total = matrix.sum()
5 col_sum = matrix.sum(axis=0)
6 row_sum = matrix.sum(axis=1)
7 col_max = matrix.max(axis=0)
8
9 print(total)
10 print(col_sum)
11 print(row_sum)
12 print(col_max)
```

```
21.0
[5. 7. 9.]
[ 6. 15.]
[4. 5. 6.]
```

total は全要素の和である。axis=0 は「0 軸をつぶす」、すなわち各列ごとの集計になり、axis=1 は各行ごとの集計になる。言葉だけで覚えるより、「どの軸が消えて、何が残るか」を shape で確認する方が理解しやすい。

行列 $A = (a_{ij})$ に対しては、

$$(\text{col_sum})_j = \sum_i a_{ij}, \quad (\text{row_sum})_i = \sum_j a_{ij}$$

に対応する。つまり、axis=0 は列方向の和、axis=1 は行方向の和を返している。

6.2.5 添字、スライス、条件抽出

NumPy の添字は Python リストと似ているが、多次元配列とブール配列が自然に使える点が重要である。

```
1 times = np.array([10, 15, 23, 41, 42])
2 print(times[0])
3 print(times[-1])
4 print(times[1:4])
5 print(times[times > 20])
6
7 grid = np.arange(12).reshape(3, 4)
8 print(grid[1, 2])
9 print(grid[:, 1])
10 print(grid[1, :])
```

```
10
42
[15 23 41]
[23 41 42]
6
[1 5 9]
[4 5 6 7]
```

`times[1:4]` は 1 番目から 3 番目までを取り出す。`grid[:, 1]` は全行の 2 列目、`grid[1, :]` は 2 行目全体である。多次元配列に対して `for row in grid:` と書くと、最初の軸に沿って 1 行ずつ取り出される。反復自体はできるが、NumPy を使うなら、まず配列演算で書けないかを先に考える方が自然である。

6.2.6 形を変える

NumPy を使い始めたら、配列の `shape` を意識することが重要である。1 次元配列なのか、行列なのか、列ベクトルとして扱いたいのかで、同じ演算でも結果が変わる。

```
1 a = np.arange(12)
2 matrix = a.reshape(3, 4)
3 flat = matrix.ravel()
4 transposed = matrix.T
5 column = np.array([1.0, 2.0, 3.0])[:, None]
6
7 print(matrix.shape)
8 print(matrix)
9 print(flat)
10 print(transposed)
11 print(column.shape)
12 print(column)
```

```
(3, 4)
[[ 0  1  2  3]
 [ 4  5  6  7]
 [ 8  9 10 11]]
[ 0  1  2  3  4  5  6  7  8  9 10 11]
[[ 0  4  8]
 [ 1  5  9]
 [ 2  6 10]
 [ 3  7 11]]
(3, 1)
[[1.]
 [2.]
 [3.]]
```

`reshape` は形を変える。`ravel` は可能ならビューとして 1 次元へ潰す。`T` は転置である。`[:, None]` は新しい軸を 1 本追加し、1 次元配列を列ベクトルのように扱う書き方である。

後で述べるブロードキャストでは、この 1 本の軸追加が非常に重要になる。

6.2.7 配列をつなぐ、分ける

複数の配列をつないだり、1 つの配列を分割したりする操作もよく使う。特に、前処理済みデータを縦に積む、特徴量を列方向に並べる、といった場面が必要になる。

```
1 x = np.array([1, 2, 3])
2 y = np.array([4, 5, 6])
3
4 joined = np.concatenate([x, y])
5 stacked = np.stack([x, y], axis=0)
6
7 matrix = np.arange(12).reshape(3, 4)
8 left, right = np.split(matrix, 2, axis=1)
9
10 print(joined)
11 print(stacked.shape)
12 print(stacked)
13 print(left)
14 print(right)
```

```
[1 2 3 4 5 6]
(2, 3)
[[1 2 3]
 [4 5 6]]
[[0 1]
 [4 5]
 [8 9]]
[[ 2  3]
 [ 6  7]
 [10 11]]
```

`concatenate` は既存の軸に沿ってつなぐ。`stack` は新しい軸を追加して積む。`split` は指定した軸に沿って分割する。見た目が似ていても結果の `shape` は異なるので、実行後に必ず `shape` を見る方がよい。

6.2.8 形とブロードキャスト

NumPy では、配列の形状をそろえなくても、自動拡張の規則に従って演算できる場合がある。この規則をブロードキャストという。

```
1 x = np.array([1.0, 2.0, 3.0])
2 y = np.array([10.0, 20.0, 30.0])
3
4 z = x + y
5 matrix = x[:, None] + y[None, :]
```

後半の `matrix` では、1 次元配列を軸付きで広げることで、3 行 3 列の和の表を作っている。

る。こうした自動拡張の規則をブロードキャストという。最初は少し難しいが、二つの配列の全組合せを調べるような場面で非常に強力である。上記の操作によるブロードキャストの結果は次のようになる。

```
z =
[11. 22. 33.]

matrix =
[[11. 21. 31.]
 [12. 22. 32.]
 [13. 23. 33.]]
```

この結果から、 z は要素ごとの和、 $matrix$ は全組合せの表であることが分かる。便利ではあるが、配列サイズが大きいと一気にメモリを消費するので、実データでは常に形と大きさを見積もる必要がある。

数式で書けば、

$$z_i = x_i + y_i, \quad M_{ij} = x_i + y_j$$

である。後者の M_{ij} が、ブロードキャストによって作られる「全組合せの表」に対応している。

6.2.9 統計量とヒストグラム

NumPy には、平均、分散、最小値、最大値、ヒストグラムなど、解析の基本となる集計関数がそろっている。代表的な統計量とヒストグラムを計算する例を下に示す。

```
1 values = np.array([1.0, 2.0, 2.0, 3.0, 4.0])
2 mean = values.mean()
3 std = values.std(ddof=0)
4 hist, edges = np.histogram(values, bins=[0.0, 2.0, 4.0, 6.0])
5
6 print(f"mean={mean:.2f}")
7 print(f"std={std:.2f}")
8 print(hist)
9 print(edges)
```

`np.histogram` は図を描かずに分布だけを数えたいときに便利である。ビン境界 `edges` も同時に返るため、後で自分で曲線を重ねたり、複数データを比較したりしやすい。可視化と数え上げを分けて考えると、処理の見通しが良くなる。実際にこれらの統計量を出力した結果は次のようになる。

```
mean = 2.40
std = 1.02
[1 3 1]
[0. 2. 4. 6.]
```

この例では、 $[0, 2)$ に 1 個、 $[2, 4)$ に 3 個、 $[4, 6]$ に 1 個入っている。平均や標準偏差

だけでは分布の形は分からず、ヒストグラムだけでは条件間比較がしにくい。数値要約と分布表示を組み合わせる読むことが、データ解析では基本になる。

`values.mean()` と `values.std(ddof=0)` は、それぞれ

$$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i, \quad \sigma = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2}$$

を計算している。ここで `ddof=0` は、標本標準偏差ではなく母標準偏差の定義を使うという意味である。

6.3 よくある落とし穴

6.3.1 演算子の意味を取り違える

`*` は要素ごとの積であり、行列積ではない。行列積が欲しいときは `@` か `np.dot` を使う。

```
1 A = np.array([[1.0, 2.0],
2               [3.0, 4.0]])
3 B = np.array([[5.0, 6.0],
4               [7.0, 8.0]])
5
6 print(A * B)
7 print(A @ B)
```

この違いを理解せずに書くと、コードは動いているのに意味だけが間違ふ、という厄介な状態になる。特に線形代数や座標変換では注意が必要である。

6.3.2 axis と条件式

`axis` の意味は、初学者が最初に混乱しやすい箇所である。`axis=0` は列ごとの集計、`axis=1` は行ごとの集計になる。また、配列どうしの条件結合では `and` や `or` ではなく、`&` や `|` を使う。

```
1 matrix = np.array([[1, 2, 3],
2                    [4, 5, 6]])
3 print(matrix.sum(axis=0))
4 print(matrix.sum(axis=1))
5
6 times = np.array([10, 15, 23, 41, 42])
7 mask = (times > 10) & (times < 40)
8 print(mask)
9 print(times[mask])
```

```
[5 7 9]
[ 6 15]
[False  True  True False False]
[15 23]
```

`times > 10 & times < 40` のように括弧を省略すると、優先順位の違いで意図しない式になる。NumPy の条件式では「各比較を括弧で囲む」を基本にした方が安全である。

6.3.3 dtype と np.empty

NumPy では、混在した型を入れると配列全体の dtype が自動的に決まる。この挙動を意識していないと、数値計算のつもりが文字列配列になっていた、ということが起こる。

```
1 a = np.array([1, 2.5])
2 b = np.array([1, "2"])
3 tmp = np.empty(5)
4
5 print(a.dtype)
6 print(b.dtype.kind)
7 print(np.issubdtype(a.dtype, np.number))
8 print(np.issubdtype(b.dtype, np.number))
9 print(tmp.shape)
```

```
float64
U
True
False
(5,)
```

`a` は浮動小数点へそろえられる。これに対して `b` は `dtype.kind == "U"`、つまり Unicode 文字列の配列になっており、もはや数値計算用ではない。`tmp` は 0 で初期化されないので、値を見る前に必ず全要素を書き込む必要がある。配列生成直後に dtype と初期値の有無を確認することが重要である。

6.3.4 コピーとビュー

NumPy は便利だが、配列をむやみにコピーすると逆に重くなる。一方で、意図せずビューを通じて元配列を書き換えてしまうこともある。この違いを理解せずに値を書き換えると、意図しない副作用や余分なメモリ使用を招く。

```
1 a = np.arange(6)
2
3 view = a[1:4]
4 view[:] = -1
5
6 copy = a[[0, 2, 4]]
7 copy[:] = 99
8
9 safe = a.copy()
```

この例では、スライスで作った `view` は元の `a` とデータを共有するので、`view[:] = -1` とすると `a` も変わる。これに対して、整数配列やブール配列による取り出しは新しい配列を返すので、`copy[:] = 99` としても元の `a` は変わらない。`reshape` や `ravel` も可能ならビューを

返すため、「独立した配列が欲しい」ときは `copy()` を明示した方が安全である。

```
a after view = [ 0 -1 -1 -1  4  5]
copy          = [99 99 99]
safe          = [ 0 -1 -1 -1  4  5]
```

この出力では、`view` を書き換えた時点で元配列 `a` が変化しているのに対し、`copy` は独立していることが見て取れる。

6.3.5 浮動小数点数の比較

浮動小数点数の丸め誤差にも注意が必要である。理論上は等しいはずの値でも、計算手順によって最後の数桁がずれることがある。そのため、`a == b` のような直接比較より、許容誤差を設けた比較を使う方が安全ことが多い。

```
1 a = 0.1 + 0.2
2 print(a == 0.3)
3 print(np.isclose(a, 0.3))
```

```
False
True
```

6.4 解析へのつながり

6.4.1 解析で NumPy を使うときの視点

大規模データでは、型を適切に選ばないとメモリを無駄に使う。たとえば、識別子や時刻差なら `int64` が自然だが、カテゴリ番号が小さい範囲なら `int16` や `int32` でも十分なことがある。大規模データでは、この積み重ねが効いてくる。

また、平均や分散だけでなく、差分、閾値判定、並べ替え、ヒストグラムまで NumPy の中で一貫して処理できると、コードの往復が減り、解析の流れを追いやすくなる。

6.4.2 差分、ソート、ヒストグラム

解析では、まず時刻順に並べ、次に差分を取り、その後で条件を掛けて分布を見る、という流れがよく現れる。NumPy ではこの流れをほぼそのまま式として書ける。

```
1 order = np.argsort(times)
2 sorted_times = times[order]
3 deltas = np.diff(sorted_times)
4 mask = (deltas >= 0) & (deltas <= 250)
5 hist, edges = np.histogram(deltas[mask], bins=50)
6 peak_bin = hist.argmax()
```

`np.argsort` は並べ替え順の添字を返す。`np.diff` は隣接差分である。`hist.argmax()` は最も高いビンの位置を返す。イベント時刻、スペクトル、波形特徴量のいずれでも、この種の処

理は頻出である。

```
sorted_times = [10 15 23 41 42]
deltas       = [ 5  8 18  1]
peak_bin     = 0
```

6.4.3 線形代数の入口

NumPy は単なる配列操作だけでなく、線形代数の入口としても重要である。小規模な連立方程式や座標変換なら、まず NumPy の `linalg` を使うだけで十分なことが多い。

```
1 A = np.array([[1.0, 1.0],
2               [1.0, -1.0]])
3 b = np.array([3.0, 1.0])
4 x = np.linalg.solve(A, b)
```

校正係数の決定、座標変換、最小二乗法の前処理などでは、こうした線形代数の操作が自然に現れる。大規模で高度な最適化は後の SciPy 章で扱うが、入口は NumPy で十分に理解できる。

6.4.3.1 Python リストを用いた数値計算の限界

Python の標準リストは非常に柔軟であり、どんな型のものでも放り込める。しかしいざ大量の数値を計算しようとする、この「なんでも入る」という性質が最大のネックとなる。避けるべきリストを用いた数値計算の例を示す。

```
1 # 100万個のリストを作る
2 py_list = list(range(1000000))
3
4 # すべての要素を2倍にする。forループと内包表記が必要
5 doubled_list = [x * 2 for x in py_list]
```

一見普通に動くが、Python のリストは「あちこちに散らばっている多様なサイズの箱へのポインタ（地図）」の集まりである。CPU は一つの値を計算するたびに「この値は何型か」「どこに置かれているか」を確認しなければならない、絶望的に遅い。

6.4.3.2 NumPy のベクタライズ化

これに対し NumPy デイメンショナル配列 (`ndarray`) は、同じ型の数値 (`int64` や `float64` など) をメモリ上に「すき間なく一列に並べた団地」として構成される。型確認が不要で、C 言語レベルの一括演算回路が直結する。NumPy 配列へ変換してから一括計算するコードは次の通りである。

```
1 import numpy as np
2
3 # 1. リストから NumPy アレイへの変換 (メモリ上にきれいに並べ直す)
4 np_array = np.array(py_list)
5
```

```
6 # 2. アレイはベクトル演算が可能 (for文を書かなくても全要素を一気に計算できる)
7 doubled_array = np_array * 2
8
9 # 3. アレイからリストへ戻すことも可能だが、重いので通常は最後だけにする
10 back_to_list = doubled_array.tolist()
```

6.4.3.3 Pandas DataFrame との変換

後述する Pandas DataFrame は、この NumPy 配列を「列」として束ねた拡張版である。分析の途中で NumPy 独自の計算関数を使いたい場合、DataFrame を NumPy に戻すことができる。Pandas の DataFrame・Series と NumPy アレイを相互変換するには、主に次のように書く。

```
1 import pandas as pd
2
3 # NumPy アレイから pandas の DataFrame (二次元) に変換
4 df = pd.DataFrame(np_array, columns=["Value"])
5
6 # Pandas のデータから NumPy アレイに戻す
7 # \code{.to_numpy()} は背後で持っているC言語配列を直接取り出すため一瞬で終わる
8 values_array = df["Value"].to_numpy()
```

6.4.4 公式資料の使い方

NumPy の基礎を復習したいときは、NumPy quickstart [7] を併読すると整理しやすい。特に、配列生成、添字とスライス、shape の変更、ブロードキャスト、コピーとビューは、解析コードを書くたびに帰って確認したくなる項目である。本章では解析で困りやすい点を補って説明しているので、まず本章で全体像をつかみ、その後で API 名や細かな仕様を quickstart で確認する読み方がよい。

第 7 章 pandas による表形式データ解析

pandas は、行と列からなる表形式データを扱うための代表的なライブラリである。観測ログ、イベント一覧、校正表、集計結果のように「1 行が 1 件の記録」であるデータは、まず pandas の DataFrame として読むのが自然である。本章では、DataFrame の意味、最小限の操作、落とし穴、解析へのつながりを順に整理する。

7.1 pandas の考え方

7.1.1 Series と DataFrame

pandas の基本構造は Series と DataFrame である。Series はラベル付き 1 次元配列、DataFrame は列名付き 2 次元表である。NumPy の配列が「同じ型の値を高速に並べる道具」だとすれば、pandas は「列ごとに意味を持つデータをまとめて扱う道具」である。

```
1 import pandas as pd
2
3 events = pd.DataFrame(
4     {
5         "detector": ["A", "A", "B", "B"],
6         "time_ns": [1032, 1188, 1055, 1244],
7         "signal": [12.4, 10.1, 14.8, 9.7],
8         "valid": [True, True, False, True],
9     }
10 )
11
12 print(type(events).__name__)
13 print(events)
```

このコードを実行すると、次のような DataFrame が表示される。

	detector	time_ns	signal	valid
0	A	1032	12.4	True
1	A	1188	10.1	True
2	B	1055	14.8	False
3	B	1244	9.7	True

この表では、行番号 0, 1, 2, 3 は index、"detector" や "signal" は列名である。index は「行を識別する補助ラベル」であり、列名は「何の量なのか」を示す。初学者は中身の数値ばかり見がちだが、実際には列名と型を確認した方が理解は速い。

DataFrame の利点は、列ごとに意味を持たせながら、まとめて処理を書けることにある。

「何列目か」を覚える必要が減り、列名を通して処理の意味が見えやすくなる。特に、ファイル読み込み、列変換、フィルタ、集計、書き出しまでを一つの流れで扱える点は大きい。解析の途中で確認用の表を少し表示したいときにも便利である。

DataFrame の基本操作は、Python 公式チュートリアル の「データ構造」章に相当する考え方を、表形式へ拡張したものだと考えると理解しやすい。リストや辞書を知っていると、列名によるアクセスや行集合に対するフィルタの意味が見えやすい。

7.1.2 最初に見るべき情報

DataFrame を作ったり読んだりした直後は、まず `head()`、`shape`、`dtypes`、`info()` を見る癖を付けるとよい。

```
1 print(events.head())
2 print(events.shape)
3 print(events.dtypes)
```

この確認では、先頭数行、形、各列の型がまとめて分かる。出力は次の通りである。

```
detector  time_ns  signal  valid
0         A    1032    12.4   True
1         A    1188    10.1   True
2         B    1055    14.8  False
3         B    1244     9.7   True
(4, 4)
detector    object
time_ns      int64
signal      float64
valid        bool
dtype: object
```

`shape` は行数と列数、`dtypes` は各列の型である。ここで `signal` が `float64` なのか、`detector` が文字列列として読まれているのかを確かめるだけで、多くの不具合を早い段階で防げる。特に `object` は「文字列かもしれないし、型が混ざっているかもしれない」という合図なので、数値に見える列が `object` になっていたら注意が必要である。

7.1.3 index と列名の役割

pandas の操作は、整数位置だけでなくラベルでも書ける。これが NumPy との大きな違いである。

```
1 print(events["signal"])
2 print(events.loc[1:2, ["detector", "signal"]])
3 print(events.iloc[1:3, 0:2])
```

`events["signal"]` は列名による選択、`loc` はラベルによる選択、`iloc` は整数位置による選択である。pandas の indexing ガイド [11] でも、対話的な試行錯誤では `[]` が便利だが、整理されたコードでは `loc`、`iloc`、`at`、`iat` を意識することが勧められている。解析コードでは

「列名で取りたいのか」「何行目を取りたいのか」を曖昧にしない方が安全である。

7.1.4 pandas が速くなりやすい理由

pandas が速くなりやすいのは、列単位でデータを処理し、内部でベクトル化された操作を使えるからである。Python の辞書リストを 1 行ずつ回して書くより、列としてまとめて扱う方が速く、コードも短くなりやすい。

ただし、すべての場面で pandas が最適とは限らない。行ごとに複雑な条件分岐を大量に行う場合や、データ構造自体を細かく制御したい場合には、NumPy や自作構造の方が向くこともある。したがって、「とりあえず pandas を使う」よりも、「列として扱える問題かどうか」を考える方が重要である。表として整理できるなら pandas は強力だが、近傍探索や状態遷移のように行どうしの関係が複雑になると、別の設計の方が自然なこともある。

7.2 最小限のコード例

7.2.1 列選択と行抽出

最初に身に付けたいのは、必要な列だけを残し、条件に合う行だけを取り出す操作である。

```
1 selected = events[["detector", "signal"]]
2 valid_events = events.loc[events["valid"], :]
3 strong = events.loc[events["signal"] > 11.0, ["detector", "signal"]]
4
5 print(selected)
6 print(valid_events)
7 print(strong)
```

それぞれの変数にどの行と列が残ったかは、実際の出力を見ると追やすい。

```
detector  signal
0         A    12.4
1         A    10.1
2         B    14.8
3         B     9.7
detector  time_ns  signal  valid
0         A    1032    12.4   True
1         A    1188    10.1   True
3         B    1244     9.7   True
detector  signal
0         A    12.4
2         B    14.8
```

ブール配列で行を絞る操作は NumPy と似ているが、pandas では列名を介して意味を保ったまま書ける。events["signal"] > 11.0 の結果は行ごとの真偽値であり、それを loc に渡すと条件に合う行だけが残る。

7.2.2 列を追加する

解析では、元の列から比や差、フラグ列を作ることが多い。pandas では列全体に対する式として書くのが自然である。

```
1 events["signal_ratio"] = events["signal"] / events["signal"].mean()
2 events["is_late"] = events["time_ns"] > 1100
3
4 print(events)
```

列を追加すると、元の表へ新しい列が右側へ増える。出力は次のようになる。

	detector	time_ns	signal	valid	signal_ratio	is_late
0	A	1032	12.4	True	1.058874	False
1	A	1188	10.1	True	0.862202	True
2	B	1055	14.8	False	1.263652	False
3	B	1244	9.7	True	0.827111	True

assign() を使うと、途中の DataFrame を明示しながら複数列をまとめて追加できる。

```
1 derived = (
2     events
3     .assign(
4         dt_ns=lambda df: df["time_ns"] - df["time_ns"].min(),
5         quality=lambda df: pd.Series(["high", "mid", "low", "mid"])
6     )
7 )
```

assign() は処理をパイプラインの形で並べたいときに読みやすい。一方で、単に 1 列だけ追加するなら events["new_col"] = ... の方が直感的である。

7.2.3 欠損値と型

現実のデータでは、空欄や壊れた値が入り込む。pandas ではこれを NaN や NA として扱うことが多い。

```
1 df = pd.DataFrame(
2     {
3         "id": [1, 2, 3, 4],
4         "signal": [12.4, None, 14.8, 9.7],
5         "comment": ["ok", "bad", None, "ok"],
6     }
7 )
8
9 print(df.isna())
10 print(df.dropna(subset=["signal"]))
11 print(df["signal"].fillna(df["signal"].mean()))
```

isna() の真偽表、dropna() の結果、fillna() 後の列を順に表示すると、欠損処理の違いが見えやすい。

```

      id  signal  comment
0  False  False   False
1  False   True   False
2  False  False    True
3  False  False   False
      id  signal  comment
0     1    12.4     ok
2     3    14.8    None
3     4     9.7     ok
0    12.400000
1    12.300000
2    14.800000
3     9.700000
Name: signal, dtype: float64

```

欠損値は == で判定しない。isna()、notna()、dropna()、fillna() を使う。また、整数列に欠損が入ると float64 に変わることがあるので、必要なら pandas の nullable integer 型である Int64 を使う。

```
1 df["id"] = df["id"].astype("Int64")
```

7.2.4 要約統計と groupby

describe() は列の全体像を手早く見るのに便利であり、groupby() はカテゴリごとの集計で中心になる。

```

1 print(events.describe())
2
3 summary = (
4     events
5     .groupby("detector")
6     .agg(
7         count=("signal", "size"),
8         mean_signal=("signal", "mean"),
9         std_signal=("signal", "std"),
10        late_fraction=("is_late", "mean"),
11    )
12 )
13
14 print(summary)

```

describe() は全体の要約、groupby() の結果は検出器ごとの集計である。出力は次の通りである。

```

      time_ns      signal  signal_ratio
count    4.000000    4.000000    4.000000
mean   1129.750000   11.750000    1.002960
std     99.494975    2.306513    0.196299

```

min	1032.000000	9.700000	0.827111
25%	1049.250000	10.000000	0.853429
50%	1121.500000	11.250000	0.960538
75%	1202.000000	13.000000	1.110069
max	1244.000000	14.800000	1.263652
count mean_signal std_signal late_fraction			
detector			
A	2	11.25	1.626346
B	2	12.25	3.606245

groupby() は「検出器ごと」「日ごと」「run ごと」に同じ集計を繰り返したいときの基本である。agg() に名前付き集計を書くと、列名が分かりやすくなる。

7.2.5 表の形を変える

Getting started tutorials [9] でも、表を縦長から横長へ変える操作、複数表を結合する操作が重視されている。解析でも、観測値と較正值を結び付けたり、日別表をまとめたりする場面で必ず使う。

```

1 gain = pd.DataFrame(
2     {
3         "detector": ["A", "B"],
4         "gain": [1.02, 0.97],
5     }
6 )
7
8 merged = events.merge(gain, on="detector", how="left")
9 stacked = pd.concat([events.iloc[:2], events.iloc[2:]], ignore_index=True)
10
11 long_df = pd.DataFrame(
12     {
13         "detector": ["A", "A", "B", "B"],
14         "kind": ["raw", "cal", "raw", "cal"],
15         "value": [12.4, 12.7, 14.8, 14.4],
16     }
17 )
18 wide = long_df.pivot(index="detector", columns="kind", values="value")
19
20 print(merged[["detector", "signal", "gain"]])
21 print(wide)

```

merge() で較正係数が付き、pivot() で縦長の表が横長に変わる様子は、出力を並べると分かりやすい。

	detector	signal	gain
0	A	12.4	1.02
1	A	10.1	1.02
2	B	14.8	0.97
3	B	9.7	0.97

kind	cal	raw
detector		
A	12.7	12.4
B	14.4	14.8

`merge()` は SQL の `join` に近い。`concat()` は同じ形の表を縦や横につなぐ。`pivot()` や `pivot_table()` は、縦長データを比較しやすい横長形式へ変えるときに使う。逆に横長から縦長へ戻すなら `melt()` が便利である。

7.2.6 時刻、文字列、カテゴリ

時刻や文字列は、そのままでは解析しにくい。pandas には時刻用の `dt` アクセサ、文字列用の `str` アクセサ、カテゴリ型がある。

```

1 log = pd.DataFrame(
2     {
3         "timestamp": ["2026-04-01_12:00:00", "2026-04-01_12:00:05", "2026-04-02_09:30:00"],
4         "run_name": ["run_A_001", "run_A_002", "test_B_001"],
5         "detector": ["A", "A", "B"],
6     }
7 )
8
9 log["timestamp"] = pd.to_datetime(log["timestamp"], utc=True)
10 log["date"] = log["timestamp"].dt.date
11 log["prefix"] = log["run_name"].str.extract(r"^(run_[A-Z])")
12 log["detector"] = log["detector"].astype("category")
13
14 print(log[["timestamp", "date", "prefix", "detector"]])

```

時刻列と文字列列を分解すると、日付や接頭辞を独立した列として扱える。出力は次の通りである。

	timestamp	date	prefix	detector
0	2026-04-01 12:00:00+00:00	2026-04-01	run_A	A
1	2026-04-01 12:00:05+00:00	2026-04-01	run_A	A
2	2026-04-02 09:30:00+00:00	2026-04-02	None	B

`to_datetime()` を早めに使うと、差分計算、日付抽出、時刻順ソートが自然に書ける。文字列列には `str.contains()`、`str.extract()`、`str.strip()` などのベクトル化メソッドがある。カテゴリ型は、取り得る値が少ない列のメモリ削減や並び順の明示に役立つ。

7.2.7 入出力

Getting started tutorials [9] でも、入出力は最初期の重要項目である。本書では特に CSV、Parquet、圧縮テキストを意識する。

```

1 df = pd.read_csv(
2     "events.csv.gz",

```

```

3     compression="gzip",
4     sep=r"\s+",
5     comment="#",
6     names=["detector", "date", "time", "signal"],
7     usecols=[0, 1, 2, 3],
8 )
9
10 df.to_parquet("events.parquet")
11 small = pd.read_parquet("events.parquet", columns=["detector", "signal"])

```

`read_csv()` を使うときは、必要な列だけ読む、型を指定する、コメント行を飛ばす、といった工夫が重要である。たとえば次のように書くと、圧縮付きの空白区切りファイルから必要列だけを型付きで読める。

```

1 df = pd.read_csv(
2     path,
3     compression="gzip",
4     sep=r"\s+",
5     comment="#",
6     header=None,
7     usecols=[0, 1, 2, 3],
8     names=["id", "date", "time", "value"],
9     dtype={"id": "int64", "value": "float64"},
10 )

```

このように列を絞るだけでも、読み込み時間とメモリ消費はかなり変わる。さらに `dtype=` を指定しておく、読み込み後の型変換を減らせる。列数や行数が大きいデータでは、どの列が本当に必要かを考えるだけで、後続の処理全体が軽くなる。読み込みは解析の最初の一步だが、同時に最適化の出発点でもある。

巨大なテキストファイルを何度も読むより、一度整形したら Parquet にして再利用する方がよい。特に `read_parquet()` は列選択と相性が良く、反復的な解析で待ち時間を減らせる。日々の解析では、この「最初に 1 回だけテキストを整理して、以後は Parquet を読む」という流れを作るだけで、待ち時間が大きく減る。

ここで区別したいのは、Parquet がファイル形式の名前であり、pyarrow はその読み書きを実装するライブラリだという点である。したがって、`to_parquet()` や `read_parquet()` が失敗したときは、「Parquet が壊れている」のではなく、「必要な実装がまだ入っていない」ことがある。

列同士の演算をそのまま式として書ける点も pandas の強みである。

```

1 df["ratio"] = df["value"] / df["value"].mean()
2 selected = df[df["ratio"] > 1.5]

```

行ごとの `for` ループを書く前に、列単位で表現できないかを考える習慣を持つとよい。

7.2.8 表を LaTeX へ出力する

集計結果をレポートへ貼るときは、手で打ち直さずに `to_latex()` を使う方が再現性が高い。

```
1 tex_table = summary.reset_index().to_latex(  
2     index=False,  
3     caption="検出器ごとの平均信号",  
4     label="tab:detector-summary",  
5     float_format="%.3f",  
6     escape=False,  
7 )  
8  
9 with open("tables/detector_summary.tex", "w", encoding="utf-8") as f:  
10     f.write(tex_table)
```

ここで `index=False` は左端の連番インデックスを出力しないための指定であり、`reset_index()` は `groupby` 結果の添字を普通の列へ戻すための操作である。さらに `escape=False` は、セル中にすでに TeX 記法が入っている場合にそのまま通したいときだけ使う。通常の文字列だけなら既定値のままエスケープさせた方が安全である。

`groupby()`、`agg()`、`to_latex()` をつなぎ、最後にファイルへ保存して本ドキュメント側で `\input` すれば、解析スクリプトからレポート用表までを自動化できる。表を手で打ち直さないことは、再現性の面でも大きい。

7.2.9 `plot()` は確認用として使う

`pandas` にも `plot()` があるが、これは `Matplotlib` の薄いラップである。

```
1 summary.plot(kind="bar", y="mean_signal")
```

手早い確認には便利だが、最終的な提出図や論文用図では、`Matplotlib` の `Figure` と `Axes` を明示して描く方が制御しやすい。本書でも最終的な作図は第 9.3 節以降の方法を基準とする。

7.3 よくある落とし穴

7.3.1 `SettingWithCopy` と `loc`

`pandas` 初学者がよく踏むのが、切り出した表へ代入したつもりで元の `DataFrame` を安全に更新できていない問題である。

```
1 subset = events[events["signal"] > 11.0]  
2 subset["flag"] = True
```

この書き方では `SettingWithCopyWarning` が出ることがある。意図が「元の表の条件に合う行へ代入する」であるなら、次のように `loc` で書く方が明確である。

```
1 events.loc[events["signal"] > 11.0, "flag"] = True
```

7.3.2 object 型のまま計算しない

見た目が数値でも、空白や記号が混ざると object 型で読まれることがある。そのまま足し算や比較をすると、文字列連結や例外が起きる。大きなファイルでは `read_csv()` の `dtype=` を使い、読み込み直後に `dtypes` を確かめる方が安全である。

7.3.3 行ループは最後の手段である

Pandas の `DataFrame` は数百万行のデータを保持できるが、各行に対して複雑な文字列処理や条件判定を加えようとした時、コードの書き方一つで実行時間が数十分から数秒へと劇的に変わる。特に、`iterrows()`、`apply(axis=1)`、並列化の使い分けは初心者がつまづきやすい。

7.3.3.1 Step 1: `iterrows()` の限界

Python 初学者が最も陥りやすい罠が、「`DataFrame` の行を 1 つずつ取り出して処理する」という直感的な書き方である。

```
1 def heavy_computation(val):
2     return val ** 2
3
4 results = []
5 for index, row in df.iterrows():
6     results.append(heavy_computation(row["value"]))
7 df["value_sq"] = results
```

この書き方は、Pandas がデータフレームとしてデータを一括管理している利点をほぼ打ち消す。さらに `iterrows()` は各行を毎回 `Series` として作り直すため、列ごとの型情報が崩れやすく、オブジェクト生成コストも大きい。どうしても行ループが必要なら `itertuples()` の方が軽いことが多いが、基本方針は「まず行ループ自体を避ける」である。

7.3.3.2 Step 2: `apply(axis=1)` と列演算

行ごとに処理を適用したい場合、Pandas が用意している `apply()` メソッドを使うと、少なくともコードを `pandas` の文脈に保ったまま書ける。`axis=1` は「各行へ関数を適用する」という意味であり、`axis=0` なら各列に適用する。

```
1 df["value_sq"] = df.apply(lambda row: heavy_computation(row["value"]), axis=1)
```

ただし、`axis=1` を付けた `apply()` も各行に対して Python 関数を呼ぶため、列演算ほど速いわけではない。つまり、`apply()` は「for 文を隠した便利関数」であって、万能の高速化ではない。単に二乗したいだけなら、次のように列演算で書く方が自然で速い。

```
1 df["value_sq"] = df["value"] ** 2
```

`apply()` は「列演算だけでは書きにくい、まだ `pandas` の文脈の中で処理したい」場合の中間手段として理解の方が正確である。まず列演算、次に `apply()`、それでも重ければ並列化、という順で判断すると迷いにくい。

7.3.3.3 Step 3: 並列化と `pandarallel`

しかし、`apply()` はどれだけ行数があっても CPU の 1 コアしか使わない。本当に計算が重い処理の場合、ここで初めてマルチコアを用いた並列化が選択肢に入る。

```
1 from pandarallel import pandarallel
2
3 pandarallel.initialize(progress_bar=True)
4 df["value_sq"] = df.parallel_apply(
5     lambda row: heavy_computation(row["value"]),
6     axis=1,
7 )
```

図 7.1 は、同じ種類の処理でも `iterrows()`、`apply()`、`pandarallel` で待ち時間がどう変わるかを模式的に示している。特に、「まず列演算を疑い、その後で `apply()` や並列化を考える」という順序の重要性を読み取ってほしい。




図 7.1 同じ重い計算処理を、Python のループ、`apply()`、`pandarallel`で行ったときの模式的な比較。手段の選び方で処理時間が大きく変わる。

`pandarallel` は、`DataFrame` を複数プロセスへ分割して送り、`apply()` に近い書き方のまま並列化するためのライブラリである。つまり、「既存の `pandas` コードを大きく壊さずに、`parallel_apply()` へ置き換えて試せる」ことが利点である。一方で、背後ではプロセス生成やデータコピーが起きるため、軽い処理ではほとんど得をしない。

`pandarallel` は Linux 系環境での利用が比較的安定している一方で、ネイティブの Windows 環境では設定や挙動で悩みやすいことがある。Windows で本書の流れを再現するのなら、前章で触れた WSL を使う方が混乱しにくい。

並列化は魔法の杖ではない。pandarallel は背後で「データを複数のプロセスにコピーして分配する」ため、通信オーバーヘッドがかかる。「単純な足し算」などのすぐに終わる軽い処理を `parallel_apply()` にかけても、計算時間よりもコピー時間の方が長くなり、かえって遅くなる。CPU 1 コアでは時間がかかりすぎる重い処理でのみ並列化を採用するという見極めが必要である。

7.3.4 欠損値と比較演算を混同しない

`NaN == NaN` は `False` である。欠損判定に `==` を使わず、`isna()` を使う。また、`None`、`NaN`、`NA` の違いは列型によって見え方が変わるので、「欠損をどう表現しているのか」を確認した方がよい。

7.4 解析へのつながり

観測データの解析では、pandas はしばしば次の流れの中心になる。

1. テキストや CSV を `read_csv()` で読む
2. `head()` と `dtypes` で構造を確認する
3. 必要な列だけを残し、欠損や異常値を整理する
4. `groupby()` や `merge()` で集計・結合する
5. Matplotlib へ渡して図を描く
6. 集計表を `to_latex()` で書き出す

この流れが成立するのは、pandas が「列名と型を保ったまま処理を書ける」からである。NumPy だけで済む問題もあるが、観測条件、検出器 ID、run 名、欠損フラグのような異種の列が混ざると、DataFrame の方が自然である。

一方で、数千万行規模になり、CSV 読み込みや集計が待ち時間の支配項になってきたら、次章で扱う Polars を検討する価値がある。pandas は基準になる道具であり、その上で「どこから別の道具へ切り替えるべきか」を判断できるようになることが重要である。

また、pandas は全データを一度にメモリへ載せる必要がある設計なので、マシンのメモリを超えるようなテラバイト級データをそのまま処理させると破綻する。つまり、この章で扱ったのは「1 台のマシンのメモリに載る表を丁寧に扱う方法」である。その前提が崩れ始めたときに、次章の Polars という選択肢が出てくる。

ここまでの内容を自分で確かめ直したくなったら、公式資料へ戻るとよい。入口としては Getting started tutorials [9] と 10 minutes to pandas [10] が分かりやすい。本章はそれらを解析向けの順序へ並べ替えて説明している。列選択や代入で迷ったときは Indexing [11]、欠損値処理は Missing data [12]、表の結合は Merge, join, concatenate and compare [13]、時刻列は Time series / date functionality [14] を見ると対応する話題に戻りやすい。

第 8 章 Polars による高速な表処理

Polars は、列指向の DataFrame 処理を高速に行うためのライブラリである。pandas と同じく表形式データを扱うが、発想はかなり違う。Polars では index を持たず、式を組み合わせで列変換を書く。さらに、LazyFrame によってクエリ全体を最適化できる。本章では、Polars の考え方、最小限の書き方、落とし穴、解析で使う場面を整理する。

8.1 Polars の考え方

8.1.1 index を持たない DataFrame

Polars の DataFrame は、常に「行番号は整数位置でだけ参照する 2 次元表」である。pandas のような index に意味を持たせないため、reset_index() や loc を前提にした設計にはならない。

```
1 import polars as pl
2
3 df = pl.DataFrame(
4     {
5         "detector": ["A", "A", "B", "B"],
6         "time_ns": [1032, 1188, 1055, 1244],
7         "signal": [12.4, 10.1, 14.8, 9.7],
8     }
9 )
10
11 print(df)
```

このコードを実行すると、Polars の表は次のように表示される。

```
shape: (4, 3)
+-----+-----+-----+
| detector | time_ns | signal |
| ---     | ---     | ---     |
| str      | i64     | f64     |
+=====+=====+=====+
| A        | 1032    | 12.4    |
| A        | 1188    | 10.1    |
| B        | 1055    | 14.8    |
| B        | 1244    | 9.7     |
+-----+-----+-----+
```

この出力でも、重要なのは shape: (4, 3) と列名である。Polars は「何行目を label で指す

か」よりも、「どの列にどの式を適用するか」を中心に据えている。

8.1.2 式で列変換を書く

Polars の中心概念は `expression` である。`pl.col("signal")` は「`signal` 列を参照する式」であり、これを四則演算や比較で組み合わせる。

```
1 expr = pl.col("signal") / pl.col("signal").mean()
2 print(expr)
```

この段階では、まだ計算結果ではなく「どう計算するか」という式を表している。Polars の公式ドキュメント [17] でも、まず `expression` を理解することが最重要とされている。実際、`select()`、`with_columns()`、`filter()`、`group_by()` の多くは、最終的に式を受け取る API で統一されている。

8.1.3 eager と lazy

Polars には、すぐ実行する `eager API` と、最後まで式をためて最適化してから実行する `lazy API` がある。

```
1 eager_df = pl.read_csv("events.csv")
2 lazy_df = pl.scan_csv("events.csv")
```

`read_csv()` はすぐに `DataFrame` を作るが、`scan_csv()` は `LazyFrame` を返す。`lazy API` を使うと、必要な列だけ読む、不要な行を早い段階で落とす、といった最適化が入りやすい。巨大なログを扱うときは、この違いがそのまま待ち時間の差になる。

8.2 最小限のコード例

8.2.1 `select()` と `filter()`

Polars では、列選択は `select()`、行抽出は `filter()` が基本である。

```
1 selected = df.select("detector", "signal")
2 strong = df.filter(pl.col("signal") > 11.0)
3
4 print(selected)
5 print(strong)
```

`select()` で列が減り、`filter()` で条件に合う行だけが残る。出力は次の通りである。

```
shape: (4, 2)
+-----+-----+
| detector | signal |
+=====+=====+
| A        | 12.4   |
| A        | 10.1   |
| B        | 14.8   |
```

```

| B      | 9.7 |
+-----+
shape: (2, 3)
+-----+
| detector | time_ns | signal |
+=====+
| A      | 1032 | 12.4 |
| B      | 1055 | 14.8 |
+-----+

```

`df["signal"]` のような書き方もできるが、Polars では「表に対する操作」を `select()` や `filter()` の文脈で書く方が自然である。特に複数列をまとめて変換したいときは、この違いが大きく効く。

8.2.2 `with_columns()` で列を増やす

新しい列は `with_columns()` で追加する。複数列を同時に書けるので、Polars の式ベース設計と相性が良い。

```

1 derived = df.with_columns(
2     (pl.col("signal") / pl.col("signal").mean()).alias("signal_ratio"),
3     (pl.col("time_ns") > 1100).alias("is_late"),
4 )
5
6 print(derived)

```

列追加後の表を見ると、式で作った列がどの位置へ入るかを確認できる。

```

shape: (4, 5)
+-----+
| detector | time_ns | signal | signal_ratio | is_late |
+=====+
| A      | 1032 | 12.4 | 1.055319 | false |
| A      | 1188 | 10.1 | 0.859574 | true  |
| B      | 1055 | 14.8 | 1.259574 | false |
| B      | 1244 | 9.7  | 0.825532 | true  |
+-----+

```

`alias()` は列名を付ける操作である。Polars では式の結果へ名前を付けるという発想が頻繁に現れるので、早めに慣れておく方がよい。

8.2.3 `group_by()` と集計

集計も式として書く。`group_by()` と `agg()` は、pandas の `groupby()` に対応する中心的な道具である。

```

1 summary = (
2     derived
3     .group_by("detector")
4     .agg(

```

```

5     pl.len().alias("count"),
6     pl.col("signal").mean().alias("mean_signal"),
7     pl.col("signal").std().alias("std_signal"),
8     pl.col("is_late").mean().alias("late_fraction"),
9 )
10    .sort("detector")
11 )
12
13 print(summary)

```

集計後は、検出器ごとに 1 行ずつの表へとまとまる。出力は次の通りである。

```

shape: (2, 5)
+-----+-----+-----+-----+-----+
| detector | count | mean_signal | std_signal | late_fraction |
+=====+=====+=====+=====+=====+
| A        | 2     | 11.25      | 1.626346  | 0.5           |
| B        | 2     | 12.25      | 3.606245  | 0.5           |
+-----+-----+-----+-----+-----+

```

Polars の `group_by()` は、集計対象が `expression` なので、同じ書き方のまま統計量を増やしやすい。`count`、`mean`、`std` のような基本操作は、式の名前を見れば意味を追いやすい。

8.2.4 join と表の変形

別表の校正係数や `run` 情報を結び付けるなら `join()` を使う。縦長と横長の変換も行える。

```

1 gain = pl.DataFrame(
2     {
3         "detector": ["A", "B"],
4         "gain": [1.02, 0.97],
5     }
6 )
7
8 merged = derived.join(gain, on="detector", how="left")
9 wide = (
10     pl.DataFrame(
11         {
12             "detector": ["A", "A", "B", "B"],
13             "kind": ["raw", "cal", "raw", "cal"],
14             "value": [12.4, 12.7, 14.8, 14.4],
15         }
16     )
17     .pivot(index="detector", on="kind", values="value")
18     .sort("detector")
19 )
20
21 print(merged.select("detector", "signal", "gain"))
22 print(wide)

```

`join()` はキー列を明示する点が重要である。Polars には `index` がないので、何をキーに結合するかが曖昧になりにくい。

8.2.5 欠損値、`null`、`NaN`

Polars は欠損値の扱いが比較的厳密である。`null` と `NaN` を区別して考える。

```
1 missing = pl.DataFrame(  
2     {  
3         "signal": [12.4, None, 14.8, float("nan")],  
4     }  
5 )  
6  
7 print(missing.with_columns(  
8     pl.col("signal").is_null().alias("is_null"),  
9     pl.col("signal").is_nan().alias("is_nan"),  
10 ))
```

`null` は値が存在しないこと、`NaN` は浮動小数点の特殊値である。解析では両者を同じ「欠損」と見なしたくなるが、Polars はここを明確に分ける。どちらを落とすかで使うメソッドも変わる。

8.2.6 文字列と条件分岐

式ベースの API では、文字列処理や条件分岐も列全体に対する式として書く。

```
1 names = pl.DataFrame(  
2     {  
3         "run_name": ["run_A_001", "run_A_002", "test_B_001"],  
4         "signal": [12.4, 10.1, 14.8],  
5     }  
6 )  
7  
8 classified = names.with_columns(  
9     pl.col("run_name").str.extract(r"^(run_[A-Z])", 1).alias("prefix"),  
10    pl.when(pl.col("signal") > 12.0)  
11        .then(pl.lit("high"))  
12        .otherwise(pl.lit("normal"))  
13        .alias("quality"),  
14 )
```

`when`、`then`、`otherwise` は、`pandas` の `apply()` に頼りがちな条件分岐を Polars の式として書くための基本形である。

8.2.7 lazy API と `scan_parquet()`

大きなデータでは、eager API より lazy API の方が自然である。

```
1 lf = (  
2     pl.scan_parquet("events/*.parquet")
```

```

3     .filter(pl.col("signal") > 0.0)
4     .select("detector", "signal", "time_ns")
5     .with_columns((pl.col("time_ns") - pl.col("time_ns").min()).alias("dt_ns"))
6     .group_by("detector")
7     .agg(pl.col("signal").mean().alias("mean_signal"))
8 )
9
10 result = lf.collect()
11 print(result)

```

`scan_parquet()` はまだデータを実体化しない。`collect()` を呼んだ時点で、必要列と必要行だけを読む最適化が入りやすい。巨大ファイルを条件付きで読むなら、この書き方が有利である。

8.2.8 CSV と Parquet の入出力

Polars でも CSV と Parquet は基本である。

```

1 df = pl.read_csv("events.csv")
2 df.write_parquet("events.parquet")
3
4 lf = pl.scan_csv("events.csv")
5 result = lf.filter(pl.col("signal") > 0).collect()

```

`read_csv()` と `write_parquet()` は eager API、`scan_csv()` は lazy API の入口である。pandas と同じ名前の関数も多いが、設計思想はかなり異なる。

8.3 よくある落とし穴

8.3.1 pandas の書き方をそのまま持ち込まない

Polars 公式の migration guide [20] でも強調されているが、**Polars は pandas ではない**。pandas に似た書き方が一部動いても、それが最も自然な書き方とは限らない。特に、index 前提の考え方、`loc`、`apply(axis=1)` へ寄った設計は Polars では合わない。

8.3.2 map_elements() や Python の lambda を多用しない

Polars の利点は、式が query optimizer に見えることにある。Python の `lambda` や `map_elements()` へ逃げると、その最適化が効きにくくなる。まずは `pl.col()`、`when`、`str`、`dt`、`over` などの組み込み式で書けないかを考える方がよい。

8.3.3 lazy API では collect() を忘れない

`scan_csv()` や `scan_parquet()` は `LazyFrame` を返す。ここで `print(lf)` としても、実データではなく計画しか見えない。結果が欲しいなら `collect()` が必要である。

8.3.4 欠損値は `null` と `NaN` を区別する

Polars は型に厳密である。欠損をまとめて扱っているつもりでも、実際には `null` と `NaN` が混ざっていることがある。フィルタや集計の前に、どちらが入っているかを確認した方が安全である。

8.4 解析へのつながり

Polars が特に有効なのは、次のような場面である。

- 数千万行の CSV や Parquet を条件付きで読みたいとき
- 同じ表に対する列変換と集計を一つの query としてまとめたいとき
- pandas では待ち時間が長く、入出力と集計が支配的になっているとき
- 複数ファイルをまとめて scan し、必要な列だけを残したいとき

一方で、小規模データで index を活かした対話的操作や、既存の pandas ベース資産をそのまま流用したいなら、pandas の方が自然なことも多い。大切なのは「pandas を捨てる」ことではなく、「どの規模、どの処理で Polars へ切り替えるべきか」を判断できるようになることである。

Polars の公式資料では、Concepts [16]、Expressions and contexts [17]、Lazy API [18]、IO [19]、Coming from Pandas [20] が土台になる。本章もその流れを踏まえているが、解析に必要な判断が先に見えるように並べ替えてある。式の書き方で迷ったときは expression、遅い処理をまとめて最適化したいときは lazy API、pandas との違いを整理したいときは migration guide を見返すとよい。

第9章 Matplotlib による可視化

Matplotlib は、Python で図を描くための標準的なライブラリである。本章では、まずデータを手軽に可視化するための基本的なコードの書き方からはじめ、データの性質に応じた図の選び方（実践的な作図）を学ぶ。そして後半では、より複雑な図を制御するために必須となる「オブジェクト指向 API」と構成要素の考え方や、スタイルの管理について解説する。

図はレポートの飾りではない。ヒストグラムや散布図は、計算結果の妥当性を自分で確かめるための道具でもある。数値だけを並べるより、まず図にした方が異常に気付きやすいことは多い。

例えば、平均値や標準偏差が妥当に見えても、分布の裾が長い、二峰性がある、外れ値が混ざっている、といった特徴は図にしないと分かりにくい。可視化は最後の仕上げではなく、途中の確認作業としても重要である。

9.1 基本的な作図と可視化

9.1.1 最小限のヒストグラム

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 values = np.random.normal(loc=0.0, scale=1.2, size=2500)
5
6 plt.hist(values, bins=40)
7 plt.xlabel("value")
8 plt.ylabel("count")
9 plt.savefig("histogram.pdf")
```

解析では PDF 出力が便利である。拡大しても崩れにくく、LaTeX レポートへそのまま入れやすいからである。図 9.1 は、この最小例をそのまま実行したときの典型的な出力である。

`plt.show` による対話的な確認は便利だが、再現可能な解析では `savefig` でファイルへ残す方が重要になる。図を保存するたびに同じファイル名へ上書きするのか、条件ごとに別名で保存するのかも、早い段階で決めておくと混乱しにくい。

9.1.2 軸ラベル、凡例、目盛り

図として最低限必要なのは、軸ラベル、必要なら単位、系列名、そして比較に必要な目盛りである。ここを省くと、図が描けても読めない。

```
1 import numpy as np
```




図 9.1 最小限のヒストグラム出力例。最初は、入力配列 `values` が何本の棒へ数え上げられているかだけを追えばよい。

```

2 import matplotlib.pyplot as plt
3
4 x = np.linspace(0.0, 10.0, 60)
5 y = np.exp(-x / 4.0) * (1.0 + 0.08 * np.sin(2.5 * x))
6
7 fig, ax = plt.subplots(figsize=(6, 4))
8 ax.plot(x, y, marker="o", label="sample_A")
9 ax.set_xlabel(r"$t$, [\mathrm{s}]$")
10 ax.set_ylabel("signal")
11 ax.set_title("Labeled_line_example")
12 ax.set_xticks([0, 2, 4, 6, 8, 10])
13 ax.legend(loc="upper_right")
14 fig.savefig("labeled_plot_example.pdf")

```

図 9.2 のように、ラベルと凡例と目盛りがそろっただけで、何を見せたい図なのかが一気に分かりやすくなる。最初は配色に凝るより、まずラベルと凡例を外さない方が重要である。

9.1.3 plot 関数へ渡すデータ

Matplotlib の多くの作図関数は、NumPy 配列や Python リストのような「配列に変換できるもの」を受け取る。加えて、辞書や DataFrame のように列名で参照できるオブジェクトなら、`data=` を使って列名指定で描くこともできる。

```

1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 times = [0, 1, 2, 3]
5 values = [1.0, 2.0, 1.5, 3.0]
6
7 fig, ax = plt.subplots(figsize=(6, 4))

```




図 9.2 ラベル、凡例、目盛りを付けた最小限の線図。横軸の単位と系列名があるだけで読みやすさが大きく変わる。

```

8 x = np.asarray(times)
9 y = np.asarray(values)
10 ax.plot(x, y)
11
12 table = {"time": x, "value": y}
13 ax.plot("time", "value", data=table)

```

`np.asarray` で NumPy 配列へそろえておくと、型のぶれを減らせる。`data=` は短いコードを書くのに便利だが、列名の打ち間違いに気付きにくいこともあるので、最初は `x` と `y` を明示して渡す方が安全である。

9.2 実践的な作図（データに応じた図の選択）

データ解析において、2つの変数の相関関係を見ることは非常に多い。しかし、これを「とりあえず」描画関数にかけるだけでは、重要な特徴を見落とす。データ量に応じた適切な図の選択プロセスを順番に見ていく。

9.2.1 相関の可視化：論理的改善ステップ

9.2.1.1 Step 1: 直感的な散布図 (Scatter) の限界

2 変数の相関を見るのに最も基本となるのが散布図 (scatter) である。しかし、データ点が数十万規模になると、これはすぐに「役に立たない図」と化す。

```

1 # s=10 で大量の点（約60万点）をそのまま描画すると...
2 fig, ax = plt.subplots(figsize=(6, 5))
3 ax.scatter(x, y, s=10, c='black')
4 fig.savefig("scatter_bad.png", dpi=150)

```




図 9.3 大量データに対する散布図。全てが黒く沈んでおり内部構造が一切見えない。

図 9.3 のような図を作ってしまうてはならない。データがどこにどれだけ集中しているのか（密度）が全く分からないからである。

9.2.1.2 Step 2: 2次元ヒストグラムの導入と、線形スケールの限界

点が潰れるなら、「その領域にいくつ点があるか」を色で表現する 2 次元ヒストグラム (hist2d) が有効である。

```
1 fig, ax = plt.subplots(figsize=(6, 5))
2 h_lin = ax.hist2d(x, y, bins=50, cmap='viridis')
3 cbar = fig.colorbar(h_lin[3], ax=ax, label="Counts_␣(Linear)")
4 fig.savefig("hist2d_linear_bad.pdf")
```

図 9.4 は中心部が明るくなっているため、散布図よりはマシに見える。しかし、極端に集中している一部（例: 2 万カウント）の色に引っ張られ、10 カウント、100 カウントといった周囲のノイズや裾野の広がりやすべて濃紺に塗りつぶされてしまっている。

9.2.1.3 Step 3: 大規模データに必須となる LogNorm (対数カースケール)

現実の物理イベントは、頻度が「1, 10, 100, 1000」のように桁単位で変化することが多い。この何桁にもまたがる広がりをもつデータを一つの図に収めるための判断基準が「カウントのカラーバーを対数 (log) にするべきか否か」である。

```
1 import matplotlib.colors as mcolors
2
3 fig, ax = plt.subplots(figsize=(6, 5))
4 # norm=mcolors.LogNorm() により色の割当を対数スケールにする
5 h_log = ax.hist2d(x, y, bins=50, norm=mcolors.LogNorm(), cmap='viridis')
6 cbar = fig.colorbar(h_log[3], ax=ax, label="Counts_␣(Log_Scale)")
7 fig.savefig("hist2d_lognorm_good.pdf")
```




図 9.4 線形スケールを用いた 2D ヒストグラム。最も集中した中心部だけが目立ち、周辺が潰れる。




図 9.5 LogNorm を用いた 2D ヒストグラム。中心の密集部分と、周囲の広がりが同時に視認できる。

図 9.5 を見れば、単一のピークの周りに広く緩やかなイベントの相関層が広がっていることが一目で分かる。これが「なぜ LogNorm を知っていなければならないか」の強力な理由である。

9.2.2 複数の図を並べる (subplots)

レポートや論文では、関連する分布を左右や上下に並べて比較することが多い。この場合、1 枚のキャンバス (Figure) の中に複数のパネル (Axes) を配置する機能を利用する。

```
1 # 1行2列 (左右に2つ) のパネルを作成する。
2 # fig はキャンバス全体、axes は2つのパネル (配列) を表す。
3 fig, axes = plt.subplots(1, 2, figsize=(10, 4))
```

```

4
5 # 左のパネルには axes[0] を使って描画する
6 axes[0].hist(data_a, bins=30)
7 axes[0].set_title("Data_A")
8
9 # 右のパネルには axes[1] を使って描画する
10 axes[1].hist(data_b, bins=30)
11 axes[1].set_title("Data_B")
12
13 # 複数のパネルを描くと軸の数字やラベルが隣の図と重なりやすいため、
14 # 最後に必ず tight_layout() を呼んで余白を自動調整する。
15 fig.tight_layout()
16 fig.savefig("subplots_example.pdf")

```

単純な `plt.plot()` ばかり使っていると、この「特定のパネル (`axes[0]`) に対して描画を命令する」という書き方に慣れるのに少し時間がかかるが、複雑な比較図を作る上では避けて通れない技法である。Figure や Axes についての詳細は、第 9.3 節以降で述べる。

9.2.3 凡例とレイアウト

複数の系列やフィット曲線を同じ図へ重ねるなら、凡例は不可欠である。凡例をどこへ置か、枠を付けるか、何をどの順に書くかで、読みやすさは大きく変わる。

ここでいう `values1` と `values2` は、同じ物理量を別条件で測った 1 次元配列だと考えればよい。例えば、温度条件 A と B で得た信号振幅を左右のパネルへ並べ、同じビン数でヒストグラムを描いて分布形状を比較する場面である。単にコードの書式を見るのではなく、同じ量を別条件で見比べるための雛形だと捉えると、このリストの意図が分かりやすい。

```

1 fig, axes = plt.subplots(1, 2, figsize=(10, 4), sharey=True)
2 axes[0].hist(values1, bins=40, alpha=0.7, label="sample_A")
3 axes[0].set_title("sample_A")
4 axes[0].set_xlabel("value")
5 axes[0].set_ylabel("count")
6
7 axes[1].hist(values2, bins=40, alpha=0.7, label="sample_B")
8 axes[1].set_title("sample_B")
9 axes[1].set_xlabel("value")
10
11 for ax in axes:
12     ax.legend(loc="upper_right")
13     ax.set_axisbelow(True)
14
15 fig.tight_layout()
16 fig.savefig("subplots_example.pdf")

```

この例では、`axes` は二つの Axes を並べた配列であり、`for ax in axes:` の部分で「凡例位置をそろえる」という共通処理を両パネルへまとめて適用している。`sharey=True` を付けると図 9.6 のように縦軸の尺度がそろうため、左右の高さをそのまま比較しやすい。ここでは




図 9.6 左右に並べたヒストグラムの出力例。縦軸を共有すると、高さの差をそのまま比較しやすい。各パネルに系列が一つしかないため、凡例はやや大げさに見えるかもしれないが、後からフィット曲線や参照線を重ねるとそのまま拡張できる書き方である。

`tight_layout` は余白調整の基本であるが、すべてを自動で完璧に直してくれるわけではない。タイトルや長いラベルが多い場合は、図のサイズや余白を自分で調整した方がよい。複数パネルの図では、どのパネルを比較させたいのかを意識して配置することが大切である。

凡例がデータを隠すなら、`loc="best"` で自動配置に任せるか、`bbox_to_anchor` を使って枠の外へ逃がす。レイアウト調整は「自動で整うかどうか」ではなく、「比較したい情報が隠れていないかどうか」で判断する方が実践的である。

9.2.4 エラーバーと対数軸 (log-log プロット)

実際の物理データの多くは測定誤差を伴うため、単なる散布図ではなくエラーバー付きのプロットが必要になる。また、横軸や縦軸のスケールが指数関数的に落ち幅を変える場合、対数 (log) のグラフでプロットしなければ分布の様子が潰れてしまうことが多い。

図 9.7 にエラーバーと対数プロットの例を示す。




図 9.7 エラーバーと対数軸の設定例。左は通常の線形軸、右は X, Y 両方を対数にした図。

```
1 fig, axes = plt.subplots(1, 2, figsize=(10, 4)) # 横10インチ、縦4インチで 1行2列のパネルを作成
```




図 9.8 Matplotlib による分布図とフィットの例。左はガウシアン型、右は指数分布であり、どちらもヒストグラムの上にフィット曲線を重ね、凡例に関数形とパラメータを書いている。

```

2
3 # 左のパネル (axes[0]) へのプロット
4 # x_val, y_val を点ごとにエラー y_err でプロット。
5 # fmt='o' は丸い点を意味し、capsize=3 はエラーバーの終端の横棒の長さ。
6 axes[0].errorbar(x_val, y_val, yerr=y_err, fmt='o', capsize=3, label="data")
7 axes[0].set_xlabel("Time_μs")
8
9 # 右のパネル (axes[1]) へのプロット
10 axes[1].errorbar(x_val, y_val, yerr=y_err, fmt='o', capsize=3, label="data")
11 # 対数スケール化
12 axes[1].set_yscale('log')
13 axes[1].set_xscale('log')
14
15 fig.tight_layout() # ラベルや目盛りが重ならないように余白を自動調整
16 fig.savefig("errorbar_example.pdf")

```

9.2.5 結果例の読み方

図を読めるようになるには、単に描けるだけでは足りない。まず軸と単位を確認し、次に分布の中心と幅、最後に裾や外れ値を見る、という順で眺めると整理しやすい。

例えば、図 9.8 の左パネルでは、ヒストグラムの山がフィット曲線とよく重なっているか、左右対称性がどの程度あるかを見る。右パネルでは、短時間側の立ち上がりや長時間側の減衰が同じ時定数で説明できるかを見る。こうした読み方を本文中で言葉にしておくと、図は単なる飾りではなく考察の根拠になる。

9.2.6 画像フォーマットの選択：ラスタとベクタ

解析図を保存する際、適切な画像フォーマットを選ぶことは極めて重要である。

- **ベクタ形式 (.pdf, .svg, .eps)**：どれだけ拡大しても線や文字がぼやけない。論文やレポートで図を用いる場合、文字やプロット点を高品質なまま印刷できるためこれが基本

となる。関数 `savefig("plot.pdf")` で保存できる。

- **ラスタ形式 (.png, .jpg)**：ピクセル（点）の集まりで画像を描画する。拡大するとジャギ（ピクセルのギザギザ）が見える。ただし、例えば数十万点に及ぶ密集した散布図や、ヒートマップのような巨大な 2 次元データをベクタ形式で保存すると、点の一つ一つがファイルに記録されるためファイルサイズがギガバイトを超え、PDF ビューアがフリーズする原因になる。そのような複雑な図の場合は、`savefig("plot.png", dpi=150)` のように解像度 (dpi) を指定して PNG で出力する方が適切である。

```
1 fig, ax = plt.subplots(figsize=(6, 4))
2 ax.plot(x, y)
3 ax.set_xlabel("time_μs")
4 ax.set_ylabel("count")
5
6 fig.savefig("spectrum.pdf")
7 fig.savefig("spectrum.png", dpi=150)
```

同じ図でも、`spectrum.pdf` は拡大しても線と文字が崩れにくく、`spectrum.png` はスライド貼り付けや Web 掲載で扱いやすい。どちらが良いかは「図の複雑さ」と「最終的な使い道」で決まる。線図や通常のヒストグラムなら PDF を第一候補にし、巨大散布図やヒートマップでは PNG を検討する方が実務的である。

9.3 オブジェクト指向 API による複雑な図の管理

9.3.1 Figure, Axes, Axis, Artist の役割

Matplotlib の初学者が最も混乱しやすいのは、Figure と Axes と Axis の区別である。特にややこしいのは、Axes という名前が複数形に見えるにもかかわらず、Matplotlib では「1 枚の作図パネル」を表すクラス名として使われている点である。まずは次の対応で覚えるとよい。

Figure 図全体である。1 つの PDF や PNG、1 つの表示ウィンドウに相当する。`savefig`、`supplitle`、図全体の凡例や `colorbar` などは主に Figure 側の仕事である。

Axes データを実際に描く 1 つのパネルである。`plot`、`hist`、`scatter`、`set_xlabel`、`legend` など、日常的な作図命令の多くは Axes のメソッドとして呼ぶ。

Axis (x Axis, y Axis) 目盛り、目盛りラベル、スケールを管理する部品である。通常は `ax.set_xscale("log")` や `ax.set_xlim(...)` のように Axes 経由で触るが、内部には `ax.xaxis` と `ax.yaxis` がある。

Artist 図の中に描かれるすべての要素の総称である。線は `Line2D`、文字は `Text`、凡例は `Legend`、ヒストグラムの棒は `Rectangle` といった Artist として管理される。以下なども Artist に含まれる。

- Title, Legend: 図のタイトル、および各系列を示す凡例。




図 9.9 Figure、Axes、Axis、Artist の関係を示した例。1 つの Figure の中に Axes があり、その Axes の中で線、文字、凡例などの Artist が描かれている。

- Grid, Spine: グリッド線と、座標系を囲む枠線。
- Line, Markers: 折れ線や散布図の点。
- xlabel, ylabel: x 軸・y 軸のラベル。

Figure、Axes、Axis、Artist の階層関係だけを先に図解の構図に合わせて木構造で書くと、次のようになる。

```
Figure
|-- Axes
|   |-- Title
|   |-- Spine, Grid
|   |-- xaxis, yaxis (x Axis, y Axis / xlabel, ylabel)
|   |-- Line2D, Markers
|   `-- Legend
`-- Figure-level Text / Colorbar / ...
```

図 9.9 に、Figure、Axes、Axis、Artist の位置関係を示す。まずは「Figure の中に Axes があり、その中に Axis と各種 Artist がある」という階層だけ押さえれば十分である。この対応を、実際の Python オブジェクトの型で確かめる短いコードを次に示す。

```
1 import matplotlib.pyplot as plt
2
```

```

3 x = [0, 1, 2, 3]
4 y = [1.0, 2.0, 1.5, 3.0]
5
6 fig, ax = plt.subplots(figsize=(6, 4))
7 line, = ax.plot(x, y, label="signal")
8 ax.set_title("Axes_title")
9 ax.set_xlabel("time")
10 ax.set_ylabel("signal")
11 legend = ax.legend()
12
13 print(type(fig).__name__)
14 print(type(ax).__name__)
15 print(type(ax.xaxis).__name__)
16 print(type(line).__name__)
17 print(type(legend).__name__)
18 print(len(fig.axes))
19 fig.savefig("line.pdf")

```

このコードを実行すると、次の出力が得られる。

```

Figure
Axes
XAxis
Line2D
Legend
1

```

最後の 1 は、この Figure の中に Axes が 1 枚だけ入っていることを表す。もし `plt.subplots(2, 2)` と書けば、Figure は 1 つのままで、Axes が 4 枚入る。

Artist という言葉も、線だけを指すわけではない。タイトルや軸ラベルは Text、ヒストグラムの各棒は Rectangle として管理される。次のコードで、どの型が返るかを確かめる。

```

1 import matplotlib.pyplot as plt
2
3 fig, ax = plt.subplots(figsize=(6, 4))
4 title = ax.set_title("Histogram")
5 xlabel = ax.set_xlabel("value")
6 bars = ax.hist([1, 1, 2, 3], bins=[0.5, 1.5, 2.5, 3.5])[2]
7
8 print(type(title).__name__)
9 print(type(xlabel).__name__)
10 print(type(bars).__name__)
11 print(type(bars[0]).__name__)

```

このコードの出力は次のとおりである。

```

Text
Text
BarContainer
Rectangle

```

ここで bars 全体は BarContainer であり、その中の 1 本 1 本は Rectangle である。したがって、「ヒストグラムの棒だけ色を変える」といった細かい調整は、最終的には Artist を触る操作だと理解できる。

Figure 側の要素も、コードで見ると役割が分かりやすい。図全体タイトル `suptitle` や `colorbar` は、特定の Axes だけでなく Figure 全体の見た目に関わることが多い。次のコードでは、その型を確認する。

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 fig, ax = plt.subplots(figsize=(5, 4))
5 img = ax.imshow(np.arange(4).reshape(2, 2))
6 suptitle = fig.suptitle("Figure_title")
7 cbar = fig.colorbar(img, ax=ax)
8
9 print(type(suptitle).__name__)
10 print(type(cbar).__name__)
```

このコードでは、次の出力が得られる。

```
Text
Colorbar
```

`suptitle` は Figure 全体に付く Text であり、`colorbar` は Figure に追加される補助要素である。複数パネルの図で共通タイトルや共通 `colorbar` を付けたいときは、Axes よりも Figure 側の仕事だと考えると整理しやすい。

Axis は少し見えにくい部品だが、実際には目盛りと表示範囲を管理している。たとえば次のような操作は Axis に関わる設定である。

```
1 fig, ax = plt.subplots(figsize=(6, 4))
2 ax.plot([1, 10, 100], [2, 3, 5], marker="o")
3 ax.set_xlim(1, 100)
4 ax.set_xscale("log")
```

`set_xlim` は表示範囲を、`set_xscale("log")` は目盛りの刻み方を変える。ふだんは `ax.xaxis` を直接操作しなくても、Axes メソッド経由で Axis の設定を変えていると理解すれば十分である。

どのオブジェクトを操作すべきかは、何を変えたいかで決まる。次の対応で考えると迷いにくい。

- 図全体を保存する、図全体タイトルを付ける: Figure
- 線やヒストグラムを描く、軸ラベルや凡例を付ける: Axes
- 対数軸、目盛り位置、目盛りラベルを変える: Axis 関連。ただし実際の操作は Axes メソッド経由が多い
- 特定の線だけ色や太さを変える、凡例や文字を細かく調整する: Artist

この区別が付くと、「保存はなぜ `fig.savefig(...)` なのか」「凡例はなぜ `ax.legend()` なのか」「対数軸はなぜ `ax.set_xscale("log")` で変えるのか」が自然につながる。Matplotlib を使い始めたら、まず `fig` と `ax` のどちらへ命令しているのかを追うだけでも、コードの見通しはかなり良くなる。

9.3.2 オブジェクト指向 API で描く

Matplotlib には `plt.hist(...)` のような簡単な書き方と、`Figure` と `Axes` を明示的に扱う書き方がある。図が複雑になるほど、後者の方が整理しやすい。

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 values = np.random.normal(loc=0.0, scale=1.2, size=2500)
5
6 fig, ax = plt.subplots(figsize=(6, 4))
7 ax.hist(values, bins=40)
8 ax.set_xlabel("value")
9 ax.set_ylabel("count")
10 fig.savefig("histogram.pdf")
```

`ax` に対して操作を書く形にしておくと、複数図や複数パネルへ発展しやすい。解析スクリプトを後で拡張したり、提出用の図を安定して作り直したりする場面では、この書き方に慣れておく価値が高い。

また、`Figure` と `Axes` を区別して考えると、図全体に効く設定と各パネルにだけ効く設定を整理しやすい。タイトルや余白は図全体、軸ラベルや凡例は各パネル、というように役割を分けて考えると見通しが良い。

9.3.3 補助関数で作図をまとめる

同じ体裁の図を何枚も作るなら、`Axes` を引数に取る補助関数へまとめると管理しやすい。

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 def plot_hist(ax, values, label):
5     ax.hist(values, bins=40, alpha=0.7, label=label)
6     ax.set_xlabel("value")
7     ax.set_ylabel("count")
8     ax.legend(loc="upper_right")
9
10 rng = np.random.default_rng(0)
11 values1 = rng.normal(loc=0.0, scale=1.0, size=2500)
12 values2 = rng.normal(loc=0.8, scale=1.3, size=2500)
13
14 fig, axes = plt.subplots(1, 2, figsize=(10, 4), sharey=True)
15 plot_hist(axes[0], values1, "sample_A")
16 plot_hist(axes[1], values2, "sample_B")
```

```
17 fig.savefig("subplots_example.pdf")
```

重要なのは、`plt.hist(...)` のようなグローバルな状態へ書くのではなく、「どの Axes に描くか」を引数で受け取る点である。比較図、条件ごとの反復描画、関数の再利用がしやすくなる。

9.4 見た目とスタイルの管理

図を読みやすくするには、少なくとも次の点を意識する。

- 軸ラベルに量と単位を書く
- タイトルを簡潔に付ける
- 余白を調整する
- 色と線幅を統一する
- レポート全体で表記を揃える

色やフォント、線幅をばらばらにすると、個々の図は読めてもレポート全体として落ち着かない。逆に、軸ラベルの位置、単位の書き方、凡例のスタイルをそろえるだけで、見た目の質は大きく上がる。可視化では、派手さより統一感の方が効くことが多い。

9.4.1 rcParams で見た目をそろえる

Matplotlib では、図のフォントや線幅などの既定値の多くを `rcParams` という辞書オブジェクトで一元管理している。図を描くたびに同じ設定を繰り返すより、作図スクリプトの冒頭で一度だけこの辞書を更新するのが基本である。

```
1 import matplotlib as mpl
2
3 mpl.rcParams.update(
4     {
5         "font.family": "serif",
6         "mathtext.fontset": "cm",
7         "font.size": 12,
8         "axes.grid": True,
9         "grid.linestyle": "--",
10        "xtick.direction": "in",
11        "ytick.direction": "in",
12        "axes.linewidth": 1.2,
13        "legend.frameon": False,
14    }
15 )
```

- `font.family`: 既定フォント族を決める。本文と図の雰囲気をもそろえたいときの入口になる。

- `font.size`: 文字の基本サイズである。発表スライド用と論文用で最初に変えたい項目である。
- `axes.grid`, `grid.linestyle`: グリッドを既定で表示するか、その線種をどうするかを決める。
- `xtick.direction`, `ytick.direction`: 目盛り線を内向きにするか外向きにするかを定める。
- `axes.linewidth`: 枠線の太さである。細すぎると印刷時に弱く見える。
- `legend.frameon`: 凡例の枠を出すかどうかを決める。

`rcParams` で設定した値は、そのスクリプトで後から作る図へまとめて効く。したがって、「毎回同じ見た目にしたい項目」をここへ集め、「この図だけ変えたい項目」は後で `ax.set_*` などで上書きする、と分けると整理しやすい。

9.4.2 設定ファイル (.mplstyle) で見た目を共通化する

しかし、解析テーマごとに作図スクリプトが増えていくと、すべての Python ファイルの先頭に上記の長い辞書をコピーするのは冗長である。Matplotlib では、これらの設定をプレーンテキストに切り出し、まとめて読み込める。

作業ディレクトリに `my_style.mplstyle` という名前で、次のような設定ファイルを作成する。

```
font.family: serif
mathtext.fontset: cm
font.size: 12
axes.grid: True
grid.linestyle: --
xtick.direction: in
ytick.direction: in
axes.linewidth: 1.2
legend.frameon: False
```

そして、各解析スクリプトの先頭でこれを一度だけ呼び出せばよい。本テキストに含まれる図も、すべてこの設定ファイル（スタイルシート）を読み込んで生成されている。

```
1 import matplotlib.pyplot as plt
2
3 # スクリプトの冒頭で自分のスタイルシートを読み込む
4 plt.style.use("./my_style.mplstyle")
5
6 # 以降の描画はすべて統一されたスタイル (Serif フォント等) が反映される
7 fig, ax = plt.subplots(figsize=(6, 4))
```

このように設定をファイルに分離しておくことで、新しい解析スクリプトを書くたびにフォントやグリッドの有無がバラバラになる事態を防ぐことができる。また、学会発表用の大きなフォント設定といった別のファイルを容易に切り替えることも可能になる。

9.4.3 共通スタイルの一部だけを上書きする

共通スタイルを決めておくと便利だが、発表スライド用に文字だけ大きくしたい、下書きではグリッドだけ消したい、といった局所的な変更もよく起こる。そのたびに元の `my_style.mplstyle` を書き換えると、別の図まで見た目が変わってしまう。こういう場合は、基準となるスタイルを読み込んだ後に、必要な項目だけを重ねる方が管理しやすい。

```
# presentation_style.mplstyle
font.size: 16
axes.grid: False
legend.fontsize: 11
```

```
1 import matplotlib as mpl
2 import matplotlib.pyplot as plt
3
4 plt.style.use(["./my_style.mplstyle", "./presentation_style.mplstyle"])
5
6 # スタイルファイルを増やしたくないなら、その場で個別に上書きしてもよい
7 mpl.rcParams["axes.titlesize"] = 14
8
9 fig, ax = plt.subplots(figsize=(6, 4))
10 ax.grid(False) # この Axes だけグリッドを消す
```

二つの `.mplstyle` を配列で渡すと、後ろに書いたファイルの設定が優先される。したがって、基準となる `my_style.mplstyle` を保ったまま、文字サイズやグリッドの有無だけを差し替えられる。さらに、`mpl.rcParams` を直接書き換えれば、そのスクリプト以降の図だけを変更でき、`ax.grid(False)` のような Axes メソッドを使えば、単一のパネルにだけ適用できる。設定の効く範囲が、スタイルファイル、スクリプト全体、個別の Axes の三段階に分かれると理解しておくくと混乱しにくい。

9.5 比較しやすい図を作る

9.5.1 Matplotlib の数式表記を使う

Matplotlib では、軸ラベルや凡例に数式風の表記を書ける。既定では LaTeX そのものではなく、TeX に似た `MathText` という仕組みが使われる。

```
1 plt.xlabel(r"$\Delta t, [\mathrm{ns}]$")
2 plt.ylabel(r"$N$")
```

単位まで数式の中へ入れるなら、上の例のように `mathrm` を使って立体で書く方が自然である。レポートを LaTeX で書くなら、図中の記号も本文と整合するようにそろえると見通しがよい。

`MathText` は便利だが、LaTeX そのものではない。よく使う分数、上付き・下付き、ギリ

シャ文字、

`mathrm` などは扱える一方で、複雑なマクロや一部のパッケージ依存の記法は使えない。通常は追加の LaTeX 環境なしで動くのが利点であり、本文と完全に同じ組版結果まで求めるときだけ `text.usetex=True` のような設定を検討する。

また、図中で使う記号は本文での定義と一致させるべきである。本文で τ を時定数として定義したなら、図の凡例やキャプションでも同じ記号を使う方が親切である。解析内容と図の表現が食い違うと、読者は不要なところで迷う。

9.6 よくある落とし穴

9.6.1 `plt` と `ax` を混ぜて迷子になる

Matplotlib では `plt.xlabel(...)` のような状態依存の書き方もできるが、複数パネルや複数 Figure を扱い始めると、「いまどの Axes が現在の対象なのか」が分かりにくくなる。複雑な図では `fig, ax = plt.subplots(...)` を起点にして、以後は `ax.set_xlabel(...)` のように書く方が安全である。

9.6.2 文字列がカテゴリ軸になる

数字に見える列でも、実際には文字列として読まれていると、Matplotlib は数値軸ではなくカテゴリ軸として解釈する。すると、1, 2, 10, 20 が数値間隔ではなく、単なる 4 つのラベルとして等間隔に並ぶ。

```
1 import matplotlib.pyplot as plt
2
3 x_str = ["1", "2", "10", "20"]
4 y = [1.0, 4.0, 2.0, 5.0]
5 fig, ax = plt.subplots(figsize=(6, 4))
6 ax.plot(x_str, y, marker="o")
```

図 9.10 の左では文字列がカテゴリ軸として扱われ、右では数値へ変換したので数値軸になっている。CSV を読んだ直後に軸の間隔が変だと感じたら、まず `dtype` を疑う方がよい。

9.6.3 `savefig` と余白調整の順序

`savefig` の直前に `tight_layout()` や `constrained_layout` を使わないと、長いラベルや凡例が切れることがある。また、対話環境では `show()` の後に状態が変わることもあるため、再現可能なスクリプトでは「描く、余白を整える、保存する」の順を守る方がよい。対数軸を使う場合は、0 以下の値をそのまま載せられない点にも注意が必要である。




図 9.10 文字列軸と数値軸の違い。左は "1", "2", "10", "20" をカテゴリとして並べており、右は数値として扱っている。

9.6.4 公式資料から似た図を探す

ここまでで、基本的な描画、レイアウト、オブジェクトの役割、保存まで一通り見た。実際の作図では、その先で「似た例をどこから探すか」が次の問題になる。Matplotlib は機能が広いため、作りたい図の名前が分からなくても、公式資料から近いものを探す方が早いことが多い。特に次の 4 つは参照頻度が高い。

- Quick start [22]
- Plot types [23]
- Gallery [24]
- Cheatsheets [25]

作りたいグラフのイメージが先にあるなら、まず Plot types で図の種類を当て、次に Gallery で近い完成例を探し、最後に Cheatsheets で引数名や書式を確認すると迷いにくい。Quick start は、'Figure' と 'Axes' の関係を短時間で思い出したいときに向いている。初学者が最初から完全なコードを自力で組み立てるより、近い例を見つけて必要な部分だけ差し替える方が現実的である。

第 10 章 SciPy による数値計算とフィット

SciPy は、NumPy を土台にして数値計算の道具をまとめたライブラリ群である。pandas が表、Matplotlib が図を担当するのに対して、SciPy は統計、補間、信号処理、最適化、積分といった「計算そのもの」を担当することが多い。本章では、SciPy の考え方、最小限のコード例、落とし穴、解析へのつながりを順に見る。

10.1 SciPy の考え方

10.1.1 NumPy の上にある専門道具箱

SciPy の多くの関数は、NumPy 配列を入力に取り、NumPy 配列やスカラーを返す。したがって、SciPy を理解するには NumPy の ndarray と配列演算に慣れていることが前提になる。その上で、「平均や標準偏差を出したいのか」「曲線を当てたいのか」「ピークを探したいのか」に応じて、適切な subpackage を選ぶ。

- `scipy.stats`: 分布、検定、要約統計
- `scipy.optimize`: 最適化、非線形最小二乗、`curve_fit`
- `scipy.interpolate`: 補間
- `scipy.signal`: フィルタ、ピーク検出、相関、スペクトル処理
- `scipy.integrate`: 数値積分
- `scipy.constants`: 物理定数

何でも SciPy で解くのではなく、「NumPy だけで足りるか」「SciPy のどの subpackage が自然か」を切り分けることが重要である。

10.1.2 関数形を仮定して数値を取り出す

SciPy が特に役立つのは、図や配列を「見た目」で終わらせず、数値へ落とし込む場面である。ヒストグラムから幅を取りたい、減衰曲線から時定数を取りたい、ノイズの多い波形からピーク時刻を取りたい、といった場面では、NumPy の基本操作だけでは足りないことが多い。

ヒストグラムを描いただけでは、分布の特徴を定量化できないことがある。そこで、ある関数形を仮定してパラメータを求める。これがフィットである。フィットは万能ではない。まず、なぜその関数形を選ぶのかという物理的、統計的な理由が必要である。さらに、ヒストグラムの範囲、ビン幅、外れ値処理によって見え方が変わるため、「フィット結果が出た」

ことと「解釈してよい」ことは別である。

フィットの目的は、曲線をきれいに重ねることではない。分布の中心、幅、時定数などを、比較可能な量として取り出すことが目的である。したがって、フィット前に図を見ておくこと、フィット後に残差やずれを確認することが重要になる。

10.1.3 この本でよく使う分布

データ解析では、ガウシアンと指数分布がよく現れる。

- ガウシアン: 時刻差のばらつき
- 指数分布: 待ち時間や発生間隔

もちろん、実際のデータがいつもきれいな理想分布になるとは限らない。重要なのは「なぜその関数を当てようとしたのか」を説明することである。分布の名前を覚えるだけでなく、どの量に対して自然に現れるかを知ること重要である。ガウシアンは独立なばらつきの和として、指数分布はランダムな待ち時間として現れやすい。こうした背景を知っていると、単なる形合わせで終わらない。

たとえば、平均 μ 、標準偏差 σ のガウシアンは

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right]$$

で書ける。また、時定数 τ の指数分布は

$$p(t) = \frac{1}{\tau} \exp\left(-\frac{t}{\tau}\right) \quad (t \geq 0)$$

である。SciPy の分布オブジェクトは、このような確率密度やその積分を関数として評価する道具だと捉えると分かりやすい。

10.2 最小限のコード例

10.2.1 scipy.stats による要約統計と分布

まずは、配列の全体像を数値で確認する方法から始める。

```
1 import numpy as np
2 from scipy import stats
3
4 values = np.array([1.2, 0.9, 1.5, 1.1, 0.8])
5
6 summary = stats.describe(values)
7 print(summary.nobs)
8 print(summary.mean)
9 print(summary.variance)
```

この例では、要素数、平均、分散が順に表示される。

```
5
1.1
0.075
```

`stats.describe()` は、要素数、平均、分散、最小値、最大値、歪度、尖度をまとめて返す。最初の確認として便利だが、返り値は名前付きタプルなので、何が入っているかを読んで使う必要がある。

SciPy の分布オブジェクトは、確率密度関数や累積分布関数を同じ API で扱える。

```
1 x = np.linspace(-3.0, 3.0, 7)
2 pdf = stats.norm.pdf(x, loc=0.0, scale=1.0)
3 cdf = stats.norm.cdf(x, loc=0.0, scale=1.0)
4
5 print(pdf)
6 print(cdf)
```

pdf と cdf を同じ点列で評価すると、次のような値が得られる。

```
[0.00443185 0.05399097 0.24197072 0.39894228 0.24197072 0.05399097
 0.00443185]
[0.0013499  0.02275013 0.15865525 0.5          0.84134475 0.97724987
 0.9986501 ]
```

pdf、cdf、rvs、ppf がそろっているので、理論分布との比較、乱数生成、しきい値計算を統一的に書ける。

ここで pdf は確率密度 $p(x)$ 、cdf はその積分

$$F(x) = \int_{-\infty}^x p(t) dt$$

に対応する。したがって、`stats.norm.cdf(x)` は「 x 以下に入る確率」を返している。

10.2.2 curve_fit によるパラメータ推定

SciPy で最もよく使われる関数の一つが `scipy.optimize.curve_fit` である。モデル関数を自分で定義し、データへ当てはめる。

SciPy には、分布やフィットのための道具が複数ある。代表的なのは `scipy.stats` と `scipy.optimize.curve_fit` である。図 9.8 のような曲線を重ねると、単に形を見るだけでなく、平均や幅、時定数を数値として比較しやすくなる。単純な場合は、自分で平均や分散を計算するだけでも十分なことがある。一方で、より一般的なモデルや誤差評価をしたいなら SciPy が役立つ。

```
1 from scipy.optimize import curve_fit
2
3 def linear_model(x, a, b):
4     return a * x + b
5
6 xdata = np.array([0.0, 1.0, 2.0, 3.0, 4.0])
```

```

7 ydata = np.array([1.1, 2.0, 3.2, 4.1, 5.1])
8
9 params, cov = curve_fit(linear_model, xdata, ydata)
10 errors = np.sqrt(np.diag(cov))
11
12 print(params)
13 print(errors)

```

この線形フィットでは、傾きと切片、およびその標準誤差の目安が次のように出る。

```

[1.02 1.04]
[0.04472136 0.10954451]

```

実際の解析では、ガウシアン平均や幅、指数分布の時定数を次のような形で整理して比較することが多い。

```

mean = 3.02
sigma = 0.79
tau = 2.47

```

`params` は推定パラメータ、`cov` は共分散行列である。対角成分の平方根が標準誤差の目安になる。上の例なら `params[0]` が傾き、`params[1]` が切片に対応する。一方、非対角成分はパラメータ間の相関を表し、値が大きいと「片方を少し動かすと、もう片方で補えてしまう」ような不安定さがあることを示す。重要なのは、`curve_fit()` が単に曲線をきれいに重ねる道具ではなく、「仮定したモデルのパラメータを数値として取り出す道具」だという点である。

上の直線モデル $f(x; a, b) = ax + b$ なら、`curve_fit()` は概ね

$$S(a, b) = \sum_i [y_i - (ax_i + b)]^2$$

を小さくする a と b を探していると考えればよい。より一般には、モデル $f(x; \mathbf{p})$ に対して

$$S(\mathbf{p}) = \sum_i [y_i - f(x_i; \mathbf{p})]^2$$

という残差二乗和を最小化している。

こうした数値が得られたら、次に考えるべきは「図の見た目と整合するか」「別条件のデータと比較して意味があるか」「単位は妥当か」である。数値が出たこと自体より、どう読むかの方が重要である。SciPy を使うときも、ライブラリ名だけを覚えるのではなく、「どの関数が何を入力として何を返すか」を確認する読み方が重要である。

10.3 フィットを進める手順

実際の解析では、次の順に進めると混乱しにくい。

1. まず図を描き、どの関数形が候補かを考える
2. フィット範囲を決める

3. 初期値が必要なら妥当な値を与える
4. フィット曲線を図へ重ねる
5. 推定値と残差を確認する

この順序を踏まずにいきなり `curve_fit()` を呼ぶと、得られた数値が妥当なのか判断しにくい。フィットは関数呼び出しではなく、仮説と検証の手続きとして理解した方がよい。

10.3.1 初期値、制約、残差

モデルによっては、初期値や制約を与えないと不安定になる。

```

1 def exp_model(x, a, tau, c):
2     return a * np.exp(-x / tau) + c
3
4 params, cov = curve_fit(
5     exp_model,
6     xdata,
7     ydata,
8     p0=[5.0, 2.0, 0.0],
9     bounds=([0.0, 0.0, -np.inf], [np.inf, np.inf, np.inf]),
10 )

```

`p0` は初期値、`bounds` はパラメータ範囲である。どちらも万能ではないが、物理的にあり得ない範囲を避けるときには有効である。モデルによっては、初期値の与え方で収束先が変わることがある。また、明らかに負になってほしくないパラメータなどには制約を入れた方が自然なこともある。

フィット結果を図へ重ねるときは、関数形と推定パラメータを凡例に書く方が見やすいことが多い。図の上に直接テキストを置くと、データや曲線と重なって読みにくくなりやすい。特に、比較する図が複数ある場合は、凡例の書式をそろえると見通しが良くなる。

```

1 fig, ax = plt.subplots()
2 ax.hist(values, bins=40, density=True, alpha=0.7, label="sample")
3 ax.plot(
4     x,
5     gaussian_pdf(x, mean, sigma),
6     linewidth=2.0,
7     label=(
8         "fit:␣"
9         r"$f(x)=\frac{1}{\sqrt{2\pi}}\sigma$"
10        r"\exp\{-\frac{(x-\mu)^2}{2\sigma^2}\right}$"
11        "\n"
12        + fr"$\mu={mean:.2f}, \sigma={sigma:.2f}$"
13    ),
14 )
15 ax.legend(loc="upper␣right")

```

図 9.8 でも、フィット曲線の式と推定パラメータは凡例へ入れている。本文、キャプション、凡例の役割を分けると、図全体が読みやすくなる。

```

1 model_y = linear_model(xdata, *params)
2 residual = ydata - model_y
3 print(residual)

```

数値が出たことと、解釈してよいことは別である。残差に系統的な構造が残っていないかを見ないまま結論へ進むべきではない。フィットが見た目に良さそうでも、特定の範囲だけ大きくずれていることがあるため、可能なら残差も確認したい。

また、外れ値や非物理的な領域を含めると、パラメータが不安定になることがある。どの範囲でフィットしたかを書き残すことは、再現性のためにも解釈のためにも重要である。

```

1 mask = (xdata >= 0.0) & (xdata <= 10.0)
2 params, cov = curve_fit(model, xdata[mask], ydata[mask])

```

フィット範囲を切るという行為は、都合の悪い部分を隠すことではなく、どの領域でそのモデルが有効だと考えるかを明示することである。したがって、結果を報告するときは範囲も本文に書くべきである。

10.3.2 sigma を使った重み付きフィット

物理の実データでは、各データポイントが常に同じ信頼度を持つとは限らない。カウント数が少ない点は誤差が大きく、カウント数が多い点は誤差が小さい。この情報を無視してフィットを行うと、信頼性の低い点に引っ張られて誤った結果を生む。各点の信頼度が違うなら、sigma を使って重み付けする。

```

1 y_err = np.array([0.2, 0.2, 1.5, 0.2, 0.2])
2
3 params, cov = curve_fit(
4     linear_model,
5     xdata,
6     ydata,
7     sigma=y_err,
8     absolute_sigma=True,
9 )

```

sigma が大きい点は「ずれても仕方がない点」として弱く効く。図 10.1 は、その差を模式的に示している。

sigma には、通常 ydata の各点に対応する 1 次元配列を渡す。このとき最小化される量は

$$\chi^2(\mathbf{p}) = \sum_i \left(\frac{y_i - f(x_i; \mathbf{p})}{\sigma_i} \right)^2$$

と書けるので、 σ_i が大きい点ほど「ずれても仕方ない点」として弱く効き、 σ_i が小さい点ほど強く効く。カウント数 N が十分大きいポワソン統計なら、典型的には $\sqrt{N}$ を誤差の近似として使う。

absolute_sigma=True は、「今渡した sigma は本当に物理的な標準偏差である」と解釈させる指定である。これを False のままにすると、sigma は相対的な重みとしては使われるが、




図 10.1 `sigma` の有無によるフィット結果の違い。誤差の大きい点を適切に弱く扱わないと、結果全体が不安定になる。

共分散行列の大きさは残差のばらつきに合わせてあとから再スケーリングされる。そのため、推定値の重み付けだけでなく誤差評価まで行いたいなら、`sigma` の意味を明確にした上で `absolute_sigma` の設定も意識する必要がある。

図 10.1 から明らかなように、`sigma` の指定を怠ると結果全体が台無しになる。

10.3.3 `scipy.interpolate` による補間

測定点の間を滑らかにつなぎたいときは補間を使う。SciPy には複数の補間法があるが、まずは 1 次元補間の基本を押さえるとよい。

```
1 from scipy.interpolate import interp1d
2
3 x = np.array([0.0, 1.0, 2.0, 4.0])
4 y = np.array([0.0, 2.0, 1.0, 3.0])
5
6 linear_interp = interp1d(x, y, kind="linear")
7 x_new = np.array([0.5, 1.5, 3.0])
8 y_new = linear_interp(x_new)
9
10 print(y_new)
```

補間点 `x_new` に対しては、次の値が返る。

```
[1.  1.5  2. ]
```

補間は「元データの間をつなぐ」操作であり、「外側まで正しく予測する」操作ではない。外挿まで含めて解釈すると危険である。

線形補間では、各区間 $x_i \leq x \leq x_{i+1}$ で

$$y(x) = y_i + \frac{y_{i+1} - y_i}{x_{i+1} - x_i}(x - x_i)$$

という一次式を使っている。したがって、測定点の間では滑らかにつながるが、測定範囲の外ではこの式をそのまま信じる根拠はない。

10.3.4 scipy.signal による平滑化とピーク検出

波形や時系列では、ピークの検出や軽い平滑化がよく必要になる。

```
1 from scipy.signal import savgol_filter, find_peaks
2
3 x = np.linspace(0.0, 20.0, 200)
4 signal = np.sin(x) + 0.15 * np.random.default_rng(7).normal(size=x.size)
5
6 smooth = savgol_filter(signal, window_length=11, polyorder=3)
7 peaks, props = find_peaks(smooth, height=0.7, distance=15)
8
9 print(peaks[:5])
10 print(props["peak_heights"][:5])
```

この例では、検出されたピーク位置とその高さが次のように表示される。

```
[ 15  77 140]
[0.94402164 1.14918478 1.00061725]
```

savgol_filter() は局所多項式で平滑化する。find_peaks() は高さ、距離、prominence などの条件でピーク候補を探す。ピーク数を自分で数える前に、こうした既製の道具があることを知っておくとよい。

10.3.5 scipy.integrate と scipy.constants

積分や定数も SciPy でまとめて扱える。

```
1 from scipy import constants
2 from scipy.integrate import simpson
3
4 x = np.linspace(0.0, np.pi, 101)
5 y = np.sin(x)
6
7 area = simpson(y, x=x)
8 print(area)
9 print(constants.c)
```

この積分値と光速定数は、次のように出力される。

```
2.00000000108245044
299792458.0
```

simpson() は、ここでは

$$\int_0^{\pi} \sin x \, dx = 2$$

という積分を、離散点 (x_i, y_i) から数値的に評価している。したがって、simpson(y, x=x) は

「 $y(x)$ をサンプル点から積分する関数」と読めばよい。また、`constants.c` は

$$c = 299792458 \text{ m s}^{-1}$$

を表す定数である。ただし、単位付き計算や時刻系まで含めて厳密に扱いたいなら、次章の `Astropy` の方が自然な場面も多い。

10.4 よくある落とし穴

10.4.1 モデル選択の理由がないままフィットしない

ガウシアン、指数、直線のどれを使うかは、物理的・統計的な理由が必要である。見た目がそれらしく重なったという理由だけでモデルを採用すると、パラメータの意味も崩れる。

10.4.2 初期値と制約を無視しない

非線形フィットは、初期値次第で別の極小へ落ちたり、収束しなかったりする。`curve_fit()` が値を返したからといって、それが唯一の解だとは限らない。複数の初期値で試す、図へ重ねて見る、残差を見る、といった確認が必要である。

10.4.3 補間と外挿を混同しない

`interp1d()` や `spline` は、観測点の間を埋めるための道具である。測定範囲の外で値を予測すると、もっともらしい数字が出ても根拠は薄い。外側までモデル化したいなら、補間ではなく関数フィットとして考えた方がよい。

10.4.4 信号処理ではサンプリング間隔を意識する

`find_peaks()` の `distance` やフィルタ長は、サンプル数で指定することが多い。したがって、時間軸が 1 サンプル 1 ns なのか 10 ns なのかで、同じ数値でも意味が変わる。コード中の数字をそのまま流用せず、軸の単位へ戻して考える必要がある。

10.5 解析へのつながり

`SciPy` は、解析の中で次のような役割を持つ。

1. `stats` で分布の形や要約統計を確認する
2. `signal` でピーク候補や平滑化を行う
3. `interpolate` で校正曲線や補助曲線を作る
4. `optimize` でモデルパラメータを推定する
5. `integrate` や `constants` で計算を閉じる

ここで重要なのは、`SciPy` が「魔法の黒箱」ではないという点である。入力配列がどうい

う意味を持ち、返ってきた値をどう解釈するかは自分で決めなければならない。特にフィットでは、図を見る、範囲を切る、重み付けを考える、残差を見る、という手順を省略すべきではない。

ここまで見てきた SciPy は、主に「数値をどう計算するか」を受け持つ道具である。時刻系、単位、座標系、FITS のように「数値そのものの意味付け」まで含めて扱いたくなったところで、次章の Astropy が必要になる。SciPy は計算アルゴリズム、Astropy は物理量や観測量の表現を担当すると考えると、章のつながりも見えやすい。

本文を読み終えた後で関数名や引数を確認したいときは、SciPy User Guide [27] を起点にすると探しやすい。分布や検定は Statistics [28]、フィットや最適化は Optimization [29]、補間は Interpolation [30]、波形処理は Signal processing [31]、数値積分は Integration [32] が対応している。本章は、それらを解析で使う順に並べ替えて説明した。

第 11 章 Astropy による時刻・単位・天体データ処理

Astropy は、天文学や宇宙物理の解析で頻出する「単位付き物理量」「時刻系」「座標系」「FITS」「天文向け表」を安全に扱うためのライブラリである。NumPy や SciPy だけでも数値計算はできるが、単位や時刻系を自前で文字列管理すると、解釈違いや換算ミスが入りやすい。本章では、Astropy の考え方、最小限のコード例、落とし穴、解析へのつながりを整理する。

11.1 Astropy の考え方

11.1.1 数値だけでなく意味も持たせる

Astropy の中心的な発想は、「数値そのもの」ではなく「何の単位で、どの時刻系で、どの座標系なのか」までオブジェクトへ持たせることである。例えば 100 という値だけでは、100 ns なのか 100 ms なのか分からない。Astropy の Quantity を使えば、この曖昧さを減らせる。

```
1 import astropy.units as u
2
3 time_window = 250 * u.ns
4 speed = 299792458 * u.m / u.s
5 distance = speed * time_window
6
7 print(distance)
8 print(distance.to(u.m))
```

この計算では、単位付きのまま距離が評価され、次のように表示される。

```
74.9481145 m
74.9481145 m
```

この例では、`250 * u.ns` という時点で「250 ns」という意味が値に埋め込まれている。式の途中で単位を落とさない限り、単位換算はライブラリが引き受ける。

数式で書けば、ここで行っているのは

$$d = v\Delta t$$

である。特に $v = c$ とみなすなら、250 ns の時間窓に対応する距離 $d = c\Delta t$ をそのまま安全に計算できる。

11.1.2 時刻系と座標系を自前で持たない

観測データでは、UTC、TAI、TT、MJD、JD、Unix time が混在することがある。これを自前の文字列処理でつなぐと、秒境界やうるう秒で破綻しやすい。Astropy の Time と SkyCoord は、こうした表現を専用オブジェクトとして扱う。

11.2 最小限のコード例

11.2.1 units と Quantity

単位付き計算の基本は Quantity である。

```
1 import astropy.units as u
2
3 length = 3.2 * u.m
4 time = 12.5 * u.ns
5 velocity = length / time
6
7 print(velocity)
8 print(velocity.to(u.m / u.s))
```

単位変換の結果は次の通りである。

```
0.256 m / ns
256000000.0 m / s
```

to() を使えば単位変換を明示できる。解析メモの段階では、いきなり .value で生の数値へ落とさず、できるだけ単位付きのまま式を組んだ方が安全である。

この計算は

$$v = \frac{L}{t}$$

に対応しており、具体的には

$$v = \frac{3.2 \text{ m}}{12.5 \text{ ns}} = 0.256 \text{ m/ns} = 2.56 \times 10^8 \text{ m/s}$$

である。コードと単位換算を一緒に見ておくと、桁や接頭辞の取り違えに気が付きやすい。

11.2.2 物理定数

Astropy には物理定数も入っている。SciPy の constants と似ているが、こちらは単位付きで返る点が大い。

```
1 from astropy.constants import c, k_B
2
3 print(c)
4 print(k_B)
```

Astropy の定数オブジェクトを表示すると、値だけでなく単位と参照元も確認できる。

```
Name   = Speed of light in vacuum
Value   = 299792458.0
Uncertainty = 0.0
Unit    = m / s
Reference = CODATA 2018
Name    = Boltzmann constant
Value   = 1.380649e-23
Uncertainty = 0.0
Unit    = J / K
Reference = CODATA 2018
```

数値と単位が一緒に出るので、式の中で何を使っているかを見失いにくい。

11.2.3 Time による時刻表現

Astropy の Time は、複数のフォーマットと複数の時刻系をまたいで扱える。

```
1 from astropy.time import Time
2
3 t = Time("2026-04-12T12:34:56.123456789", format="iso", scale="utc")
4
5 print(t.mjd)
6 print(t.unix)
7 print(t.tai.iso)
```

同じ時刻を複数の表現へ変換すると、次の値が得られる。

```
61142.52426068816
1775997296.1234567
2026-04-12 12:35:33.123
```

format="iso" は入力形式、scale="utc" は時刻系を表す。mjd、unix、tai.iso のように別形式・別時刻系へ変換できる。重要なのは、datetime の代替品というより、「観測時刻を正しい時刻系のまま持つ道具」として捉えることである。

たとえば、修正ユリウス日 MJD は

$$\text{MJD} = \text{JD} - 2400000.5$$

で定義される。Astropy は、このような時刻表現どうしの対応を自前で管理せずに済むようにしてくれる。

11.2.4 時刻差と TimeDelta

差分計算も Time のまま行える。

```
1 from astropy.time import Time
2
3 t1 = Time("2026-04-12T12:00:00.000000100", format="isot", scale="utc")
```

```

4 t2 = Time("2026-04-12T12:00:00.000000320", format="isot", scale="utc")
5 dt = t2 - t1
6
7 print(dt)
8 print(dt.to_value("ns"))

```

時刻差をそのまま表示した結果と、ns へ変換した結果は次の通りである。

```

2.2e-07
220.0

```

このように書くと、秒境界や日付境界をまたいでも同じ考え方で差分が取れる。課題のように 250 ns の窓を扱うときも、自前で桁を切り貼りするより安全である。

ここで計算しているのは単純に

$$\Delta t = t_2 - t_1 = 220 \text{ ns}$$

である。重要なのは、コード上では単に引き算しているだけでも、背後で時刻系と単位が保たれている点である。

11.2.5 SkyCoord による座標変換

Astropy の coordinates は、天球上の座標系を変換する。

```

1 from astropy.coordinates import SkyCoord
2 import astropy.units as u
3
4 coord = SkyCoord(ra=150.0 * u.deg, dec=20.0 * u.deg, frame="icrs")
5 gal = coord.galactic
6
7 print(gal.l.deg)
8 print(gal.b.deg)

```

座標変換後の銀河経度と銀河緯度は次の通りである。

```

213.80097741291977
50.26374216488792

```

重要なのは、ra と dec に単位を付けている点である。度なのかラジアンなのかを曖昧にしない方が安全である。

この操作は、赤道座標 (α, δ) から銀河座標 (l, b) への変換に対応する。天球上の回転そのものは自分で式を書かなくても、入力座標系と出力座標系を明示すれば Astropy が一貫して扱える。

11.2.6 Table と QTable

Astropy には表処理のために Table と QTable がある。QTable は列へ単位を保持できる。

```

1 from astropy.table import QTable

```

```

2 import astropy.units as u
3
4 table = QTable()
5 table["time"] = [0.0, 1.0, 2.0] * u.s
6 table["signal"] = [12.4, 10.1, 14.8] * u.mV
7 table["detector"] = ["A", "A", "B"]
8
9 print(table)

```

QTable を表示すると、列名だけでなく単位も一緒に確認できる。

time	signal	detector
s	mV	
0.0	12.4	A
1.0	10.1	A
2.0	14.8	B

QTable は pandas の DataFrame より単位との相性がよい。一方で、複雑な groupby や join、列演算の豊富さでは pandas や Polars の方が便利なのも多い。どちらを中心にするかは、何を守りたいかで決まる。

11.2.7 Astropy Table と pandas の行き来

Astropy の表と pandas の DataFrame は相互変換できるが、単位や時刻の情報が完全には残らないことがある。

```

1 df = table.to_pandas()
2 print(df)

```

to_pandas() は便利だが、どの情報が失われるかを理解してから使う方がよい。特に単位やマスク情報を持つ列は、変換後の解釈を確認した方が安全である。

11.2.8 astropy.io.fits による FITS の読み書き

天文データでは FITS が標準的である。Astropy なら NumPy 配列やヘッダをそのまま扱える。

```

1 import numpy as np
2 from astropy.io import fits
3
4 image = np.arange(9).reshape(3, 3)
5 hdu = fits.PrimaryHDU(image)
6 hdu.header["OBJECT"] = "test"
7 hdu.writeto("image.fits", overwrite=True)
8
9 with fits.open("image.fits") as hdul:
10     data = hdul[0].data
11     header = hdul[0].header
12

```

```
13 print(data.shape)
14 print(header["OBJECT"])
```

FITS を書いてから読み直すと、配列形状とヘッダ値は次のように確認できる。

```
(3, 3)
test
```

`fits.open()` は HDU のリストを返す。画像なら `PrimaryHDU`、表なら `BinTableHDU` である。最初は「どの HDU に何が入っているか」を確認し、その後で必要なデータだけ読む方が混乱しにくい。

11.2.9 ASCII や ECSV も読める

Astropy の表入出力は FITS だけではない。`Table.read()` は ASCII、CSV、ECSV などにも対応している。

```
1 from astropy.table import Table
2
3 tbl = Table.read("events.ecsv", format="ascii.ecsv")
```

ECSV は単位やメタデータを持たせやすいので、テキスト形式のまま情報を落としにくい。共同研究や中間生成物の受け渡しでは便利である。

11.3 よくある落とし穴

11.3.1 `.value` を早く使い過ぎない

`Quantity.value` を使うと、生の NumPy 配列やスカラーへ戻る。これは便利だが、その瞬間に単位情報は消える。式の早い段階で `.value` を多用すると、「何 ns のつもりだったか」「何 mV のつもりだったか」が見えなくなる。

11.3.2 時刻系を省略しない

`Time("2026-04-12 12:00:00")` とだけ書くと、どの format と scale を想定しているのかが曖昧になる。特に UTC、TAI、TT をまたぐときは、`format=` と `scale=` を明示した方が安全である。

11.3.3 座標変換には観測条件が必要なことがある

赤道座標から銀河座標への変換だけなら比較的単純だが、地平座標へ変換するには観測地点や観測時刻が必要になる。座標系だけを変えているつもりでも、背後では時刻と場所が意味を持つことがある。

11.3.4 DataFrame への変換で情報が落ちる

Astropy Table を pandas や Polars へ変換すると、単位、マスク、時刻系、メタデータが薄まることもある。逆に pandas の強い groupby や join を使いたいからといって、何でも最初から DataFrame にするべきではない。まず何を保存したいのかを決める方がよい。

11.4 解析へのつながり

ここまでの節を踏まえると、Astropy が効いてくる場面はかなりはっきりしている。典型例を挙げると、次の通りである。

- 観測時刻を UTC、MJD、JD、Unix time の間で変換したいとき
- ns、 μ s、mV、MeV などの単位を混ぜて計算したいとき
- 天球座標を別の座標系へ変換したいとき
- FITS 画像や FITS テーブルを直接読み書きしたいとき
- 表データに単位やメタデータを持たせたまま運びたいとき

一方で、巨大な表の集計や複雑な join を高速に回すなら、pandas や Polars の方が便利である。実務では、まず Astropy で単位と時刻を正しく解釈し、その後に必要な部分だけを pandas や Polars へ渡して集計し、最後に Matplotlib や SciPy へつなぐことが多い。

ここまでの内容を公式資料で引き直すなら、まず Getting Started [34] と User Guide [35] を入口にするとよい。その上で、単位は Units and Quantities [36]、時刻は Time and Dates [37]、座標は Coordinates [38]、表は Tables [39]、FITS は FITS File Handling [40] が対応している。本章では、それらの中でも観測データ解析で頻繁に使う順に絞って説明した。

第 12 章 自作モジュールを作って再利用する

解析コードは最初、1 本のスクリプトとして書き始めることが多い。しかし、同じ処理を別の日のデータにも使いたくなり、さらに別のプロジェクトからも呼びたくなると、単発スクリプトのままでは管理しにくい。こういうときは、処理を自作モジュールとして切り出し、必要ならパッケージとしてインストールできる形へ整理した方がよい。

ここでいう「モジュール」は、`plotting.py` や `models.py` のような Python ファイル 1 つを指すことが多い。一方、「パッケージ」は、それらのモジュールをディレクトリとしてまとめ、`import` できる形にした単位である。本章では、`uv` を使ってパッケージ開発を始め、`pip install` や `pip install -e` で使えるようにするまでを、具体例付きで順に見ていく。

12.1 なぜ自作モジュールにするのか

処理をモジュールへ分ける利点は、単にファイル数が増えることではない。役割ごとに分離でき、テストしやすくなり、エディタから補完やドキュメントも見やすくなる。特に解析では、次のような部品が再利用されやすい。

- データ読み込み関数
- フィルタ条件やカットの判定関数
- 図を作成して保存する関数
- フィット関数やモデル関数

こうした処理を `main.py` の中へすべて書いてしまうと、別スクリプトから流用するときにはコピーペーストが増える。コピー元とコピー先がずれると、片方だけバグ修正される、といった問題も起こりやすい。自作モジュールへ切り出して `from histfit_tools import save_histogram_with_fit` のように呼べる形にしておけば、修正箇所は 1 か所で済む。

12.2 `uv` でパッケージ開発を始める

12.2.1 最初の初期化

本書では、単発スクリプトではなく「後で `import` される部品」として育てたいので、`uv init --package` から始めるのが自然である。たとえばヒストグラム作図用のパッケージを作るなら、次のように実行する。

```
$ mkdir histfit_tools
$ cd histfit_tools
```

```
$ uv init --package
$ uv add numpy matplotlib scipy
$ uv add --dev pytest ruff
$ uv sync
```

uv add で追加した numpy、matplotlib、scipy は、このパッケージを使うときにも必要な実行時依存関係である。一方、pytest や ruff は開発者だけが使う道具なので、--dev 付きで追加する。たとえば pytest は、本章で後から示す tests/test_models.py のように、linear が期待通りの値を返すか、未知のモデル名で ValueError が正しく送出されるかなどのテストを行う際に使用する。ruff は、uv run ruff check . として実行し、未使用 import や単純な書式崩れを commit 前に見つけるための道具である。pytest や ruff によるテストは必須ではないが、将来的にパッケージを公開する予定があるなら早い段階で実装しておくことが好ましい。

最終的なディレクトリ構成は、少なくとも次のように整理したい。

histfit_tools/ の例

```
.gitignore
.python-version
README.md
pyproject.toml
src/
`-- histfit_tools/
    |-- __init__.py
    |-- models.py
    `-- plotting.py
tests/
`-- test_models.py
```

ここで src/ の下にパッケージを置く構成を src レイアウトという。これは、作業ディレクトリ直下にあるファイルをたまたま import してしまう事故を防ぎやすい。パッケージとして配布する前提なら、この構成にしておく方が後で困りにくい。

12.2.2 pyproject.toml の役割

パッケージ開発では、pyproject.toml が中心になる。ここにはパッケージ名、Python バージョン条件、依存関係、ビルド方法などを書く。上の例なら、少なくとも次のような内容になる。

pyproject.toml

```
[project]
name = "histfit_tools"
version = "0.1.0"
description = "Histogram plotting and fitting utilities."
readme = "README.md"
requires-python = ">=3.12"
dependencies = [
```

```

"matplotlib>=3.10",
"numpy>=2.0",
"scipy>=1.15",
]

[build-system]
requires = ["hatchling"]
build-backend = "hatchling.build"

[dependency-groups]
dev = [
    "pytest>=8.3",
    "ruff>=0.11",
]

```

`dependencies` に書いた内容は、このパッケージを `pip install` したときに一緒に解決される。つまり、「自分の環境でたまたま入っているから動く」のではなく、「このパッケージを使うにはこれが必要だ」と宣言していることになる。

一方、`uv.lock` は開発側で環境を厳密にそろえるためのファイルである。自分のリポジトリへ戻ってきたときや、共同研究者が同じ環境を再現したいときには `uv lock` や `uv sync` が役に立つ。しかし、利用者が `pip install` するときに参照するのは基本的に `pyproject.toml` であり、`uv.lock` ではない。この違いは重要である。

12.3 具体例: ヒストグラムとフィットをまとめたパッケージ

ここでは、1 次元データを与えると、`numpy.histogram` でヒストグラムを作り、`matplotlib` の `errorbar` で描き、必要なら `scipy.optimize.curve_fit` でフィットした曲線を重ねて保存する関数を作る。要求仕様は次の通りとする。

- データ列と保存先を受け取る
- `bins` か `bin_width` のどちらかでビンを指定できる
- `fit=False` にするとフィットせずにヒストグラムだけ保存する
- `linear`、`quadratic`、`power_law`、`gaussian` を名前で選べる
- 自分で定義した関数もそのまま渡せる
- フィット初期値 `p0` も引数から与えられる

12.3.1 モデル関数を分ける

まず、フィット関数群を `models.py` へ切り出す。

`src/histfit_tools/models.py`

```

1 from collections.abc import Callable
2
3 import numpy as np

```

```

4
5 ModelFunc = Callable[..., np.ndarray]
6
7
8 def linear(x: np.ndarray, a: float, b: float) -> np.ndarray:
9     """一次関数  $y = ax + b$  を返す。"""
10    return a * x + b
11
12
13 def quadratic(x: np.ndarray, a: float, b: float, c: float) -> np.ndarray:
14     """二次関数  $y = ax^2 + bx + c$  を返す。"""
15    return a * x**2 + b * x + c
16
17
18 def power_law(x: np.ndarray, amplitude: float, alpha: float) -> np.ndarray:
19     """べき関数  $amplitude * x^alpha$  を返す。  $x > 0$  を仮定する。"""
20    return amplitude * np.power(x, alpha)
21
22
23 def gaussian(
24     x: np.ndarray,
25     amplitude: float,
26     mean: float,
27     sigma: float,
28     offset: float,
29 ) -> np.ndarray:
30     """ガウス関数と定数オフセットを返す。"""
31     z = (x - mean) / sigma
32     return amplitude * np.exp(-0.5 * z**2) + offset
33
34
35 NAMED_MODELS: dict[str, ModelFunc] = {
36     "linear": linear,
37     "quadratic": quadratic,
38     "power_law": power_law,
39     "gaussian": gaussian,
40 }
41
42
43 def resolve_model(model: str | ModelFunc) -> ModelFunc:
44     """名前または callable からフィット関数を返す。"""
45     if callable(model):
46         return model
47
48     try:
49         return NAMED_MODELS[model]
50     except KeyError as exc:
51         names = ", ".join(sorted(NAMED_MODELS))
52         raise ValueError(f"Unknown model: {model}. Choose from {names}." ) from exc

```

モデル関数を別ファイルへ置いておくと、作図ロジックと数学的なモデルが分離される。その結果、後で指数減衰やローレンツ関数を追加したくなったときも、`plotting.py` を大きく書き換えずに済む。

12.3.2 pytest で最小のテストを書く

`tests/test_models.py` は、`models.py` の公開関数が最低限期待通りに振る舞うかを確認するためのファイルである。ここでは、式の値そのもの、ガウス関数の基本的な形、未知のモデル名に対する例外の 3 点だけを確認しておく。

```
tests/test_models.py
1 import numpy as np
2 import pytest
3
4 from histfit_tools.models import gaussian, linear, resolve_model
5
6
7 def test_linear_returns_expected_values() -> None:
8     x = np.array([0.0, 1.0, 2.0])
9     y = linear(x, 2.0, 1.0)
10    assert np.allclose(y, [1.0, 3.0, 5.0])
11
12
13 def test_gaussian_has_peak_at_mean() -> None:
14     x = np.array([4.0, 5.0, 6.0])
15     y = gaussian(x, amplitude=10.0, mean=5.0, sigma=1.0, offset=2.0)
16     assert y[1] == pytest.approx(12.0)
17     assert y[1] > y[0]
18     assert y[0] == pytest.approx(y[2])
19
20
21 def test_resolve_model_rejects_unknown_name() -> None:
22     with pytest.raises(ValueError):
23         resolve_model("lorentzian")
```

最初のテストは、一次関数の実装が式通りかを直接確かめている。2 つ目は、ガウス関数が平均値の位置で最大になり、左右対称になることを見ている。3 つ目は、誤ったモデル名を黙って通さず、利用者へ早い段階でエラーを返すことを確かめるテストである。

実行は次のように行う。

```
$ uv run pytest
$ uv run ruff check .
```

ここで `pytest` は関数の振る舞いを確かめ、`ruff` は未使用 `import` や単純な書式の乱れを確認する。今回のような小さなパッケージでも、この 2 つがあるだけで「動いているつもり」の状態を減らしやすい。

12.3.3 ヒストグラムを作って保存する関数

次に、実際の主役である `save_histogram_with_fit` を `plotting.py` に書く。

```
src/histfit_tools/plotting.py

1 from collections.abc import Sequence
2 from pathlib import Path
3
4 import matplotlib.pyplot as plt
5 import numpy as np
6 from numpy.typing import ArrayLike
7 from scipy.optimize import curve_fit
8
9 from .models import ModelFunc, resolve_model
10
11
12 def _make_bin_edges(
13     values: np.ndarray,
14     bins: int | Sequence[float] | None,
15     bin_width: float | None,
16     data_range: tuple[float, float] | None,
17 ) -> np.ndarray:
18     if bins is not None and bin_width is not None:
19         raise ValueError("Specify either bins or bin_width, not both.")
20
21     if data_range is None:
22         low = float(np.min(values))
23         high = float(np.max(values))
24     else:
25         low, high = data_range
26
27     if low == high:
28         high = low + 1.0
29
30     if bin_width is not None:
31         if bin_width <= 0:
32             raise ValueError("bin_width must be positive.")
33         return np.arange(low, high + bin_width, bin_width)
34
35     if bins is None:
36         bins = 40
37
38     if isinstance(bins, int):
39         return np.linspace(low, high, bins + 1)
40
41     return np.asarray(bins, dtype=float)
42
43
44 def save_histogram_with_fit(
```

```

45     data: ArrayLike,
46     output_path: str | Path,
47     *,
48     bins: int | Sequence[float] | None = 40,
49     bin_width: float | None = None,
50     data_range: tuple[float, float] | None = None,
51     fit_model: str | ModelFunc = "gaussian",
52     fit: bool = True,
53     p0: Sequence[float] | None = None,
54     xlabel: str = "x",
55     ylabel: str = "Counts",
56     title: str | None = None,
57 ) -> Path:
58     """ヒストグラムと誤差棒を描き、必要ならフィット線も重ねて保存する。
59
60     Args:
61         data: 1次元データ列。
62         output_path: 保存先ファイル名。
63         bins: ビン数またはビン境界列。
64         bin_width: ビン幅。binsと同時に指定しない。
65         data_range: ヒストグラム範囲。
66         fit_model: モデル名または自作callable。
67         fit: Falseならフィットを実行しない。
68         p0: curve_fitへ渡す初期値。
69         xlabel: x軸ラベル。
70         ylabel: y軸ラベル。
71         title: 図タイトル。
72
73     Returns:
74         保存したファイルのPath。
75     """
76     values = np.asarray(data, dtype=float)
77     if values.ndim != 1:
78         raise ValueError("data must be one-dimensional.")
79
80     bin_edges = _make_bin_edges(values, bins, bin_width, data_range)
81     counts, bin_edges = np.histogram(values, bins=bin_edges)
82     centers = 0.5 * (bin_edges[:-1] + bin_edges[1:])
83     errors = np.sqrt(counts)
84
85     fig, ax = plt.subplots()
86     ax.errorbar(centers, counts, yerr=errors, fmt="o", capsize=3, label="data")
87
88     if fit:
89         model = resolve_model(fit_model)
90         sigma = np.where(errors > 0, errors, 1.0)
91         params, _ = curve_fit(
92             model,
93             centers,

```

```

94         counts,
95         p0=p0,
96         sigma=sigma,
97         absolute_sigma=True,
98         maxfev=10000,
99     )
100     x_fit = np.linspace(bin_edges[0], bin_edges[-1], 400)
101     y_fit = model(x_fit, *params)
102     ax.plot(x_fit, y_fit, label="fit")
103
104     ax.set_xlabel(xlabel)
105     ax.set_ylabel(ylabel)
106     if title is not None:
107         ax.set_title(title)
108     ax.legend()
109
110     output_path = Path(output_path)
111     output_path.parent.mkdir(parents=True, exist_ok=True)
112     fig.savefig(output_path, dpi=150, bbox_inches="tight")
113     plt.close(fig)
114     return output_path

```

この関数では、ビン境界の決定と作図本体を分けている。こうしておくと、ビン幅指定のロジックだけを単独にテストしやすい。また、`fit_model` が文字列なら既定のモデル群から選び、`callable` ならそのまま使うので、利用者は既定モデルと自作モデルを同じ引数で扱える。

12.3.4 公開インタフェースを `__init__.py` で整える

パッケージの外から使ってほしい関数は、`__init__.py` でまとめて再公開しておくといよい。

```

src/histfit_tools/__init__.py
1  """Histogram plotting and fitting utilities."""
2
3  from .models import gaussian, linear, power_law, quadratic
4  from .plotting import save_histogram_with_fit
5
6  __all__ = [
7      "gaussian",
8      "linear",
9      "power_law",
10     "quadratic",
11     "save_histogram_with_fit",
12 ]

```

こうしておけば、利用側は `from histfit_tools import save_histogram_with_fit` と短く書ける。内部ファイル構成を後で整理し直しても、公開 API を保っている限り、利用者側のコードを壊しにくい。

12.3.5 使い方の例

実際にこのパッケージを使うスクリプトは、たとえば次のようになる。

```
1 from pathlib import Path
2
3 import numpy as np
4
5 from histfit_tools import save_histogram_with_fit
6
7 rng = np.random.default_rng(42)
8 data = rng.normal(loc=5.0, scale=1.2, size=4000)
9
10 save_histogram_with_fit(
11     data,
12     Path("figures/gaussian_fit.png"),
13     bins=35,
14     fit_model="gaussian",
15     p0=[250.0, 5.0, 1.0, 1.0],
16     xlabel="signal[mV]",
17     title="Gaussian_fit_example",
18 )
19
20 save_histogram_with_fit(
21     data,
22     Path("figures/hist_only.png"),
23     bin_width=0.2,
24     fit=False,
25     xlabel="signal[mV]",
26 )
```

1 つ目はガウス関数でフィットし、2 つ目は `fit=False` としてヒストグラムだけを保存している。ビン数指定とビン幅指定の両方が動くことも、この 2 例で確認できる。

自作関数を渡す例も示しておこう。たとえば指数減衰を仮定したいなら、次のように書ける。

```
1 import numpy as np
2
3 from histfit_tools import save_histogram_with_fit
4
5
6 def exponential_decay(
7     x: np.ndarray,
8     amplitude: float,
9     tau: float,
10    offset: float,
11 ) -> np.ndarray:
12     return amplitude * np.exp(-x / tau) + offset
13
```

```

14
15 save_histogram_with_fit(
16     data,
17     "figures/custom_fit.png",
18     bin_width=0.25,
19     fit_model=exponential_decay,
20     p0=[120.0, 3.0, 5.0],
21 )

```

このように、`fit_model` へ callable を渡せるようにしておけば、パッケージ側は柔軟性を保ちつつ、利用者側は自分の解析に必要なモデルを差し込める。

12.4 docstring、型ヒント、README

自作モジュールは、動くだけでは不十分である。後から自分で使うときにも、他人が使うときにも、「何を受け取り、何を返すか」がすぐ分かる形で書いておく方がよい。そのために有効なのが docstring、型ヒント、README である。

12.4.1 docstring と型ヒント

基礎編で見た docstring だが、パッケージではその重要性がさらに増す。特に、引数の意味や既定値、返り値、例外条件まで書いておくと、`help()` だけでなくエディタの補完でも内容が見やすくなる。

先ほどの `save_histogram_with_fit` には、`data: ArrayLike`、`output_path: str | Path`、`fit: bool = True` のような型ヒントが付いている。VS Code などのエディタでは、関数名にカーソルを合わせたときや補完候補を開いたときに、これらの型ヒントと docstring の先頭がそのまま表示されることが多い。つまり、docstring は文書であると同時に、普段のコーディング画面そのものへ表示される説明でもある。

そのため、docstring の最初の 1 行には、関数の役割を簡潔に書く方がよい。たとえば「ヒストグラムと誤差棒を描き、必要ならフィット線も重ねて保存する。」のように書けば、補完欄を見ただけでも関数の用途が分かる。

12.4.2 README に書くべきこと

`README.md` は、リポジトリを開いた人が最初に読む文書である。少なくとも次の 4 点は入れておきたい。

- このパッケージが何をするか
- どうインストールするか
- 最小の使用例
- 主要な依存関係

たとえば最小限の README は次のようになる。

README.md

```
# histfit_tools

Histogram plotting and fitting utilities for analysis scripts.

## Installation

```bash
pip install .
```

## Example

```python
from histfit_tools import save_histogram_with_fit
```
```

将来 GitHub へ置いたり、研究室内で URL を共有したりするときも、README があるだけで入口がかなり分かりやすくなる。docstring は関数単位の説明、README はパッケージ全体の説明、と役割を分けると整理しやすい。

12.5 pip install . と pip install -e .

12.5.1 通常インストール

作ったパッケージを別の環境から使いたいときは、パッケージのルートディレクトリで `pip install .` を実行する。

```
$ source .venv/bin/activate
$ pip install .
```

これは「いまのソースコードのスナップショットを環境へインストールする」操作である。したがって、後から `src/histfit_tools/plotting.py` を編集しても、その変更は自動では反映されない。もう一度 `pip install .` し直す必要がある。

12.5.2 editable install

開発中は、`pip install -e .` の方が便利である。

```
$ source .venv/bin/activate
$ pip install -e .
```

`-e` は `editable` の略であり、環境にコピーを置く代わりに、手元のソースディレクトリを参照する形でインストールする。つまり、Python ファイルを編集した結果がすぐ `import` 側へ反映される。関数定義や docstring を調整しながら試す段階では、こちらを使う方が自然である。

ただし、`editable install` は「何もかも自動で再ビルドされる」という意味ではない。`pyproject.toml` の依存関係を書き換えたときや、後述する `pybind11` のような C++ 拡張を編集したときは、再インストールや再ビルドが必要になることがある。この点は覚えておいた方がよい。

12.5.3 インストール確認

インストール後は、短い `import` テストを必ずしておく方がよい。

```
$ python -c "from histfit_tools import save_histogram_with_fit; print(save_histogram_with_fit)"
```

`ImportError` が出なければ、少なくともパッケージとして見つかっている。さらに依存関係も含めて確認したいなら、短い実データや乱数データで関数を 1 回実行して、図ファイルが保存されることまで確認すると確実である。

12.6 Git リポジトリへ置いて共有する

研究室内や共同研究で共有するなら、Git リポジトリとして管理しておく方がよい。`uv init --package` は既定では `.git/` も作るので、通常は改めて `git init` し直す必要はない。

GitHub で共有する場合は、まず GitHub の Web 画面で空のリポジトリを 1 つ作る。ここではリポジトリ名と公開範囲だけを決めればよい。`README` や `.gitignore` は手元ですでに用意しているので、最初は GitHub 側で追加しない方が流れが単純である。

その準備ができれば、手元では次のように進めればよい。

```
$ git add pyproject.toml README.md src tests .python-version
$ git commit -m "Create histfit_tools package"
$ git remote add origin git@github.com:username/histfit_tools.git
$ git push -u origin main
```

`uv init --vcs none` のように Git 初期化を明示的に無効化して始めた場合には、最初に `git init` が必要になる。

`.venv/` や `__pycache__/` はコミットしないので、`.gitignore` に書いておくのがよい。Git の詳細については付録 B を参照されたい。

GitHub などへ置いたリポジトリは、別環境からそのまま `pip install` できる。たとえば次のように書く。

```
$ pip install "git+ssh://git@github.com:username/histfit_tools.git"
```

タグやコミットを固定したいなら、URL の末尾に `@v0.1.0` や `@9f3c1a2` を付ける。

```
$ pip install "git+ssh://git@github.com:username/histfit_tools.git@v0.1.0"
```

これは再現性のために重要である。研究ノートや論文用メモには、「どのタグを入れたか」まで残しておく方が後で確実である。

12.7 依存関係をどう書くか

最後に、依存関係の考え方を整理しておく。パッケージでは「いま自分の環境で動く」ことより、「利用者の環境でも必要なものが入る」ことの方が重要である。そのため、次の3種類を区別するとよい。

実行時依存関係 パッケージを `import` して使うだけで必要なもの。今回なら `numpy`、`matplotlib`、`scipy` がこれに当たる。

開発用依存関係 テスト、整形、静的解析にだけ必要なもの。今回なら `pytest` や `ruff` がこれに当たる。

ローカル環境の固定 開発者どうしで完全に同じ環境を再現したいときの情報。これは `uv.lock` が担う。

ライブラリとして配布するなら、`dependencies` にはあまり厳しすぎる固定を入れない方がよい。たとえば `numpy==2.0.0` のように完全固定すると、利用者側の既存環境と衝突しやすい。むしろ `numpy>=2.0` のように「必要な下限」を書き、自分の開発環境の厳密な再現は `uv.lock` に任せる方が扱いやすい。

また、パッケージを書いていると、Jupyter、Sphinx、mkdocs など「利用者全員には不要だが、自分は使いたい」ものが増えやすい。そのとき全部を実行時依存関係へ入れてしまうと、インストールが重くなる。依存関係は増やすほど便利になる一方で、衝突や管理コストも増える。だからこそ、まずは公開 API を小さく保ち、本当に必要な依存関係だけを残す方がよい。

第 13 章 Python 解析の高速化

13.1 まず測る

高速化を始める前に、どこが遅いのかを測る。読み込みが遅いのか、探索が遅いのか、図の作成が遅いのかを区別しないまま最適化しても、効果は見えにくい。

ここで役立つのが `time.perf_counter` である。処理の前後で時刻を取り、差を記録するだけでも、どの段階が重いのかの見当が付く。大切なのは、全体時間だけでなく、読み込み、前処理、探索、書き出し、作図のように段階を分けて測ることである。

```
1 import time
2
3 t0 = time.perf_counter()
4 run_analysis()
5 t1 = time.perf_counter()
6 print(f"elapsed={t1-t0:.3f}s")
```

測定するときは、一度だけの結果を絶対視しないことも重要である。キャッシュや OS の状態で多少は揺れるため、条件をそろえ、複数回の傾向を見る方がよい。

13.1.1 Jupyter では `%timeit` も使える

ノートブック環境で短い式や関数の速度を見たいときは、Jupyter の `%timeit` や `%%timeit` も便利である。複数回の実行を自動で繰り返し、平均的な実行時間を表示してくれるため、小さな差を見たいときに役立つ。

```
1 %%timeit
2 result = array * 2
```

ただし、`%timeit` はノートブックや IPython での簡便な測定であり、スクリプト全体の読み込みや入出力を含めた時間を見るには向かない。小さな部品には `%timeit`、解析全体には `perf_counter` というように使い分けると整理しやすい。

13.2 計算量の見積もり

高速化では、実測だけでなく理屈の見積もりも役に立つ。入力サイズを N としたとき、処理回数が N に比例するのか、 $N \log N$ 程度なのか、 N^2 なのかで、大きなデータに対する伸び方がまるで違う。

厳密な漸近解析までできなくても、「データを 2 倍にしたら計算量は何倍くらいになるか」

を考えるだけで十分に有益である。高速化はテクニック集ではなく、問題の構造を考える作業である。

この点は初学者ほど見落とししやすい。変数名を短くしたり、関数を減らしたりすることは、ほとんど速度に効かない。一方で、比較回数を減らす、探索範囲を絞る、配列演算へ置き換えるといった変更は、本質的に計算量や定数倍を変える。

13.2.1 オーダーとは何か

ここでいう「オーダー」とは、入力サイズ N を大きくしたときに処理回数がどのように増えるかを表す粗い記法である。通常は Big-O 記法で書き、定数倍や低次の項を落として、最終的に支配的になる項だけを見る。

$$3N + 20 \rightarrow O(N), \quad 5N \log N + 100N \rightarrow O(N \log N), \quad N^2 + N \rightarrow O(N^2)$$

よく出るオーダーには、たとえば次のようなものがある。

- $O(\log N)$: 範囲を半分ずつ絞る処理。二分探索など
- $O(N)$: 1 回走査する処理。総和、平均、閾値判定、隣接差分など
- $O(N \log N)$: ソートを含む処理。高速なソート、ソート後の探索など
- $O(N^2)$: 全組合せ比較。全ペアの力づく比較など

たとえば $N = 10^6$ なら、 $\log_2 N$ はおよそ 20、 $N \log_2 N$ はおよそ 2×10^7 、 N^2 は 10^{12} である。どちらも「増える」ことに変わりはないが、その増え方の差は圧倒的である。小さなテストデータでは目立たなくても、大きな入力では急に効いてくる。

ただし、オーダーは定数倍を完全に無視してよい、という意味ではない。同じ $O(N)$ でも 10 倍、100 倍の速度差が付くことは普通にある。ここでいう「ファクター」とは、この定数倍の差のことである。したがって、まずオーダーを疑い、その後で定数倍を詰める、という順序で考えると整理しやすい。

この中で、 $O(\log N)$ や $O(N \log N)$ は初学者には直感を持ちにくい。そこで、まず二分探索で $O(\log N)$ を見てから、ソートで $O(N \log N)$ を見る。

13.2.1.1 二分探索ではなぜ $O(\log N)$ になるか

$\log N$ は、「問題の大きさを毎回半分にできる」場面で現れる。たとえば昇順に並んだ列から目的の値を探す二分探索では、中央を見て、左半分か右半分のどちらかを捨てられる。

```
1 def binary_search(values, target):
2     left = 0
3     right = len(values) - 1
4
5     while left <= right:
6         mid = (left + right) // 2
7         if values[mid] == target:
8             return mid
```

```

9         if values[mid] < target:
10             left = mid + 1
11         else:
12             right = mid - 1
13     return -1

```

要素数が N 個あっても、1 回ごとに候補数が半分になるなら、必要な反復回数は $N \rightarrow N/2 \rightarrow N/4 \rightarrow \dots \rightarrow 1$ という形になる。これが $\log_2 N$ 回程度である。したがって、二分探索は $O(\log N)$ で動く。重要なのは、「1 個ずつ減らす」のではなく「毎回半分に減らす」ことが $\log N$ を生む、という点である。

13.2.1.2 ソートではなぜ $O(N \log N)$ になるか

ソートは、計算量の違いを理解するための基本例である。たとえば、挿入ソートやバブルソートのような初等的な方法は、一般に $O(N^2)$ で動く。一方、マージソートやヒープソートは $O(N \log N)$ であり、Python の `sorted()` も実用的な高速ソートを使っている。

ここで $N \log N$ と書くなら、その意味も説明する必要がある。典型例であるマージソートでは、まず列を半分に分け、さらにその半分へ分ける、という分割を繰り返す。この分割の深さは、およそ $\log_2 N$ 段である。一方、各段では、分かれた小列どうしを併合する過程で、全体として各要素を 1 回ずつ見るので $O(N)$ かかる。

$$\text{各段の仕事量 } O(N) \times \text{段数 } O(\log N) = O(N \log N)$$

ここで重要なのは、「ソートは前処理にすぎない」と軽視しないことである。データを一度並べ替えるだけで、その後の探索や近傍判定がずっと安くなることがある。つまり、 $O(N \log N)$ の前処理へ投資することで、後続の $O(N^2)$ を避けられるなら、全体として大幅に得をする。

データが 10 倍に増えたとき、 $O(N^2)$ のソートはおおよそ 100 倍重くなるが、 $O(N \log N)$ のソートは 10 倍強で済む。この差を理解しておく、単にソートの名前を知るだけでなく、「なぜその方法を選ぶのか」を説明できるようになる。

13.2.2 オーダーが改善する例: 重複判定

問題をはっきりさせよう。長さ N の整数列に、同じ値が 2 回以上現れるかを判定したいとする。

最も素朴な方法は、すべての組 (i, j) を比べることである。

```

1 def has_duplicate_slow(values):
2     for i in range(len(values)):
3         for j in range(i + 1, len(values)):
4             if values[i] == values[j]:
5                 return True
6     return False

```

この方法では、最悪の場合ほぼすべてのペアを比べるので $O(N^2)$ になる。データ量が 10 倍になると、比較回数はおおよそ 100 倍に増える。

しかし、いったんソートしてしまえば、同じ値どうしは必ず隣り合う。したがって、隣接要素だけを見れば重複を判定できる。

```
1 def has_duplicate_fast(values):
2     values_sorted = sorted(values)
3     for i in range(len(values_sorted) - 1):
4         if values_sorted[i] == values_sorted[i + 1]:
5             return True
6     return False
```

`sorted()` の部分は $O(N \log N)$ 、その後の 1 回走査は $O(N)$ なので、全体は $O(N \log N)$ である。元の $O(N^2)$ より明確に良い。ここで本質なのは、Python の書き方が少し変わったことではなく、「全比較」という問題の解き方をやめたことである。

Python では `set(values)` を使えば平均的には $O(N)$ で重複判定できることも多いが、ここでは「ソートすると後続の走査が安くなる」という典型的な発想を示すために、あえてソートを使った例を出している。

同じ考え方は探索でも現れる。未整列の列から目的の値を探す線形探索は $O(N)$ だが、整列済みの列なら二分探索で $O(\log N)$ にできる。したがって、「一度だけ探す」のか「何度も探す」のかによって、先にソートする価値があるかどうかが変わる。前処理に時間を使っても、その後の探索を何度も繰り返すなら、全体としては得になることが多い。

13.2.3 オーダーは同じで定数倍だけ改善する例

今度は、 $N \times N$ 行列 A が対称行列かどうか、すなわち $A_{ij} = A_{ji}$ が成り立つかを調べる問題を考える。

最も素朴な方法は、すべての (i, j) について比較することである。

```
1 def is_symmetric_slow(A):
2     n = len(A)
3     for i in range(n):
4         for j in range(n):
5             if A[i][j] != A[j][i]:
6                 return False
7     return True
```

これは n^2 回程度の比較を行うので $O(N^2)$ である。

しかし、対称性の判定では、上三角と下三角は同じ情報を二重に見ている。したがって、片側だけ見れば十分である。

```
1 def is_symmetric_fast(A):
2     n = len(A)
3     for i in range(n):
4         for j in range(i + 1, n):
5             if A[i][j] != A[j][i]:
```

```
6         return False
7     return True
```

こちらもオーダーは同じく $O(N^2)$ だが、比較回数はおよそ $n(n-1)/2$ 回になり、素朴な実装のほぼ半分で済む。つまり、問題の大きさに対する増え方は変わっていないが、無駄な比較を消したことで定数倍が改善している。

この例は、「同じオーダーでも速くなる」ことを示している。図 13.1 の隣接差分フィルタの比較も、基本的にはこの種類の改善である。比較回数そのものを 2 次から 1 次へ落としたのではなく、同じ種類の処理をより効率よく実装しているのである。

13.3 実装を軽くする

13.3.1 NumPy と pandas による高速化

アルゴリズムを見直した後は、NumPy や pandas へ処理を移すことで、Python レベルのループを減らせる。特に差分計算、ソート、列抽出、フィルタは、これらのライブラリが得意とする。図 13.1 からも、配列演算が速度に与える効果を視覚的に確認できる。

ここで注意したいのは、NumPy や pandas を使えば自動的に何でも速くなるわけではないことである。根本的に無駄な比較をしているなら、配列演算へ移しても限界がある。まず計算量を減らし、そのうえで実装をベクトル化するという順序が自然である。

13.3.2 メモリとコピーの管理

速度だけを見ていると、メモリ使用量が大きくなりすぎて逆に遅くなることがある。巨大な中間配列を何度も作る実装では、CPU よりもメモリ転送が支配的になる場合がある。

そのため、高速化では「何回ループしたか」だけでなく、「何回コピーしたか」も見る必要がある。不要なコピーを減らし、必要な列や範囲だけを扱う設計は、速度と安定性の両方に効く。

13.3.3 分割読み込み、並列化、ストリーミング

大規模解析では、全部を一度にメモリへ載せない設計も重要である。ファイル単位で処理し、必要な情報だけを持ち回る。さらに、独立な単位に分割できるなら並列化も検討できる。

ストリーミング処理では、「今必要な範囲だけを覚える」という考え方が中心になる。全履歴が不要なら保持しない、集計済みの量は逐次更新する、といった設計が有効である。メモリ節約と速度向上が同時に得られることも多い。

13.4 プロファイリングと低レベル実装

13.4.1 プロファイラを使う

本格的に遅い理由を調べるなら、プロファイラも役立つ。例えば cProfile を使うと、どの関数に時間が使われているかを確認できる。

```
1 import cProfile
2
3 cProfile.run("run_analysis()", sort="cumtime")
```

ただし、プロファイラの数字も文脈なしには読めない。回数が多いから遅いのか、1 回が重いのか、入出力を待っているのかを区別する必要がある。測定値とコード構造を一緒に見ることが重要である。

| ncalls | tottime | cumtime | function |
|---------|---------|---------|----------------|
| 1000000 | 1.25 | 1.40 | check_pair |
| 10 | 0.02 | 2.10 | read_all_files |

この結果例では、check_pair は 1 回は軽い回数が多く、read_all_files は内部の処理込みで累積時間が大きいと読める。どの列が何を意味するかを理解すると、改善方針が立てやすくなる。

13.4.2 C や C++ へ書き換えるという選択肢

Python は開発速度が高いが、計算コアのすべてを Python で書く必要はない。アルゴリズムを十分に整理したうえで、どうしても重い部分だけを C や C++ へ移す、というのは自然な選択肢である。

ただし、言語を変える前に Python 側で何が遅いかを把握しておく必要がある。ボトルネックが入出力や高水準の設計にあるなら、C++ 化しても大きな改善にならない。低レベル言語への移行は、最後の切り札として考える方がよい。

```
1 for (std::size_t i = 0; i < n; ++i) {
2     for (std::size_t j = i + 1; j < n; ++j) {
3         if (std::abs(times[j] - times[i]) <= window) {
4             ++count;
5         }
6     }
7 }
```

この書き換えは、定数倍の改善をもたらすことがある。しかし、比較回数そのものが多いすぎるなら本質的な改善ではない。アルゴリズムと実装言語を分けて考える姿勢が必要である。

13.4.3 Python から C/C++ を呼び出す

方法はいくつかある。たとえば ctypes で共有ライブラリを呼ぶ方法、Python C 拡張を書く方法、pybind11 を使って C++ を Python から自然に使える形へ包む方法などがある。さらに、Python と C の中間に位置する Cython を使い、Python に近い構文のまま重いループだけをコンパイルする方法も、この節に含まれる重要な選択肢である。

```
1 cdef int i
2 cdef double total = 0.0
3
4 for i in range(n):
5     total += values[i]
```

ここで cdef は Cython 特有の宣言であり、変数を Python オブジェクトではなく C の整数や浮動小数点数として扱わせるために使う。これにより、ループ内部の型判定やボックス化のコストを減らせる。

どの方法を選ぶかは、必要な速度、保守性、ビルドの難しさで決まる。目安としては次のように考えるとよい。

- ctypes: 既にある C の共有ライブラリを手早く呼びたいときに向く。設定は比較的軽い
が、引数や戻り値の型を手で合わせる必要がある
- Python C 拡張: Python 本体の C API を直接使う最も低レベルな方法で、自由度は高い
が記述量も多い
- pybind11: C++ の関数やクラスを Python から自然に使える形で公開しやすい。C++ 側
の実装をすでに持っている場合に相性がよい
- Cython: Python に近い構文を保ちながら、重いループや数値計算だけへ型を付けてコン
パイルしたいときに向く

短い試作なら ctypes、Python らしい使い勝手まで整えたいなら pybind11、既存の Python 風コードを保ちながら内側だけ速くしたいなら Cython、といった選択が考えられる。重要なのは、インタフェースを狭く保ち、重い部分だけを外へ出すことである。pybind11 の最小構成は付録 C を参照してほしい。

```
1 result = fast_module.count_pairs(times, window)
```

Python 側の呼び出しが単純であれば、内部実装を後から差し替えやすい。まず Python で正しい API を決め、その内部だけを高速化するという順が自然である。なお、Cython も強力だが、アルゴリズムそのものが無駄な場合には決定打にならない。この点は C++ 化と同じであり、まず Python 側で何が遅いのか、どのループが本当に支配的なのかを見極めた後に使う方が効果的である。

13.4.4 外部実装を参考にする時の見方

高速化を学ぶときは、外部の C や C++ の実装例を読むことが参考になる。ただし、そこで大切なのは固有名詞を覚えることではない。まず見るべきなのは、どの問題を解いているのか、どのアルゴリズムを選んでいるのか、どの部分だけを低レベル言語へ移しているのか、という点である。

高速化の章では、このような例を参照しながら、次の二つを常に区別して考える。

- アルゴリズムを変えたから速くなったのか
- 実装言語を変えたから速くなったのか

多くの場合、最初に効くのは前者である。

したがって、高速化のレポートを書くときは、「NumPy にした」「C++ にした」で終わらせない方がよい。何が変わった結果として速くなったのかを、計算量、比較回数、メモリ配置、ループの位置といった観点で説明すべきである。

13.5 結果例と報告の仕方

高速化の結果は、本文中で比較できる形に整理すると読みやすい。例えば、次のような簡潔な結果でも十分に意味がある。

```
slow version : 182.4 s
vectorized   :  12.7 s
streaming    :   4.8 s
```

この表現だけでは理由が分からないので、続けて「比較回数を減らした」「Python ループを配列演算へ移した」「全件保持をやめた」といった説明を添える。数値と理由の両方がそろって初めて報告になる。

特に、高速化の報告では「 $O(N^2)$ から $O(N \log N)$ や $O(N)$ へ落とした改善」と、「同じ $O(N)$ や $O(N^2)$ のまま NumPy, Cython, C++ などで定数倍を詰めた改善」を分けて書くといい。前者は問題の解き方を変えた改善であり、後者は実装の効率を上げた改善である。この二つを混同しない方が、読者にも自分にも何が効いたのかが伝わりやすい。

```
1 import numpy as np
2
3 values = np.array(data, dtype=np.float64)
4 diffs = np.diff(values)
5 count = np.count_nonzero(diffs > 0.25)
```




図 13.1 同じ隣接差分フィルタを、純粋な Python ループ、NumPy、pandas で実行した例。縦軸は実行時間で、対数目盛を使っている。

第 14 章 課題: 同時観測イベントの探索

14.1 課題の準備

この課題では、次のファイルを配布する。

- events_data.zip
- slow_event_analysis.py
- 本テキスト

events_data.zip を展開すると、events_data/ というディレクトリが得られる。日ごとに gzip 圧縮されたイベントファイルがあり、年・月ごとのディレクトリに分かれている。

課題のスクリプトやデータは、GitHub リポジトリ (https://github.com/i-komae/python_textbook) から入手できる。手元に配布物がそろっていない場合は、まずリポジトリを取得し、リポジトリ直下にある slow_event_analysis.py と events_data.zip の配置を確認する。events_data.zip を展開すると events_data/ が得られ、これを入力ディレクトリとして使う。

配布物は意図的に最小限にしてある。したがって、何を入力とし、どのファイルが正解判定の対象で、どこからどこまでを自分で実装するのかを最初に整理してから着手した方がよい。

14.1.1 まず配布コードを動かす

まずは、配布された遅いコードをそのまま動かす。

```
$ python3 slow_event_analysis.py events_data --outdir slow_output
```

この実行は環境によってかなり時間がかかる。最初は数日分だけ切り出して試してもよい。

重要なのは、最初から完成版を書こうとしないことである。まず配布コードが本当に遅いことを自分の環境で確認し、どの出力が得られるかを見てから変更を始める方が、修正の意味が分かりやすい。

14.1.2 gzip ファイルの中身を見る

データの中身を見ずに解析を始めてはいけない。まずは 1 ファイルを開き、列の意味を確認する。

```
$ gzip -cd events_data/2024/01/events_2024_01_01.txt.gz | head
```

各行の列は次のようになっている。

```
event_id year month day hhmmss ns detector_id signal
```

列名を見たら、それぞれの型と役割を自分で言葉にしてみるとよい。整数として扱うべき列、時刻を構成する列、識別子としてだけ使う列、物理量として解釈する列が混ざっている。ここを曖昧にしたまま進むと、後でバグの原因になる。

この課題では、2 事象の時刻差を ns 単位まで含めて評価し、 $|\Delta t| \leq 250 \text{ ns}$ を満たすものを「同時観測」と定義する。したがって、hhmmss 列だけを見ればよいわけではなく、ns 列も含めて時刻を一つの量として組み立てる必要がある。秒境界や日付境界をまたぐ場合にどう振る舞うかも、この定義を満たす形で確認しなければならない。

14.1.3 小さいデータで確認する

いきなり 500 日分全体に対して試すのではなく、まずは数日分を別ディレクトリにコピーして試すとよい。

```
$ mkdir -p events_data_small/2024/01
$ cp events_data/2024/01/events_2024_01_01.txt.gz events_data_small/2024/01/
$ cp events_data/2024/01/events_2024_01_02.txt.gz events_data_small/2024/01/
$ cp events_data/2024/01/events_2024_01_03.txt.gz events_data_small/2024/01/
```

小さい入力での確認は、速度のためではなく、正しさを素早く確かめるためである。数十秒で終わる条件を作っておけば、修正してすぐ再実行できる。大きなデータを回すのは、その後で十分である。

```
n_pairs_total = 241
analysis_sec = 18.4
```

この段階では、数値そのものよりも、修正のたびに一貫した結果が出るかが大切である。件数が毎回変わる、出力ファイルの形式が揺れる、といった状態では、その先の高速化に進むべきではない。

14.2 課題で求めること

最低限、次の内容に取り組むこと。

1. 配布コードの処理時間を確認する
2. 同時観測イベント数が正しいかを検証する
3. バグを修正する
4. 高速化する
5. 同時観測イベントの時刻差分布を描き、フィットする

この並びにも意味がある。いきなり高速化から始めるのではなく、まず元のコードの振る舞いを把握し、次に正しさを確認し、その後で改善する。間違ったコードを高速化しても、間違いが速くなるだけである。

14.2.1 出力としてほしいもの

最低限ほしい出力は次の三つである。

- 同時観測イベントの一覧
- 同時観測イベントを構成する 2 事象の時刻差の分布
- 同時観測イベントどうしの発生間隔、またはそれに相当する量の分布

ここでいう「2 事象の時刻差」は、同時観測と判定した 2 つのイベントの時刻差である。たとえば $\Delta t = t_2 - t_1$ と定義してよい。ただし、符号付きで使うのか絶対値を使うのか、検出器番号で向きをそろえるのかなどは、自分で決めて明記すること。

分布を描くときは、ビン幅、横軸の範囲、単位も明記すること。図は出しただけでは不十分で、どの量をどう定義して数えたのかが分からなければ、他人は解釈できない。フィットを行うなら、どの範囲を使ったかも書くべきである。

```
coincidence_pairs.csv
pair_dt_hist.pdf
pair_mean_gap_hist.pdf
summary.txt
```

ファイル名の流儀を最初に決めておくと、後で解析を繰り返したときにも混乱しにくい。どのファイルが一覧で、どれが図で、どれが数値要約なのかが名前から分かるようにしておくとよい。

14.2.2 正しさ確認の目安

今回の配布データは 500 日分であり、正しく同時観測イベントを拾えていれば、全期間で得られる同時観測イベント数は

```
n_pairs_total = 12033
```

になる。この値は最終確認の目安として使ってよい。

ただし、この値に合ったからといって、それだけで実装が正しいとは限らない。偶然件数だけ一致している可能性もある。可能なら、個々のイベント対の内容や、ファイル境界付近の振る舞いも確認した方がよい。

```
n_pairs_total = 12033
analysis_sec = 248.6
plot_sec = 1.8
```

このような要約ファイルを出しておくと、コード変更のたびに結果を比較しやすい。件数だけでなく処理時間も同じ場所へ残すと、正しさと速度を一緒に追える。

14.3 提出物と発展課題

提出物は次の二つである。

- 解析に使った Python コード
- LaTeX で書いたレポートと、その PDF

レポートには、少なくとも次の内容を書くこと。

- 元のコードの問題点
- 正しさをどう検証したか
- バグをどう修正したか
- どう高速化したか
- 改善前後の処理時間
- 作成した図
- フィット結果とその解釈

レポートを書くときは、変更点の羅列よりも、問題の発見、原因の切り分け、修正方針、検証方法、結果、考察の順で並べると読みやすい。図や表を入れるときは、本文の中で参照しながら説明すること。

1. 元のコードの観察
2. バグの特定
3. 修正内容
4. 高速化方針
5. 結果の比較
6. 図とフィットの考察

この順序で書けば、読者は「何が問題で、どう直して、何が改善したのか」を追やすい。レポートは成果物であると同時に、思考過程の記録でもある。

14.3.1 発展課題

余裕があれば、図の作成やフィットまで含めた全体処理をさらに高速化してよい。さらに、NumPy や pandas を使うだけでなく、自分でアルゴリズムを設計し直したり、C や C++ で計算コアを実装したりしてもよい。

この発展課題では、特定の解法を要求しない。pandas を深く使う方向もあれば、ストリーミング処理を突き詰める方向もあり得るし、重い部分だけを別言語へ切り出す方向もあり得る。重要なのは、自分の方針を説明できることである。

付録 A SSH, 鍵認証, ファイル転送

A.1 SSH の基本

SSH は、離れたマシンへ安全に接続してコマンドを実行するための仕組みである。研究室や計算サーバーへ入り、大きなデータ処理や長時間ジョブを回すときによく使う。GitHub へ SSH で接続するときにも同じ仕組みを使うが、GitHub はシェルへログインする相手ではなく、Git 操作の認証先である点は区別しておいた方がよい。

A.1.1 サーバーへ接続する

最も基本的な形は次である。

```
$ ssh user@server.example.jp
```

user はサーバー上の自分のユーザー名、server.example.jp はホスト名である。ポート番号が既定の 22 でないなら -p を付ける。

```
$ ssh -p 2222 user@server.example.jp
```

接続後は、ローカルのターミナルと似た形でコマンドを打てる。ただし、そこで見えているファイルは自分の手元ではなく、サーバー側のファイルである。この区別が曖昧になると事故の原因になるので、hostname、whoami、pwd を見て今どこにいるかを確認する習慣を持った方がよい。

A.1.2 SSH 鍵を作る

毎回パスワードを打つ代わりに、SSH 鍵を使うことが多い。鍵は公開鍵と秘密鍵の 2 つ 1 組であり、公開鍵をサーバーへ登録し、秘密鍵は自分だけが持つ。

```
$ ssh-keygen -t ed25519 -C "your_email@example.com"
```

既定値のまま進めると、多くの場合は ~/.ssh/id_ed25519 が秘密鍵、~/.ssh/id_ed25519.pub が公開鍵になる。.pub が付いている方だけを相手へ渡す。.pub が付いていない方は秘密鍵なので、決して共有してはいけない。

```
$ ls -l ~/.ssh
```

秘密鍵の権限が緩いと SSH が拒否することがある。その場合は次のように直す。

```
$ chmod 700 ~/.ssh
$ chmod 600 ~/.ssh/id_ed25519
$ chmod 644 ~/.ssh/id_ed25519.pub
```

A.1.3 公開鍵をサーバーへ登録する

公開鍵をサーバーへ登録する最も簡単な方法は `ssh-copy-id` である。

```
$ ssh-copy-id user@server.example.jp
```

特定の公開鍵を使いたいなら `-i` で指定できる。

```
$ ssh-copy-id -i ~/.ssh/id_ed25519.pub user@server.example.jp
```

`ssh-copy-id` は、指定した公開鍵をサーバー側の `~/.ssh/authorized_keys` へ追加する。つまり、「手元の公開鍵を安全に送り、向こうで追記する」という面倒な作業を代わりにやってくれる。

A.1.3.1 `ssh-copy-id` が使えない場合

`ssh-copy-id` が使えない環境では、公開鍵の中身を手で登録する。

```
$ cat ~/.ssh/id_ed25519.pub
```

表示された 1 行全体を、サーバー側の `~/.ssh/authorized_keys` へ追記する。サーバーへ通常のパスワードログインができるなら、自分でログインして追記してもよい。

A.1.4 `ssh-agent` を使う

パスフレーズ付きの鍵を使う場合は、`ssh-agent` に読み込ませておくと毎回の入力を減らせる。

```
$ eval "$(ssh-agent -s)"
$ ssh-add ~/.ssh/id_ed25519
```

A.2 接続設定と GitHub 連携

A.2.1 `~/.ssh/config` を書く

接続先が増えると、毎回長いホスト名やポート番号や鍵ファイル名を書くのは面倒になる。そこで `~/.ssh/config` を使う。設定ファイルの中身は次のようになる。

`~/.ssh/config`

```
Host labserver
  HostName server.example.jp
  User ikomae
  Port 2222
  IdentityFile ~/.ssh/id_ed25519
```

これを書いておけば、以後は次のように短く書ける。

```
$ ssh labserver
```

config ファイル自体も秘密情報に近いので、`chmod 600 ~/.ssh/config` としておく方が安全である。

A.2.2 GitHub に SSH 鍵を登録する

通常のサーバーとは違って、GitHub には `ssh-copy-id` を使わない。GitHub はシェル接続先ではなく、アカウント設定に公開鍵を登録する相手だからである。

最も確実なのは、GitHub の設定画面の SSH and GPG keys へ公開鍵を登録する方法である。もし GitHub CLI `gh` を使うなら、認証時に SSH 鍵の作成や登録を案内させることもできる。

```
$ gh auth login --git-protocol ssh --web
```

GitHub CLI を使う場合は、既存の鍵を検出してアップロードするか、新しい鍵を作るかを対話的に選べる。GitHub CLI を使わない場合は、`cat ~/.ssh/id_ed25519.pub` で表示した公開鍵を Web 画面へ貼り付ければよい。

A.3 ファイル転送

小さなファイルを 1 回だけ送るなら `scp` でもよいが、解析ではディレクトリ全体を何度も同期することが多い。その場合は `rsync` を使う方が自然である。

A.3.1 scp の最小例

```
$ scp result.csv user@server.example.jp:~/work/  
$ scp user@server.example.jp:~/work/result.csv .
```

1 行目は手元からサーバーへ送り、2 行目はサーバーから手元へ持ってくる。ディレクトリごと送りたい場合は `-r` を付ける。

A.3.2 rsync を推奨する理由

`rsync` は、差分だけを転送し、途中で止まっても再開しやすく、除外パターンも柔軟に書ける。そのため、解析用ディレクトリやコード一式をサーバーへ送る用途では `scp` より向いている。

```
$ rsync -aP ./analysis/ user@server.example.jp:~/work/analysis/
```

よく使うオプションの意味は、次のように 1 つずつ読んだ方が理解しやすい。

- a** archive モードである。再帰コピーを行い、時刻や権限などもまとめて保つ。
- P** `--partial --progress` の省略形である。途中ファイルを残しつつ進捗を表示する。
- v** 何を転送しているか詳しく表示する。
- z** 転送時に圧縮する。低速回線では有利だが、既に圧縮済みの大きなデータでは効果が薄いこともある。
- exclude** 特定のファイルやディレクトリを転送対象から除外する。

```
$ rsync -aPv \
--exclude='.venv/' \
--exclude='__pycache__/' \
--exclude='build/' \
--exclude='.mypy_cache/' \
./analysis/ user@server.example.jp:~/work/analysis/
```

仮想環境、キャッシュ、ビルド成果物はサーバー側で作り直せることが多いので、転送から外した方が軽くなる。

A.3.2.1 末尾のスラッシュに注意する

rsync では、送信元パスの末尾に / を付けるかどうかで意味が変わる。

```
$ rsync -aP analysis user@server:~/work/
$ rsync -aP analysis/ user@server:~/work/analysis/
```

1 行目は analysis というディレクトリごと送る。2 行目は analysis の中身を送る。この違いは非常に重要であり、意図しない階層を作る原因になりやすい。

付録 B Git と GitHub の基本

B.1 Git の基本概念

Git は、手元のファイルの変更履歴を記録するためのソフトウェアである。これに対して GitHub は、Git リポジトリを置いて共有するためのサービスである。

- Git: ローカルマシンでも単独で使えるバージョン管理システム
- GitHub: Git リポジトリをホストし、共有、Issue、Pull Request などを提供するサービス

したがって、`git init`、`git add`、`git commit` は Git の話であり、`git push` で GitHub へ送る段階になって初めて GitHub が関係してくる。

B.1.1 リポジトリと公開範囲

リポジトリは、コード、データ、履歴をまとめて管理する単位である。GitHub へ置く場合は、公開範囲も意識する必要がある。

- `public`: 誰でも見られる
- `private`: 明示的に許可した人だけが見られる
- `internal`: 組織内だけで見られる。主に GitHub Enterprise の文脈で使う

授業用の配布物、研究中のコード、機密データを含むリポジトリでは、公開範囲の設定を誤ると問題になる。GitHub で新しいリポジトリを作るときは、まず `visibility` を確認した方がよい。

B.1.2 Git で何をしているのか

Git は、ファイルを 1 回で全部自動保存してくれるわけではない。ふつうは次の 3 段階で進む。

1. 作業中のファイルを編集する
2. 記録したい変更を `git add` で選ぶ
3. `git commit` で履歴として確定する

この 2 段階目の「いったん選ぶ場所」をステージングエリアという。`git add` と `git commit` の違いを理解するには、ここが重要である。

最初はここが見えにくいので、次の 3 層に分けて考えるとよい。

- working tree: いま自分がエディタで直接書き換えている実ファイル
- staging area (index): 次のコミットへ入れる予定の変更を一時的に集めた場所
- commit history: すでに確定して履歴へ残った状態

たとえば、ファイルを編集した直後は変更は working tree にしかない。git add を実行すると、その時点の内容が staging area へコピーされる。git commit は、その staging area の内容を履歴として確定する操作である。したがって、git add の後にさらにファイルを編集すると、「ステージ済みの内容」と「作業中の内容」がずれることがある。

B.2 ローカルで履歴を作る

B.2.1 最初の設定

最初に、自分の名前とメールアドレスを設定しておく。

```
$ git config --global user.name "Your Name"
$ git config --global user.email "your_email@example.com"
```

これをしておかないと、コミット時に誰の変更なのかが分からなくなる。

B.2.2 新しいリポジトリを作る

まだ Git 管理されていないディレクトリなら、git init で始める。

```
$ mkdir analysis_work
$ cd analysis_work
$ git init
$ git status
```

git status は最重要コマンドである。今どのファイルが未追跡か、どれが変更済みか、何がコミット待ちかを確認できる。迷ったらまず git status を見る、という習慣を付けるとよい。

B.2.3 編集、確認、記録の流れ

日常的な流れは、編集して、差分を確認して、必要なものだけをコミットする、である。

```
$ git status
$ git diff
$ git add analyze.py
$ git diff --cached
$ git commit -m "Add first analysis script"
$ git log --oneline
```

git diff は、まだ add していない変更を見る。git diff --cached は、add 済みで次のコミットへ入る変更を見る。git log --oneline は、これまでのコミット履歴を短く確認する。

B.2.3.1 git status の読み方

git status は、少なくとも次の 3 種類を見分けられるようになるとうい。

- untracked: まだ Git が追跡していない新規ファイル
- modified: 追跡中だが、まだ add していない変更
- changes to be committed: add 済みで、次のコミットへ入る変更

つまり、git status は「いま何がどの段階にあるか」を示す画面である。

B.2.3.2 git add は何をしているのか

git add は「変更を次のコミット候補として選ぶ」コマンドである。保存ではない。したがって、git add した後でも、コミット前にさらに編集すれば、その追加分はまだコミット対象へ入っていない。

```
$ git diff
$ git add analyze.py
$ git diff --cached
```

この 2 回の diff を見分けられるようになると、Git の挙動がかなり分かりやすくなる。

B.2.4 .gitignore を使って除外する

生成物まで毎回コミットすると、履歴が見にくくなる。Python 解析なら、仮想環境、キャッシュ、ビルド成果物などは除外することが多い。

B.2.4.1 .gitignore を書く

.gitignore は、Git に「このパターンのファイルは追跡しなくてよい」と教えるためのファイルである。リポジトリのルートに置くことが多い。Python 解析用の最小例は次のようになる。

.gitignore

```
.venv/
__pycache__/
*.pyc
build/
dist/
.pytest_cache/
```

このファイルを作ると、まだ追跡されていない .venv/ や build/ は git status に出にくくなり、誤ってコミットしにくくなる。

B.2.4.2 すでに追跡済みなら git rm --cached が必要

.gitignore は「これから追跡しない」ための設定である。すでに一度コミットしたファイルには、そのままでは効かない。

```
$ git rm --cached -r .venv __pycache__ build
$ git commit -m "Stop tracking generated files"
```

`git rm --cached` は、作業ディレクトリの実ファイルを消さずに、インデックスからだけ外す。そのため、「手元には残したまま Git の追跡対象から外す」という目的に向いている。

B.2.4.3 uv プロジェクトで何をコミットするか

uv を使うプロジェクトでは、通常 `.venv/` はコミットしない。一方で、`pyproject.toml`、`uv.lock`、`.gitignore`、そしてプロジェクト単位でバージョンを固定したいなら `.python-version` はコミット候補になる。

B.3 GitHub と接続する

B.3.1 既存のリポジトリを持ってくる

他人のプロジェクトや GitHub 上の教材は、`git clone` で手元へコピーする。

```
$ git clone git@github.com:example/project.git
$ cd project
$ git remote -v
```

`git clone` は、履歴も含めて手元へ持ってくる。`git remote -v` は、どの URL が接続先として設定されているかを確認する。本書では、GitHub から取得するときも `push` するときも SSH URL を使う方針を勧める。公開鍵の準備は付録 A を参照してほしい。

B.3.2 手元のリポジトリを GitHub へ初めて載せる

ここまでは「GitHub 上にあるものを取得する」話だったが、逆に、手元で `git init` して育てたプロジェクトを自分の GitHub へ載せたい場面も多い。その場合は、まず GitHub 側で空のリポジトリを作り、次に手元のリポジトリから接続先を登録して `push` する。

B.3.2.1 GitHub 側で空のリポジトリを作る

GitHub の Web 画面で `New repository` を開き、リポジトリ名と公開範囲を決める。このとき、手元にすでに履歴があるなら、最初は空のリポジトリとして作る方が簡単である。つまり、`Add a README file`、`Add .gitignore`、`Choose a license` には最初は触れない方がよい。

最初から README や `.gitignore` を GitHub 側で作ると、リモート側に 1 個目のコミットができる。その状態で手元の履歴をそのまま `push` すると、履歴の始点が一致しないため、初心者には扱いにくい状況になりやすい。したがって、既存のローカルリポジトリを載せるときは「空の GitHub リポジトリ」を作る、という方針で覚えた方が安全である。

B.3.2.2 README や LICENSE を先に作っていた場合

すでに GitHub 側で README や LICENSE を作ってしまったなら、リモート側には先にコミットが1つ以上存在する。その場合は、いきなり git push するのではなく、まずリモート側の履歴を取り込んでから push しなければならない。

```
$ git branch -M main
$ git remote add origin git@github.com:owner/project.git
$ git pull origin main --allow-unrelated-histories
$ git push -u origin main
```

--allow-unrelated-histories が必要なのは、手元のリポジトリと GitHub 側のリポジトリが別々に作られており、履歴の出発点が一致していないからである。この pull によって、GitHub 側の README や LICENSE のコミットを自分の履歴へ取り込んでから、その続きとして push できるようになる。

もし手元にも README や LICENSE があり、同じ名前のファイルを両側で作っていたなら、git pull の途中で競合が起こることがある。その場合は、どちらの内容を残すかを自分で決めて修正し、git add と git commit で競合解消を確定してから、あらためて git push -u origin main を実行する。

B.3.2.3 接続先を登録して最初の push を行う

GitHub が表示する URL を確認し、手元のリポジトリで origin として登録する。多くの場合、次の流れで足りる。

```
$ git status
$ git branch --show-current
$ git branch -M main
$ git remote add origin git@github.com:owner/project.git
$ git remote -v
$ git push -u origin main
```

git branch --show-current は、いま自分がどのブランチにいるかを確認する。git branch -M main は、既定ブランチ名を main へそろえるための書き方である。main ではなく既存のブランチ名をそのまま使いたいなら、その名前で push してよい。

git remote add origin ... は、GitHub の URL を origin という別名で登録する。git remote -v を見れば、正しい URL が設定されたかを確認できる。git push -u origin main の -u は、以後このローカルブランチが origin/main を追跡する、という設定である。初回にこれを付けておけば、次回以降は git push や git pull を短く書きやすい。

B.3.2.4 origin がすでにある場合

すでに origin が登録されている状態で git remote add origin ... を実行すると、エラーになる。その場合は、いま何が設定されているかを確認してから、必要なら URL を差し替える。

```
$ git remote -v
$ git remote set-url origin git@github.com:owner/project.git
$ git remote -v
```

教材を別のリポジトリから複製して流用した場合や、HTTPS から SSH へ切り替えたい場合に、この操作が必要になることがある。

B.3.3 GitHub と同期する

ローカルでコミットしただけでは、まだ GitHub には反映されない。GitHub 側から最新を取り込むのが pull、手元のコミットを送るのが push である。

```
$ git pull --ff-only
$ git push origin main
```

git pull --ff-only は、自分がまだ追加のコミットを持っていないときだけ安全に進める書き方である。履歴が分岐している場合は止まるので、意図しないマージを避けやすい。

B.3.4 GitHub で使う URL には HTTPS と SSH がある

GitHub のリポジトリ URL には、少なくとも HTTPS と SSH の 2 通りがある。

```
https://github.com/owner/repo.git
git@github.com:owner/repo.git
```

HTTPS は見慣れた URL で扱いやすい。一方 SSH は、公開鍵認証を済ませておけばパスワードやトークン入力を減らしやすい。どちらを使ってもよいが、混在させると混乱しやすいので、最初に方針を決めた方がよい。git clone、pull、push を通して運用をそろえるなら、本書では SSH を標準にする方が自然だと考える。特に、公開リポジトリを読む段階では HTTPS でも動くが、後で push や private repository の取得が必要になると認証方式が増えて煩雑になりやすい。そのため、最初から SSH へそろえておく方が混乱が少ない。

B.4 認証と最小ワークフロー

B.4.1 GitHub の認証: SSH 鍵を基本にし、必要なら PAT

GitHub では、HTTPS 経由の Git 操作で通常のアカウントパスワードは使えない。現在は、SSH 鍵を登録して使うか、個人用アクセストークン (PAT) を使うのが基本である。本書では SSH 鍵を使う方法を標準とし、HTTPS + PAT は事情がある場合の代替手段として扱う。

B.4.1.1 SSH 鍵を使う

SSH を使う場合は、付録 A を参照して公開鍵を用意し、それを GitHub の SSH and GPG keys へ登録する。GitHub CLI gh auth login --git-protocol ssh --web を使うと、その作業

を対話的に進めやすい。

B.4.1.2 PAT を使う

SSH 鍵を使えない事情があり、HTTPS で GitHub を使う場合は、プライベートリポジトリへの push や pull で PAT を使う。

1. GitHub の Settings を開く
2. Developer settings から Personal access tokens へ進む
3. fine-grained token か classic token を作る
4. 対象リポジトリと必要最小限の権限を選ぶ
5. 発行したトークンを安全に保管する

認証時には、ユーザー名は GitHub のアカウント名、パスワード欄には通常のパスワードではなく PAT を入れる。組織アカウントでは、SAML SSO の承認が別に必要なこともある。その場合は、発行したトークンをその組織用に追加承認しないと使えない。

fine-grained token は、どのリポジトリへ、どの操作権限だけを与えるかを細かく絞れる新しい方式である。個人の通常利用では、まずこちらを選ぶ方が安全である。これに対して classic token は古い方式で、広い権限をまとめて与える形になりやすい。古いツールや特殊な用途ではまだ必要になることがあるが、理由がなければ fine-grained の方を優先した方がよい。

SAML SSO は、組織アカウントで「そのトークンが本当に組織のリソースへアクセスしてよいか」を追加で承認する仕組みである。つまり、トークンを作っただけでは終わらず、対象組織に対して明示的に利用許可を与えないと push や pull に失敗することがある。個人リポジトリしか使わないなら通常は意識しなくてよいが、大学や研究所の GitHub 組織では重要になる。

B.4.2 初心者が押さえるべき最小ワークフロー

最初のうちは、次の順序だけ守れば十分である。

1. `git status` で状況を見る
2. `git diff` で変更内容を読む
3. `git add` で記録したいファイルを選ぶ
4. `git diff --cached` でコミット内容を再確認する
5. `git commit -m "..."` で記録する
6. GitHub とやり取りするなら `git pull --ff-only` と `git push` を使う

この流れを身に付ければ、教材の取得、uv プロジェクトの再現、共同研究でのコード共有まで一通り対応できる。最初からブランチ運用や複雑な履歴操作まで覚える必要はないが、`status` と `diff` を読まずに `add` や `commit` をする癖だけは避けた方がよい。

付録 C pybind11 による C++ 拡張モジュール

高速化を進めると、最終的に「この部分だけは C++ で書きたい」という場面が出てくる。そのとき、Python から自然に呼べる形で C++ 関数を公開する道具として便利なのが pybind11 である。本付録では、最小限の構成で C++ 製モジュールを作り、`pip install -e .` で使えるようにする流れを示す。

C.1 どのようなときに使うか

pybind11 が向いているのは、重いループや数値計算の核は C++ で書きたいが、入出力や可視化、制御全体は Python に残したい場合である。つまり、「公開する関数の数は少なく、内側だけが重い」という構造に合っている。

具体例として、時刻列 `times` に対して、差が `window` 以下のペア数を数える関数を C++ で実装する。これは高速化章で出てきた「重い内側のループ」を外へ出す典型例である。

C.2 最小構成

ディレクトリ構成は次のようになる。

fastcount_cpp/ の例

```
pyproject.toml
CMakeLists.txt
cpp/
`-- bindings.cpp
src/
`-- fastcount_cpp/
    `-- __init__.py
```

C.2.1 pyproject.toml

純粋な Python パッケージと違って、C++ 拡張ではビルドバックエンドも必要になる。ここでは `scikit-build-core` と `pybind11` を使う。`pybind11` は `setup.py` ベースでも扱えるが、この付録では C++ 側の構成を見通しよく保ちやすい `CMake` ベースの流儀でそろえる。

pyproject.toml

```
[build-system]
requires = [
    "pybind11>=2.13",
    "scikit-build-core>=0.10",
```

```

]
build-backend = "scikit_build_core.build"

[project]
name = "fastcount_cpp"
version = "0.1.0"
requires-python = ">=3.12"
dependencies = ["numpy>=2.0"]

[tool.scikit-build]
wheel.packages = ["src/fastcount_cpp"]

```

build-system に書いたパッケージは、拡張モジュールをコンパイルするために必要である。これは通常の実行時依存関係とは別物であり、dependencies へ混ぜない方が整理しやすい。

C.2.2 CMakeLists.txt

CMakeLists.txt

```

cmake_minimum_required(VERSION 3.15)
project(fastcount_cpp LANGUAGES CXX)

find_package(pybind11 CONFIG REQUIRED)

pybind11_add_module(_core cpp/bindings.cpp)
target_compile_features(_core PRIVATE cxx_std_17)
install(TARGETS _core DESTINATION fastcount_cpp)

```

pybind11_add_module が、Python から import できる共有ライブラリを作る中心になる。ここで作るモジュール名を _core にしておくと、Python 側では fastcount_cpp._core として参照できる。

C.2.3 C++ の実装

cpp/bindings.cpp

```

1 #include <cmath>
2 #include <cstdint>
3 #include <vector>
4
5 #include <pybind11/pybind11.h>
6 #include <pybind11/stl.h>
7
8 std::size_t count_pairs_within_window(
9     const std::vector<double>& times,
10     double window
11 ) {
12     std::size_t count = 0;
13     const std::size_t n = times.size();

```

```

14
15     for (std::size_t i = 0; i < n; ++i) {
16         for (std::size_t j = i + 1; j < n; ++j) {
17             if (std::abs(times[j] - times[i]) <= window) {
18                 ++count;
19             }
20         }
21     }
22     return count;
23 }
24
25 namespace py = pybind11;
26
27 PYBIND11_MODULE(_core, m) {
28     m.doc() = "Count_close_pairs_in_C++.";
29     m.def(
30         "count_pairs_within_window",
31         &count_pairs_within_window,
32         py::arg("times"),
33         py::arg("window"),
34         "Return the number of pairs whose time difference is within window."
35     );
36 }

```

pybind11/stl.h を include しているので、Python の list は自動で `std::vector<double>` に変換される。つまり、Python 側からは特別な変換コードを書かずに呼べる。

C.2.4 Python 側の入口

```

src/fastcount_cpp/__init__.py
1 """Python interface for the C++ pair counter."""
2
3 from ._core import count_pairs_within_window
4
5 __all__ = ["count_pairs_within_window"]

```

この `__init__.py` を用意しておくと、利用側は `from fastcount_cpp import count_pairs_within_window` と書ける。C++ 側の内部モジュール名 `_core` を意識せず済む。

C.3 ビルドとインストール

開発中は、プロジェクトの仮想環境を作ったうえで `editable install` するのが分かりやすい。

```

$ uv sync
$ source .venv/bin/activate
$ pip install -e .

```

```
$ python -c "from fastcount_cpp import count_pairs_within_window; print(
    count_pairs_within_window([0.0, 0.1, 0.4], 0.25))"
```

最後の出力は次のようになる。

```
1
```

これは、(0.0, 0.1) だけが窓 0.25 の中に入っていることを表している。

ここで重要なのは、純粋な Python の editable install と違い、C++ ソースを書き換えたら再ビルドが必要になることが多い点である。つまり、bindings.cpp を編集した後は、`pip install -e .` をもう一度実行するか、対応するビルドコマンドを走らせて更新する必要がある。

C.4 Python 側からの使い方

Python から見れば、これは普通のモジュールと同じである。

```
1 from fastcount_cpp import count_pairs_within_window
2
3 times = [0.0, 0.1, 0.4, 0.55]
4 window = 0.2
5
6 count = count_pairs_within_window(times, window)
7 print(count)
```

したがって、設計上は「どの関数を Python へ公開するか」を小さく保つ方がよい。まず Python 側で使いやすい関数シグネチャを決め、その中身だけを C++ へ差し替える、という順序で進めると壊れにくい。

C.5 どこまで C++ へ出すべきか

pybind11 を使えるようになると、つい多くの処理を C++ へ移したくなる。しかし、入出力や可視化、例外処理、引数整理まで全部 C++ へ押し出すと、かえって保守が難しくなる。通常は、次のように役割を分けるとよい。

- Python: ファイル読み込み、引数処理、図の保存、ワークフロー全体
- C++: 重いループ、組合せ探索、繰り返し数値計算

つまり、Python 側には分かりやすい API を残し、C++ 側には計算コアだけを押し込む。これが、pybind11 を長く使いやすく保つための基本方針である。

付録 D 正規表現の基本

正規表現は、文字列の集合を短く記述するための書き方である。grep、awk、Python の re モジュールなどで共通して使われ、ログの抽出、ファイル名の検査、検出器 ID の選別、時刻文字列の確認といった場面で役に立つ。ここでは、本文で触れた grep や awk の延長として、解析で本当に必要になる範囲をまとめる。

D.1 正規表現とは何か

D.1.1 文字どおりの一致とメタ文字

最初の一步は、普通の文字列検索と正規表現の違いを区別することである。det_A という文字列だけを探したいなら、文字をそのまま並べればよい。

```
$ grep "det_A" events.txt
```

これに対して、. や * のような特別な意味を持つ記号を使うと、「どの文字でもよい」「0 回以上くり返す」といった条件を書けるようになる。こうした特別な意味を持つ文字をメタ文字という。

```
.  
*  
+  
?  
^  
$  
[ ]  
( )  
|
```

たとえば det_. は det_A にも det_B にも一致する。. は「任意の 1 文字」を表すからである。逆に、ピリオドそのものを探したいなら、前にバックスラッシュを付けて \. のようにエスケープしなければならない。これは + や ? でも同じである。

D.1.2 ワイルドカードとの違い

シェルのワイルドカードと正規表現は似て見えるが、同じものではない。ls *.txt の * は「任意の文字列」を表すが、正規表現の * は「直前の要素の 0 回以上のくり返し」を表す。したがって、正規表現で「任意の文字列」を書きたいときは .* と書く。

表 D.1 は、見た目が似ていて混同しやすい 2 つの記法を並べたものである。この違いを混同すると、grep "*.txt" のように書いて期待通りに動かない。シェルが展開する記法なの

表 D.1 ワイルドカードと正規表現の違い

| 場面 | 記法 | 意味 |
|------|-----------|-------------------------|
| シェル | *.txt | 任意の名前で .txt で終わるファイル |
| 正規表現 | .*\.txt\$ | 任意の文字列で始まり .txt で終わる文字列 |

か、正規表現エンジンが読む記法なのかを意識することが重要である。

D.2 よく使う部品

D.2.1 アンカー（行頭と行末）

^は行頭、\$は行末を表す。したがって、文字列の一部ではなく「行全体がその形である」ことを確かめたいときに使う。

```
$ grep '^ERROR' run.log
$ grep 'txt$' filelist.txt
$ grep '^det_A$' detectors.txt
```

1 行目は ERROR で始まる行、2 行目は txt で終わる行、3 行目は行全体がちょうど det_A である行だけを取る。特に 3 行目のように両端をアンカーで挟むと、det_AB や xdet_A が紛れ込むのを防げる。

D.2.2 文字クラス [...] と代表的な省略記法

[abc] は a か b か c の 1 文字、[A-Z] は英大文字 1 文字を表す。検出器名やセンサー番号のように、限られた候補から 1 文字だけ変わる文字列を扱うときに便利である。

```
^det_[AB]$
^run_[0-9][0-9][0-9]$
^[A-Za-z_][A-Za-z0-9_]*$
```

1 行目は det_A または det_B、2 行目は run_001 のような 3 桁番号付きの名前、3 行目は Python 風の識別子に近い形を表す。範囲指定の [0-9] は非常によく使う。

Python の re では、数字 1 文字を \d、空白 1 文字を \s と書ける。

```
1 import re
2
3 re.fullmatch(r"det_[AB]", "det_A")
4 re.fullmatch(r"\d\d:\d\d:\d\d", "12:34:56")
5 re.search(r"\s+", "det_A_15.2")
```

ただし、grep や awk では \d や \s がそのまま使えないことがある。コマンドラインでは [0-9] や [[:space:]] を使う方が移植性が高い。

D.2.3 量指定子 *, +, ?

量指定子は、直前の要素が何回くり返されるかを表す。* は 0 回以上、+ は 1 回以上、? は 0 回または 1 回である。

```
ab*c
ab+c
colou?r
```

ab*c は ac、abc、abbbc に一致する。ab+c は少なくとも 1 個の b が必要なので ac には一致しない。colou?r は color と colour の両方に一致する。

解析では、「空白が 1 個以上続く」「符号が付くかもしれない」「小数点以下があるかもしれない」といった曖昧さを扱うときに量指定子が役立つ。

```
1 pattern = re.compile(r"^[+-]?[d+(\.\d+)?]$")
2
3 for text in ["12", "-3.5", "+0.25", "1.2.3"]:
4     print(text, bool(pattern.fullmatch(text)))
```

このパターンは、符号付き整数や小数を表し、1.2.3 のような壊れた文字列は弾く。

D.3 物理・データ解析での具体例

D.3.1 ログから必要な行だけを探す

実験ログやジョブログでは、まず異常行や特定の run だけを抜き出したい。アンカーと文字クラスを組み合わせると、かなり具体的な条件を書ける。

```
$ grep '^ERROR' run.log
$ grep '^2026-04-04 .* det_[AB] ' run.log
$ grep -E '^(WARN|ERROR)' run.log
```

3 行目では grep -E を使って | による選択を書いている。拡張正規表現を使うと括弧や + を素直に書けるので、条件が少し複雑になったらこちらの方が読みやすい。

D.3.2 検出器 ID やセンサー名を選別する

検出器名が det_A, det_B, det_C のように並んでいるなら、文字クラスや選択を使って対象を絞れる。

```
$ grep '^det_[AB]$' detector_ids.txt
$ awk '$1 ~ /^det_[AB]$/ {print $1, $3}' summary.txt
```

awk では \$1 /.../ の形で、1 列目とその正規表現に一致するかどうかを判定できる。列を見ながら条件を書くときは grep より awk の方が自然なことが多い。

D.3.3 Python で抽出と変換を同時に行う

正規表現は「一致したかどうか」だけでなく、「どの部分が一致したか」を取り出すのにも向いている。Python では `re.search` や `re.fullmatch` の戻り値から、必要部分を取り出せる。

```
1 import re
2
3 line = "2026-04-04_12:34:56_det_A_signal=15.2"
4 match = re.search(r"signal=(\d+\.\d+)", line)
5
6 if match:
7     signal = float(match.group(1))
8     print(signal)
```

括弧 (...) で囲んだ部分はキャプチャされ、`group(1)`、`group(2)` のように取り出せる。ログ 1 行から `run` 番号、検出器名、信号値を抜き出して数値へ変換するような処理では、この形が便利である。

D.4 Python の re と grep/awk の使い分け

D.4.1 Python では raw string を使う

Python の文字列中で `\` を多用すると読みにくくなる。そのため、正規表現を書くときは `r"..."` のような raw string を使うのが基本である。

```
1 import re
2
3 pattern = re.compile(r"^det_[A-Z]\d+$")
4 print(bool(pattern.fullmatch("det_A12")))
```

raw string を使わないと、`"\\d+"` のようにバックスラッシュを二重に書かなければならない。正規表現の意図が見えにくくなるので、特別な事情がなければ raw string を選ぶ方がよい。

D.4.2 search, match, fullmatch を使い分ける

`re.search` は文字列のどこかに一致があればよいとき、`re.match` は先頭から一致していればよいとき、`re.fullmatch` は文字列全体がその形かを確かめたいときに使う。ファイル名や識別子を検証するときは、意図せず余分な文字が混ざらないよう `fullmatch` を使う方が安全である。

```
1 import re
2
3 print(re.search(r"\d+", "run_42").group())
4 print(bool(re.match(r"run", "run_42")))
5 print(bool(re.fullmatch(r"run_\d+", "run_42")))
```

D.4.3 コマンドラインで十分な場面と、Python に移すべき場面

単に条件に合う行を見つけない、件数を数えたい、特定列だけを抜きたい、といった用途なら `grep` や `awk` が速い。逆に、一致した部分を数値へ変換して次の計算へ渡したい、複数の条件分岐を組み合わせた、抽出結果を `DataFrame` にしたい、といった場合は Python へ移した方が自然である。

- `grep`: 行全体の抽出や件数確認をすばやく行いたいとき
- `awk`: 列条件と正規表現を組み合わせたいとき
- Python `re`: 抽出した結果をそのまま解析処理へつなげたいとき

正規表現は強力だが、複雑な 1 行を無理に作ると自分でも読めなくなる。まずはアンカー、文字クラス、量指定子の 3 つで書けないかを考え、それでも足りないときに括弧や選択を足す方が安全である。解析コードと同じく、「まず読めること」を優先した方が長く使える。

付録 E シェルスクリプトによる自動化と一括処理

第 2.1 章ではシェルの対話的な基本操作を紹介した。実際のデータ解析では、1 つのスクリプトを数十から数百のファイルに対して繰り返し実行したり、実行時のパラメータを少しずつ変えながら条件を変えてプログラムを走らせたりする場面が非常に多くなる。このような自動化やバッチ処理を担うのがシェルスクリプトである。

本章では、単純なコマンドの列挙から一歩進み、引数の受け取り、変数の計算、ファイルの存在チェック、条件分岐 (if, case)、リスト (配列) と for ループを用いた実践的なバッチ処理の書き方と sed による置換を解説する。

E.1 シェルスクリプトの基礎構造

E.1.1 シバンと実行権限

シェルスクリプトを作成する際は、先頭に「どの解釈エンジン (シェル) で実行するか」を指定するシバン (shebang) を記述する。本書では UNIX 系の標準である bash を用いることを前提とする。

```
1 #!/bin/bash
2
3 echo "Hello, Shell Scripting!"
```

作成したファイル (例: run.sh) には実行権限を付与し、直接実行できるようにしておく。

```
$ chmod +x run.sh
$ ./run.sh
```

E.1.2 コマンドライン引数

スクリプトに外から値 (ファイル名や設定値) を渡すには、実行時の引数を利用する。スクリプト内からは \$1, \$2 といった特殊な変数で受け取れる。

- \$0: 実行されたスクリプトのファイル名 (例: ./run.sh)
- \$1, \$2, ...: 1 番目、2 番目の引数
- \$#: 渡された引数の総数
- \$@: 渡されたすべての引数 (リストとして展開される)

```
1 #!/bin/bash
2
3 # 引数が2つ渡されたかどうかを確認する簡易チェック
```

```

4 if [ "$#" -ne 2 ]; then
5     echo "Usage: $0 <input_file> <output_file>"
6     exit 1
7 fi
8
9 INPUT=$1
10 OUTPUT=$2
11 echo "Reading from $INPUT, writing to $OUTPUT"

```

E.2 変数、演算、条件式

E.2.1 変数の定義とリスト（配列）

シェルで変数を定義する際は、イコールの前後に空白を入れてはならない。また、変数の値を参照するときは先頭に \$ を付ける。

```

1 COUNT=100
2 NAME="data_analysis"
3
4 echo "The count is $COUNT."      # 展開される
5 echo 'The count is $COUNT.'      # シングルクォートでは展開されず "$COUNT" と表示される

```

カンマ区切りではなく、スペース区切りで括弧 () を用いるとリスト（配列）を定義できる。Python のリストのように扱うことができ、複数の対象をまとめて扱う際に非常に便利である。

```

1 # 配列の定義
2 targets=("background" "signal" "noise")
3
4 # 配列サイズの取得
5 echo "Number of targets: ${#targets[@]}"
6
7 # 配列要素へのアクセス
8 echo "First element: ${targets[0]}"
9
10 # 配列全体を展開する (for ループでよく使う)
11 echo "All elements: ${targets[@]}"

```

E.2.2 数値計算 (算術式展開)

bash で整数の足し算や掛け算を行う場合は、(())（二重丸括弧）を用いる。この中では、変数の \$ を省略でき、空白も自由に空けることができる。浮動小数点計算には対応していないため、少数を扱う場合は Python プログラムなどの外部コマンドに任せるか bc や awk を用いる。

```

1 A=10

```

```

2 B=5
3
4 # 計算式は (( )) を用いる
5 SUM=$(( A + B ))
6 MUL=$(( A * B ))
7
8 # 変数を直接加算・インクリメントする
9 (( A++ ))
10 (( B += 20 ))

```

E.2.3 条件式 (test コマンド)

数値の大小比較や、ファイルが存在するかどうかの確認には、`[ ]` を用いる。大括弧の内側には必ずスペースが必要である。

数値の比較:

- `-eq`: 等しい (equal)
- `-ne`: 等しくない (not equal)
- `-gt`: より大きい (greater than)
- `-ge`: 以上 (greater than or equal)
- `-lt`: 未満 (less than)
- `-le`: 以下 (less than or equal)

文字列の比較:

- `=`, `==`: 一致する
- `!=`: 一致しない
- `-z "$STR"`: 文字列が空である

ファイルやディレクトリの確認:

- `-e "$FILE"`: ファイル（またはディレクトリ）が存在する
- `-f "$FILE"`: 通常のファイルとして存在する
- `-d "$DIR"`: ディレクトリとして存在する

これらの条件式は、後述する `if` 文の `[ ]` の中身として頻繁に登場する。

E.3 条件分岐 (if, case)

E.3.1 if 文を用いた分岐

前節の条件式を組み合わせて処理を分岐する。`then` と `fi` でブロックを囲むのがシェルの特徴である。

```

1  #!/bin/bash
2  FILE=$1
3
4  if [ -z "$FILE" ]; then
5      echo "エラー: ファイル名が指定されていません"
6      exit 1
7  fi
8
9  if [ -f "$FILE" ]; then
10     echo "ファイル '$FILE' を発見しました。処理を開始します。"
11 elif [ -d "$FILE" ]; then
12     echo "エラー: '$FILE' はディレクトリです。ファイルを指定してください。"
13     exit 1
14 else
15     echo "エラー: '$FILE' が存在しません。"
16     exit 1
17 fi

```

E.3.2 case 文による分岐

条件が「特定の文字列パターンと一致するか」である場合は、case 文を用いると elif を重ねるよりもきれいに書ける。拡張子での判定や、オプション引数（-h, --version など）のパーズに有用である。

```

1  #!/bin/bash
2  MODE=$1
3
4  case "$MODE" in
5      "start")
6          echo "Starting process..."
7          ;;
8      "stop" | "halt")
9          echo "Stopping process..."
10         ;;
11     *)
12         echo "Unknown mode: $MODE"
13         echo "Available modes: start, stop, halt"
14         exit 1
15         ;;
16 esac

```

各区分の終わりは ;; で締めくくる。アスタリスク * は「上記以外のすべて」にマッチするワイルドカードとして機能する。

E.4 反復処理と一括自動化 (for)

E.4.1 配列やリストの要素に対する for ループ

指定した値のリストや、定義した配列の全要素に対して処理を繰り返す場合は以下のよう
に書く。

```
1 #!/bin/bash
2
3 # 配列の全要素に対して
4 targets=("run_01" "run_02" "run_03")
5
6 for t in "${targets[@]"; do
7     echo "Processing target: $t"
8 done
9
10 # 単純な数値の手書きリストやコマンド展開に対して
11 for num in 10 20 30; do
12     echo "Number is $num"
13 done
```

E.4.2 実践: 複数ファイルのパス置換とバッチ処理

実務で最もよく使うループは「特定のディレクトリにあるファイルを順次処理する」ための構文である。ここで、入力ファイル名（例: data/input/run01.csv）から、出力ファイル名（例: data/output/run01_result.png）を自動的に作り出す技術が必要となる。

basename コマンドや、変数の後方一致削除 (%...) を用いることでこれを簡潔に実装できる。

```
1 #!/bin/bash
2
3 INPUT_DIR="data/input"
4 OUTPUT_DIR="data/output"
5
6 # 出力先が存在しなければ作成する
7 if [ ! -d "$OUTPUT_DIR" ]; then
8     mkdir -p "$OUTPUT_DIR"
9 fi
10
11 # INPUT_DIR の中にあるすべての .csv ファイルに対して反復
12 for filepath in "$INPUT_DIR"/*.csv; do
13     # 該当するファイルが存在しない場合はそのままループが回ってしまうのでチェックする
14     if [ ! -f "$filepath" ]; then
15         echo "No CSV files found in $INPUT_DIR"
16         break
17     fi
```

```

18
19     echo "Found raw file: $filepath"
20
21     # basename コマンドでディレクトリパスを取り除き、ファイル名だけにする
22     # 例: "data/input/run01.csv" -> "run01.csv"
23     filename=$(basename "$filepath")
24
25     # 文字列置換: 後方の ".csv" を取り除く
26     # 例: "run01.csv" -> "run01"
27     name_no_ext="${filename%.csv}"
28
29     # 新しい出力パスを組み立て直す
30     output_path="$OUTPUT_DIR/${name_no_ext}_result.png"
31
32     echo "Running analysis Python code for: $name_no_ext"
33     # 実際の処理コマンド (例: python analyze.py <in> <out>)
34     # python analyze.py "$filepath" "$output_path"
35 done

```

このように記述することで、数十から数千のファイルをディレクトリに放り込んでスクリプトを実行するだけで、結果ファイルが名簿通りに正しく生成されていくシステムを作ることができる。

E.5 sed を用いたテンプレート書き換えと動的実行

外部の実行プログラムの中には、引数 (--input XXX) の形式ではなく、設定ファイル (例: config.ini) を読み込ませることで動作するものがある。バッチ処理で繰り返し実行したい場合、ループを回すたびに設定ファイルの特定のパラメータ (例えばシード値や閾値など) を書き換える必要が生じる。

強力なストリーム・エディタである sed コマンドを使うことで、「テンプレートとなる設定ファイル」を用意しておき、シェルスクリプトから一部の文字列だけを置換した「実行用設定ファイル」を動的に生成させることができる。

E.5.1 テンプレートファイルの準備

パラメータ部分をユニークなプレースホルダー文字 (例: __THRESHOLD__ や __OUTFILENAME__ のように、ファイル内の他の場所には現れない文字列) にした上で保存しておく。

config_template.ini

```

[Simulation]
Events = 10000
Threshold = __THRESHOLD__
OutputFile = __OUTFILENAME__

```

E.5.2 sed による置換の実行

シェルスクリプト内で変数をループさせ、sed によって置換した設定ファイルをその都度作成してプログラムに食わせる。

sed 's/置換前文字列/置換後文字列/g' 入力ファイル > 出力ファイル の形式を取る。この際、sed で変数を展開したい場合はシングルクォートではなく、ダブルクォート ("...") で囲む必要がある点に注意する。

```
1  #!/bin/bash
2
3  # 閾値を 3 つ変えてシミュレーション用の設定ファイルを動的生成し、実行する例
4  thresholds=(0.5 1.0 2.5)
5
6  for thresh in "${thresholds[@]}; do
7
8      out_name="result_th_${thresh}.dat"
9      run_config="config_run.ini"
10
11     echo "Generating config for Threshold=$thresh"
12
13     # sedコマンドを用いて __THRESHOLD__ と __OUTFILENAME__ の 2 箇所を同時に置換する。
14     # 変数 ($thresh など) を展開させるためダブルクォートで 's/.../.../g' 全体を囲む
15     sed -e "s/__THRESHOLD__/$thresh/g" \
16         -e "s/__OUTFILENAME__/$out_name/g" \
17         config_template.ini > "$run_config"
18
19     # 置換された設定の内容を出力して確認（または直接プログラムを走らせる）
20     cat "$run_config"
21
22     # 以下で実際のプログラムを呼び出す
23     # ./my_simulation_app --config "$run_config"
24
25 done
```

このような構成を取ることで、Python プログラムはもちろんのこと、ソースコードに手を加えることのできないバイナリ形式のシミュレーションソフトやコンパイル済みの C プログラムであっても、シェルから自在に大量の条件を連続実行・制御することが可能になる。

参考文献

参考文献

- [1] Python Software Foundation, *The Python Tutorial*, <https://docs.python.org/3/tutorial/>, 閱覽日: 2026-04-12.
- [2] Python Software Foundation, *The Python Standard Library*, <https://docs.python.org/3/library/>, 閱覽日: 2026-04-12.
- [3] Project Jupyter, *JupyterLab Documentation*, <https://jupyterlab.readthedocs.io/>, 閱覽日: 2026-04-12.
- [4] Astral, *uv Documentation*, <https://docs.astral.sh/uv/>, 閱覽日: 2026-04-12.
- [5] pyenv contributors, *pyenv README / Documentation*, <https://github.com/pyenv/pyenv>, 閱覽日: 2026-04-12.
- [6] NumPy Developers, *NumPy Documentation*, <https://numpy.org/doc/stable/>, 閱覽日: 2026-04-12.
- [7] NumPy Developers, *NumPy Quickstart*, <https://numpy.org/devdocs/user/quickstart.html>, 閱覽日: 2026-04-12.
- [8] pandas development team, *pandas Documentation*, <https://pandas.pydata.org/docs/>, 閱覽日: 2026-04-12.
- [9] pandas development team, *Getting started tutorials*, https://pandas.pydata.org/docs/getting_started/intro_tutorials/, 閱覽日: 2026-04-12.
- [10] pandas development team, *10 minutes to pandas*, https://pandas.pydata.org/pandas-docs/stable/user_guide/10min.html, 閱覽日: 2026-04-12.
- [11] pandas development team, *Indexing and selecting data*, https://pandas.pydata.org/docs/user_guide/indexing.html, 閱覽日: 2026-04-12.
- [12] pandas development team, *Working with missing data*, https://pandas.pydata.org/docs/user_guide/missing_data.html, 閱覽日: 2026-04-12.
- [13] pandas development team, *Merge, join, concatenate and compare*, https://pandas.pydata.org/docs/user_guide/merging.html, 閱覽日: 2026-04-12.
- [14] pandas development team, *Time series / date functionality*, https://pandas.pydata.org/docs/user_guide/timeseries.html, 閱覽日: 2026-04-12.
- [15] Polars project, *Polars Documentation*, <https://docs.pola.rs/>, 閱覽日: 2026-04-12.
- [16] Polars project, *Concepts*, <https://docs.pola.rs/user-guide/concepts/>, 閱覽日: 2026-04-

- 12.
- [17] Polars project, *Expressions and contexts*, <https://docs.pola.rs/user-guide/concepts/expressions-and-contexts/>, 閱覽日: 2026-04-12.
 - [18] Polars project, *Lazy API*, <https://docs.pola.rs/user-guide/concepts/lazy-api/>, 閱覽日: 2026-04-12.
 - [19] Polars project, *IO*, <https://docs.pola.rs/user-guide/io/>, 閱覽日: 2026-04-12.
 - [20] Polars project, *Coming from Pandas*, <https://docs.pola.rs/user-guide/migration/pandas/>, 閱覽日: 2026-04-12.
 - [21] Matplotlib Development Team, *Matplotlib Documentation*, <https://matplotlib.org/stable/>, 閱覽日: 2026-04-12.
 - [22] Matplotlib Development Team, *Quick start*, https://matplotlib.org/stable/users/explain/quick_start.html, 閱覽日: 2026-04-12.
 - [23] Matplotlib Development Team, *Plot types*, https://matplotlib.org/stable/plot_types/index.html, 閱覽日: 2026-04-12.
 - [24] Matplotlib Development Team, *Gallery*, <https://matplotlib.org/stable/gallery/index.html>, 閱覽日: 2026-04-12.
 - [25] Matplotlib Development Team, *Cheatsheets*, <https://matplotlib.org/cheatsheets/>, 閱覽日: 2026-04-12.
 - [26] SciPy community, *SciPy Documentation*, <https://docs.scipy.org/doc/scipy/>, 閱覽日: 2026-04-12.
 - [27] SciPy community, *SciPy User Guide*, <https://docs.scipy.org/doc/scipy/tutorial/>, 閱覽日: 2026-04-12.
 - [28] SciPy community, *Statistics*, <https://docs.scipy.org/doc/scipy/tutorial/stats.html>, 閱覽日: 2026-04-12.
 - [29] SciPy community, *Optimization*, <https://docs.scipy.org/doc/scipy/tutorial/optimize.html>, 閱覽日: 2026-04-12.
 - [30] SciPy community, *Interpolation*, <https://docs.scipy.org/doc/scipy/tutorial/interpolate.html>, 閱覽日: 2026-04-12.
 - [31] SciPy community, *Signal processing*, <https://docs.scipy.org/doc/scipy/tutorial/signal.html>, 閱覽日: 2026-04-12.
 - [32] SciPy community, *Integration*, <https://docs.scipy.org/doc/scipy/tutorial/integrate.html>, 閱覽日: 2026-04-12.
 - [33] Astropy Project, *Astropy Documentation*, <https://docs.astropy.org/>, 閱覽日: 2026-04-12.
 - [34] Astropy Project, *Getting Started*, https://docs.astropy.org/en/stable/index_getting_started.html, 閱覽日: 2026-04-12.
 - [35] Astropy Project, *User Guide*, https://docs.astropy.org/en/stable/index_user_docs.html, 閱覽日: 2026-04-12.

- [36] Astropy Project, *Units and Quantities*, <https://docs.astropy.org/en/stable/units/index.html>, 閱覽日: 2026-04-12.
- [37] Astropy Project, *Time and Dates*, <https://docs.astropy.org/en/stable/time/index.html>, 閱覽日: 2026-04-12.
- [38] Astropy Project, *Coordinates*, <https://docs.astropy.org/en/stable/coordinates/index.html>, 閱覽日: 2026-04-12.
- [39] Astropy Project, *Tables*, <https://docs.astropy.org/en/stable/table/index.html>, 閱覽日: 2026-04-12.
- [40] Astropy Project, *FITS File Handling*, <https://docs.astropy.org/en/stable/io/fits/index.html>, 閱覽日: 2026-04-12.
- [41] Git project, *Git Documentation*, <https://git-scm.com/doc>, 閱覽日: 2026-04-12.
- [42] GitHub, *GitHub Docs*, <https://docs.github.com/>, 閱覽日: 2026-04-12.